



دانشگاه صنعتی امیرکبیر
(پلی تکنیک تهران)
دانشکده مهندسی کامپیوتر

پایان نامه کارشناسی
مهندسی کامپیوتر

توسعه سامانه‌ای برای تحلیل احساسات ضمنی با
استفاده از زنجیره تفکر چندمرحله‌ای

نگارش

فاطمه درج

استاد راهنما

دکتر مصطفی حقیر چهرقانی

تیر ۱۴۰۵

بِسْمِ اللَّهِ الرَّحْمَنِ الرَّحِيمِ

صفحه فرم ارزیابی و تصویب پایان نامه - فرم تأیید اعضاء کمیته دفاع

در این صفحه فرم دفاع یا تأیید و تصویب پایان نامه موسوم به فرم کمیته دفاع - موجود در پرونده آموزشی - را قرار دهید.

نکات مهم:

- نگارش پایان نامه/رساله باید به **زبان فارسی** و بر اساس آخرین نسخه دستورالعمل و راهنمای تدوین پایان نامه های دانشگاه صنعتی امیرکبیر باشد.(دستورالعمل و راهنمای حاضر)
- رنگ جلد پایان نامه/رساله چاپی کارشناسی، کارشناسی ارشد و دکترا باید به ترتیب مشکی، طوسی و سفید رنگ باشد.
- چاپ و صحافی پایان نامه/رساله بصورت **پشت و رو(دورو)** بلامانع است و انجام آن توصیه می شود.



دانشگاه صنعتی امیرکبیر
(پلی تکنیک تهران)

به نام خدا

تعهدنامه اصالت اثر

تاریخ: تیر ۱۴۰۵

اینجانب **فاطمه درج** متعهد می‌شوم که مطالب مندرج در این پایان‌نامه حاصل کار پژوهشی اینجانب تحت نظارت و راهنمایی اساتید دانشگاه صنعتی امیرکبیر بوده و به دستاوردهای دیگران که در این پژوهش از آنها استفاده شده است مطابق مقررات و روال متعارف ارجاع و در فهرست منابع و مآخذ ذکر گردیده است. این پایان‌نامه قبلاً برای احراز هیچ مدرک هم‌سطح یا بالاتر ارائه نگردیده است.

در صورت اثبات تخلف در هر زمان، مدرک تحصیلی صادر شده توسط دانشگاه از درجه اعتبار ساقط بوده و دانشگاه حق پیگیری قانونی خواهد داشت.

کلیه نتایج و حقوق حاصل از این پایان‌نامه متعلق به دانشگاه صنعتی امیرکبیر می‌باشد. هرگونه استفاده از نتایج علمی و عملی، واگذاری اطلاعات به دیگران یا چاپ و تکثیر، نسخه‌برداری، ترجمه و اقتباس از این پایان‌نامه بدون موافقت کتبی دانشگاه صنعتی امیرکبیر ممنوع است. نقل مطالب با ذکر مآخذ بلامانع است.

فاطمه درج

امضا

تقدیم بہ پدر و مادر م،

کہ بامہر، شکیبایی و حیات ہمیشگی شان،

مسیر آموختن را برایم ہموار کردند.

سپاس‌گزاری

از استاد راهنمای ارجمندم، جناب آقای دکتر مصطفی حقیر چهرقانی، به سبب راهنمایی‌های علمی، دقت نظر و حمایت ایشان در مسیر انجام این پژوهش صمیمانه سپاس‌گزاری می‌کنم. همچنین از خانواده‌ام که در دوران تحصیل با شکیبایی و پشتیبانی همیشگی همراه من بودند، قدردانی می‌کنم.

فاطمه‌درج

تیر ۱۴۰۵

فهرست مطالب

صفحه

عنوان

۱		۱ مقدمه
۳		۱-۱ بیان مسئله
۵		۲-۱ اهمیت و ضرورت پژوهش
۵		۳-۱ اهداف پژوهش
۵		۱-۳-۱ هدف اصلی
۶		۲-۳-۱ اهداف فرعی
۷		۴-۱ پرسش‌های پژوهش
۷		۵-۱ نوآوری‌ها و دستاوردهای پروژه
۸		۶-۱ روش کلی پژوهش
۱۰		۷-۱ ساختار پایان‌نامه
۱۱		۲ تعاریف اولیه
۱۲		۱-۲ تحلیل احساسات
۱۲		۱-۱-۲ سطوح تحلیل احساسات
۱۳		۲-۱-۲ قطبیت احساس
۱۳		۲-۲ تحلیل احساسات مبتنی بر جنبه
۱۴		۱-۲-۲ هدف و جنبه
۱۴		۲-۲-۲ نظر و قطبیت
۱۵		۳-۲ تحلیل احساسات ضمنی
۱۵		۱-۳-۲ تفاوت احساس صریح و ضمنی
۱۵		۲-۳-۲ چالش‌های تحلیل احساسات ضمنی
۱۶		۴-۲ مدل‌های زبانی بزرگ و مهندسی پرامپت
۱۶		۱-۴-۲ یادگیری درون‌متنی و پرامپت صفرنمونه
۱۷		۲-۴-۲ خروجی آزاد و خروجی ساختاریافته
۱۷		۵-۲ استدلال زنجیره‌ای چندمرحله‌ای
۱۸		۶-۲ بازبینی استدلال و تشخیص خطا

۱۹	۷-۲ خودسازگاری و رأی اکثریت
۲۰	۸-۲ کنترل گر و انتخاب چندمنبعی
۲۱	۹-۲ معیارهای ارزیابی
۲۱	۱-۹-۲ دقت کلی
۲۲	۲-۹-۲ صحت پیش‌بینی، بازخوانی و امتیاز افیک
۲۲	۳-۹-۲ امتیاز افیک ماکرو
۲۳	۱۰-۲ جمع‌بندی
۲۴	۳ ادبیات تحقیق
۲۵	۱-۳ مقدمه
۲۵	۲-۳ تحول رویکردهای تحلیل احساسات
۲۵	۱-۲-۳ روش‌های مبتنی بر واژگان و یادگیری ماشین
۲۶	۲-۲-۳ روش‌های مبتنی بر شبکه‌های عصبی و مدل‌های زبانی
۲۷	۳-۳ پژوهش‌های تحلیل احساسات مبتنی بر جنبه و ضمنی
۲۷	۱-۳-۳ مجموعه داده‌ها و چارچوب‌های ارزیابی
۲۷	۲-۳-۳ روش‌های پیش از رویکردهای مولد
۲۸	۳-۳-۳ چالش‌های مشترک گزارش شده
۲۹	۴-۳ مهندسی پرامپت
۲۹	۵-۳ زنجیره تفکر در پژوهش‌های پردازش زبان طبیعی
۳۰	۶-۳ روش THOR برای تحلیل احساسات ضمنی
۳۰	۱-۶-۳ تجزیه استدلال به جنبه، نظر و قطبیت
۳۱	۲-۶-۳ خودسازگاری و بازبینی در THOR
۳۱	۳-۶-۳ نقاط قوت و محدودیت‌های THOR
۳۲	۷-۳ بازبینی و خوداصلاحی در تحلیل احساسات ضمنی
۳۲	۸-۳ خودسازگاری در استدلال چندمرحله‌ای
۳۳	۹-۳ کنترل گرها و انتخاب منبع پیش‌بینی
۳۴	۱۰-۳ مقایسه پژوهش‌های مرتبط
۳۴	۱۱-۳ شکاف تحقیقاتی و جایگاه پژوهش حاضر

۳۵	۱۲-۳ جمع‌بندی
۳۷	۴ کار پیشنهادی
۳۸	۱-۴ مقدمه
۳۸	۲-۴ صورت‌بندی مسئله
۳۸	۱-۲-۴ ورودی، خروجی و نمادگذاری
۳۹	۲-۲-۴ اصول طراحی
۴۰	۳-۴ نمای کلی سامانه پیشنهادی
۴۱	۴-۴ آماده‌سازی داده
۴۱	۱-۴-۴ منبع داده و واحد تحلیل
۴۱	۲-۴-۴ استخراج و پاک‌سازی نمونه‌ها
۴۲	۵-۴ خط پایه کلاسیک
۴۲	۱-۵-۴ بازنمایی TF-IDF و رگرسیون لجستیک
۴۳	۶-۴ تولید منابع اولیه پیش‌بینی
۴۳	۱-۶-۴ پیش‌بینی مستقیم
۴۳	۲-۶-۴ استدلال چندمرحله‌ای مبتنی بر THOR
۴۵	۳-۶-۴ خودسازگاری سه‌اجرایی
۴۵	۷-۴ بازبینی آگاه از نوع خطا
۴۵	۱-۷-۴ شرط فعال‌سازی بازبینی
۴۶	۲-۷-۴ رده‌بندی خطاها
۴۶	۳-۷-۴ قالب خروجی و ترمیم پاسخ
۴۷	۸-۴ کنترل‌گر تصمیم‌گیری میانی
۴۸	۹-۴ انتخاب منبع محافظت‌شده و تنظیم‌شده با داده آموزش
۴۸	۱-۹-۴ تعریف پروفایل انتخاب
۴۸	۲-۹-۴ یادگیری سیاست از بخش آموزش
۴۹	۳-۹-۴ تنظیم آستانه‌های محافظ با اعتبارسنجی داخلی
۴۹	۴-۹-۴ تولید پیش‌بینی نهایی
۵۰	۱۰-۴ انتخاب‌گرهای یادگرفتنی جایگزین

۵۰	۴-۱۰-۱ انتخاب‌گر فراسطح مبتنی بر درخت
۵۰	۴-۱۰-۲ رتبه‌بند لجستیک منبع
۵۱	۴-۱۱-۱ جزئیات پیاده‌سازی و بازتولیدپذیری
۵۱	۴-۱۱-۱ معماری نرم‌افزار
۵۱	۴-۱۱-۲ مدل‌ها و رابط اجرا
۵۲	۴-۱۱-۳ ذخیره، ادامه اجرا و اعتبارسنجی
۵۲	۴-۱۲ جمع‌بندی
۵۴	۵ نتایج آزمایش‌ها
۵۵	۵-۱ مقدمه
۵۵	۵-۲ تنظیمات آزمایش
۵۵	۵-۲-۱ مجموعه داده و تقسیم ارزیابی
۵۶	۵-۲-۲ مدل‌ها و زیرساخت اجرا
۵۶	۵-۲-۳ پروتکل ارزیابی و جلوگیری از نشت داده
۵۷	۵-۳ روش‌های مورد مقایسه و معیارهای ارزیابی
۵۷	۵-۳-۱ روش‌های مورد مقایسه
۵۸	۵-۳-۲ معیارهای ارزیابی
۵۸	۵-۴ نتایج روش‌های اصلی روی آزمون کامل
۵۸	۵-۴-۱ مقایسه کلی روش‌ها
۶۰	۵-۴-۲ تحلیل ماتریس‌های درهم‌ریختگی
۶۱	۵-۴-۳ تحلیل عملکرد بر اساس دامنه
۶۲	۵-۵ تحلیل انتخاب‌گر و مؤلفه‌های سامانه
۶۲	۵-۵-۱ توزیع منابع و سود یا زیان نسبت به مسیر مستقیم
۶۳	۵-۵-۲ مقایسه تصمیم‌میان، انتخاب‌گرهای فراسطح و کران‌اوراکل
۶۳	۵-۵-۳ اعتبارسنجی زنجیره نهایی
۶۴	۵-۶ تحلیل کیفی و خطا
۶۴	۵-۶-۱ نمونه‌های اصلاح‌شده
۶۴	۵-۶-۲ نمونه‌های تضعیف‌شده

۶۵	۳-۶-۵ الگوهای خطای باقی‌مانده
۶۶	۷-۵ مقایسه تکمیلی با Gemini 2.5 Flash
۶۶	۱-۷-۵ ساخت زیرمجموعه مشترک
۶۶	۲-۷-۵ مقایسه سنج‌های دو مدل
۶۷	۳-۷-۵ ماتریس‌های درهم‌ریختگی Gemini
۶۸	۸-۵ ملاحظات اجرایی و محدودیت‌ها
۶۹	۹-۵ جمع‌بندی
۷۰	۶ نتیجه‌گیری و کارهای آتی
۷۱	۱-۶ جمع‌بندی پژوهش
۷۲	۲-۶ پاسخ به پرسش‌های پژوهش
۷۳	۳-۶ دستاوردهای اصلی
۷۳	۱-۳-۶ دستاوردهای علمی
۷۴	۲-۳-۶ دستاوردهای فنی و مهندسی
۷۴	۴-۶ محدودیت‌های پژوهش
۷۵	۵-۶ کارهای آتی
۷۵	۱-۵-۶ توسعه و بهبود انتخاب‌گر منبع
۷۵	۲-۵-۶ بهبود بازبینی و استدلال هدف‌محور
۷۵	۳-۵-۶ تحلیل خطاهای مشترک و گسترش منابع
۷۶	۴-۵-۶ گسترش ارزیابی به داده‌ها و مدل‌های دیگر
۷۶	۵-۵-۶ کاهش هزینه اجرا
۷۶	۶-۵-۶ ارزیابی انسانی و ریزتنظیم
۷۶	۶-۶ نتیجه‌گیری نهایی
۷۸	منابع و مراجع
۸۰	پیوست: جزئیات بازتولید آزمایش‌ها
۸۳	واژه‌نامه فارسی به انگلیسی

۸۴	 واژه‌نامه انگلیسی به فارسی
----	----------------------------------

فهرست اشکال

شکل	صفحه
۱-۴ معماری کلی سامانه پیشنهادی.	۴۰
۱-۵ مقایسه دقت کلی و امتیاز افیک ماکرو هشت روش اصلی روی ۴۴۲ نمونه آزمون.	۶۰
۲-۵ ماتریس‌های درهم‌ریختگی پیش‌بینی مستقیم و سامانه نهایی Qwen3 8B روی آزمون	
کامل.	۶۱
۳-۵ مقایسه امتیاز افیک ماکرو Qwen3 8B و Gemini 2.5 Flash روی زیرمجموعه	
مشترک ۹۰ نمونه‌ای آزمون.	۶۷
۴-۵ ماتریس‌های درهم‌ریختگی پیش‌بینی مستقیم و سیاست انتخاب تنظیم‌شده برای	
Gemini 2.5 Flash روی آزمون مشترک.	۶۷

فهرست جداول

صفحه

جدول

۳۴	۱-۳ مقایسه پژوهش‌های محوری مرتبط با تحلیل احساسات ضمنی.
۴۶	۱-۴ انواع خروجی بازبینی تشخیصی و نقش آن‌ها در تصمیم‌گیری.
۵۱	۲-۴ مؤلفه‌های اصلی پیاده‌سازی سامانه پیشنهادی.
۵۶	۱-۵ توزیع نمونه‌های ضمنی در دو دامنه و دو بخش داده.
۵۸	۲-۵ نتایج روش‌های اصلی، از خط پایه کلاسیک تا سامانه نهایی، روی مجموعه کامل آزمون.
۶۱	۳-۵ امتیاز افیک کلاس‌ها برای پیش‌بینی مستقیم و سامانه نهایی Qwen3 8B.
۶۱	۴-۵ عملکرد پیش‌بینی مستقیم و سامانه نهایی به تفکیک دامنه در بخش آزمون.
۶۲	۵-۵ توزیع منبع منتخب در ۴۴۲ نمونه آزمون.
۶۳	۶-۵ مقایسه سیاست‌های انتخاب منبع روی ۴۴۲ نمونه آزمون Qwen3 8B.

فهرست نمادها

نماد	مفهوم
s	جمله ورودی
t	هدف مشخص شده در جمله
a	جنبه مرتبط با هدف
o	نظر ضمنی استنتاج شده
y	برچسب قطبیت طلایی
$\hat{y}$	برچسب قطبیت پیش‌بینی شده
P	صحت پیش‌بینی
R	بازخوانی
F_1	امتیاز اف‌یک
π	سیاست انتخاب منبع
$\mathcal{D}_{\text{train}}$	مجموعه آموزش
$\mathcal{D}_{\text{test}}$	مجموعه آزمون
$\mathcal{S}$	مجموعه منابع پیش‌بینی نامزد

فصل اول

مقدمه

با گسترش اینترنت، کاربران هر روز دیدگاه‌ها، نقدها و تجربه‌های فراوانی درباره محصولات، خدمات، رویدادها و اشخاص منتشر می‌کنند. این متن‌ها منبعی ارزشمند برای شناخت نیازها، ترجیحات و میزان رضایت کاربران به شمار می‌آیند. تحلیل آن‌ها به سازمان‌ها در بهبود محصولات و خدمات، شناسایی نقاط قوت و ضعف و تصمیم‌گیری آگاهانه‌تر کمک می‌کند. بی‌توجهی به این بازخوردها نیز ممکن است بخش مهمی از تجربه واقعی کاربران را از فرایند تصمیم‌گیری حذف کند.

حجم زیاد و رشد پیوسته متن‌های فضای مجازی بررسی دستی آن‌ها را دشوار و در بسیاری از کاربردها ناممکن کرده است. تحلیل احساسات^۱ یکی از شاخه‌های پردازش زبان طبیعی است که نگرش، ارزیابی یا حالت عاطفی موجود در متن را استخراج می‌کند. این حوزه در تحلیل دیدگاه مشتریان، پایش رضایت از خدمات، خلاصه‌سازی بازخوردها و پشتیبانی از تصمیم‌گیری کاربرد دارد.

در ساده‌ترین صورت، سامانه تحلیل احساسات قطبیت متن را در یکی از سه دسته مثبت، منفی یا خنثی قرار می‌دهد. با این حال، احساس در همه متن‌ها به یک شیوه بیان نمی‌شود. از نظر شیوه بیان، نمونه‌های احساسی به دو دسته کلی **احساس صریح** و **احساس ضمنی** تقسیم می‌شوند.

در احساس صریح، نویسنده نگرش خود را با واژه‌ها یا عبارت‌های ارزیابانه آشکار بیان می‌کند. برای مثال، در جمله «کیفیت صفحه نمایش این لپ‌تاپ عالی است»، واژه «عالی» نگرش مثبت نویسنده را نشان می‌دهد. در چنین نمونه‌هایی، یک واژه احساسی روشن می‌تواند سرنخ نیرومندی برای تعیین قطبیت باشد.

در احساس ضمنی، نگرش نویسنده بدون یک واژه احساسی مستقیم منتقل می‌شود. برای مثال، جمله «باتری لپ‌تاپ فقط دو ساعت دوام آورد» هیچ صفتی مانند «ضعیف» یا «نامناسب» ندارد. با این حال، دانش عمومی درباره عمر مطلوب باتری نگرش منفی جمله را آشکار می‌کند. بیان پیامد، مقایسه، توصیه، انتظار برآورده نشده یا تجربه خاص نیز می‌تواند حامل احساس باشد، بی‌آنکه قطبیت در متن ذکر شود. تشخیص این نوع نگرش موضوع تحلیل احساسات ضمنی^۲ است.

تمایز میان احساس صریح و ضمنی از نظر روش تحلیل اهمیت دارد. روش‌های متکی بر واژگان احساسی در نمونه‌های صریح سرنخ‌های مناسبی می‌یابند، اما در نمونه‌های ضمنی با کمبود شواهد مستقیم روبه‌رو می‌شوند. تحلیل احساسات ضمنی به درک بافت، تشخیص رابطه هدف با رویداد و استفاده از دانش عمومی نیاز دارد. سامانه همچنین باید گزارش خنثی را از ارزیابی غیرمستقیم متمایز کند و احساس یک موجودیت را به هدفی دیگر نسبت ندهد.

^۱Sentiment Analysis

^۲Implicit Sentiment Analysis (ISA)

مدل‌های زبانی بزرگ به دلیل دانش گسترده و توانایی استدلال زبانی، امکان تازه‌ای برای رویارویی با این چالش فراهم کرده‌اند. با این حال، استفاده از این مدل‌ها پرسش‌های مهمی ایجاد می‌کند. آیا استدلال چندمرحله‌ای همواره از پیش‌بینی مستقیم بهتر است؟ اگر مسیر استدلال منحرف شود، چگونه می‌توان خطا را تشخیص داد؟ هنگام اختلاف چند مسیر پیش‌بینی، کدام خروجی باید پاسخ نهایی باشد؟ پژوهش حاضر برای پاسخ به این پرسش‌ها، یک سامانه چندمنبعی و مبتنی بر پرامپت^۳ را طراحی و ارزیابی می‌کند. این سامانه پیش‌بینی مستقیم مدل زبانی را در کنار مسیر استدلال چندمرحله‌ای الهام‌گرفته از روش استدلال سه‌گامی THOR^۴ قرار می‌دهد. هنگام اختلاف، بازبینی ساختاریافته نوع خطای احتمالی، برچسب پیشنهادی و سطح اطمینان را تولید می‌کند. خروجی کنترل‌گر یک تصمیم‌میان‌ی است. پیش‌بینی نهایی با انتخاب تنظیم‌شده یکی از منابع مستقیم، استدلالی یا تشخیصی ساخته می‌شود. این فصل مسئله، ضرورت، اهداف، پرسش‌ها، دستاوردها و روش کلی پژوهش را بیان می‌کند.

۱-۱ بیان مسئله

تمرکز این پژوهش بر تحلیل احساسات ضمنی مبتنی بر هدف است. ورودی مسئله از یک جمله و هدفی مشخص در همان جمله تشکیل می‌شود. هدف می‌تواند محصول، خدمت، ویژگی یا موجودیت مورد ارزیابی باشد. سامانه باید برای هر زوج جمله و هدف، یکی از سه قطبیت مثبت، منفی یا خنثی را پیش‌بینی کند. از آنجا که نمونه‌ها ضمنی‌اند، قطبیت از نشانه‌های پراکنده، غیرمستقیم یا وابسته به دانش عمومی استنباط می‌شود.

دشواری نخست تشخیص سرنخ واقعی نظر است. اشاره به یک ویژگی یا رویداد به تنهایی حامل احساس نیست. تفسیر بیش‌ازحد یک گزاره خنثی نیز می‌تواند به پیش‌بینی نادرست منجر شود. در مقابل، بعضی پیامدها بدون واژه احساسی مطلوب یا نامطلوب‌اند. نادیده گرفتن این رابطه باعث از دست رفتن احساس ضمنی می‌شود. دشواری دوم رعایت دامنه هدف است. ممکن است جمله چند موجودیت یا چند جنبه داشته باشد. در این حالت، استدلال درباره موجودیتی غیر از هدف تعیین‌شده قطبیت را جابه‌جا می‌کند. ابهام زبانی، نیاز به دانش عرفی و تفاوت دامنه‌ها نیز مسئله را پیچیده‌تر می‌کنند.

یک راه ساده ارائه جمله و هدف به مدل زبانی و درخواست مستقیم یکی از سه برچسب است. این

^۳Prompt-based

^۴Three-hop Reasoning (THOR), introduced in “Reasoning Implicit Sentiment with Chain-of-Thought Prompting”

راه یک خط پایه^۵ قوی، کم‌هزینه و روشن فراهم می‌کند. با این حال، مشخص نمی‌کند که مدل بر چه سرنخی تکیه کرده یا در کدام مرحله دچار خطا شده است. راه دیگر تجزیه تصمیم به شناسایی جنبه، استخراج نظر ضمنی، استدلال درباره قطبیت و تولید برچسب است. این مسیر ردپای قابل بررسی‌تری ایجاد می‌کند، اما افزایش تعداد گام‌ها دقت را تضمین نمی‌کند. خطای هر گام می‌تواند به گام‌های بعدی منتقل شود و یک استدلال روان نیز به برچسب نادرست برسد.

بررسی خروجی‌های پروژه نشان می‌دهد که هیچ منبعی در همه وضعیت‌ها برتری مطلق ندارد. پیش‌بینی مستقیم در بسیاری از نمونه‌ها درست است، در حالی که مسیر چندمرحله‌ای در بعضی اختلاف‌ها سرنخ مناسب‌تری فراهم می‌کند. بازبینی تشخیصی نیز گاهی نوع خطا را آشکار می‌کند، اما اعتماد بدون قید و شرط به آن خطر اصلاح نادرست دارد. از این رو، مسئله پژوهش فقط تولید یک زنجیره استدلال نیست. سامانه باید چند نشانه ناهمگون را کنترل‌شده ترکیب کند و بدون مشاهده برچسب طلایی آزمون، منبع مناسب پاسخ را برگزیند.

برای مطالعه این مسئله، داده‌های برچسب‌خورده روش پیش‌آموزش تقابلی نظارت‌شده SCAPT^۶ مبتنی بر مجموعه SemEval 2014 در دو دامنه لپ‌تاپ و رستوران به کار رفته‌اند. پس از استخراج نمونه‌های ضمنی و حذف برچسب‌های نامعتبر، مجموعه اصلی شامل ۲۱۸۸ نمونه است. از این تعداد، ۱۷۴۶ نمونه به بخش آموزش و ۴۴۲ نمونه به بخش آزمون تعلق دارند.

ارزیابی اصلی سامانه روی مجموعه کامل آزمون با مدل Qwen3 8B و از طریق Ollama انجام شده است. افزون بر آن، چارچوب آزمایشی با Gemini 2.5 Flash نیز روی یک زیرمجموعه متوازن ۲۴۰ نمونه‌ای اجرا شده است. این زیرمجموعه ۱۵۰ نمونه آموزشی و ۹۰ نمونه آزمون دارد. اجرای Gemini از طریق یک درگاه سازگار با OpenAI انجام شده است. به دلیل تفاوت دامنه ارزیابی، نتایج Gemini مقایسه‌ای تکمیلی هستند و جایگزین ارزیابی کامل Qwen نیستند. وزن هیچ‌یک از مدل‌ها تغییر نکرده است؛ بنابراین، مراحل زبانی صفرنمونه‌ای^۷ و مبتنی بر پرامپت هستند. فقط سیاست انتخاب منبع نهایی با استفاده از بخش آموزش تنظیم می‌شود.

بر این اساس، مسئله مرکزی پایان‌نامه چنین صورت‌بندی می‌شود: چگونه می‌توان پیش‌بینی مستقیم، استدلال چندمرحله‌ای، بازبینی خطا و انتخاب داده‌محور منبع را ادغام کرد؟ این ادغام باید تصمیمی قابل اتکا، قابل تحلیل و بازتولیدپذیر برای تحلیل احساسات ضمنی فراهم کند.

^۵Baseline

^۶Supervised Contrastive Pre-Training (SCAPT)

^۷Zero-shot

۲-۱ اهمیت و ضرورت پژوهش

بخش قابل توجهی از بازخوردهای واقعی به صورت گزارش تجربه، مقایسه، توصیه، کنایه یا بیان پیامد نوشته می‌شوند. سامانه متکی بر واژگان احساسی آشکار ممکن است معنای عملی چنین متن‌هایی را از دست بدهد. این مسئله در تحلیل دیدگاه مشتریان، پایش کیفیت خدمات، خلاصه‌سازی بازخوردها و پشتیبانی از تصمیم‌گیری سازمانی اهمیت دارد. نتیجه تحلیل باید نگرش به هدف مشخص را منعکس کند، نه فقط وجود چند واژه مثبت یا منفی را.

از منظر علمی، تحلیل احساسات ضمنی چند چالش مهم را دربرمی‌گیرد: استنتاج دانش عمومی، تشخیص هدف، تفکیک توصیف خنثی از ارزیابی و کنترل خطای استدلال. مدل‌های زبانی بزرگ می‌توانند برای این مسائل توضیح و زنجیره استدلال تولید کنند. با این حال، کیفیت ظاهری توضیح صحت پاسخ را تضمین نمی‌کند. از این رو، پیش‌بینی مستقیم، مسیر استدلال و رفتار انتخاب‌گر نهایی باید هم‌زمان ارزیابی شوند.

ضرورت دیگر پژوهش به فاصله میان یک پرامپت آزمایشی و یک سامانه بازتولیدپذیر مربوط است. اجرای قابل اتکا به آماده‌سازی داده، یکنواخت‌سازی خروجی، ادامه اجرای قطع شده و ذخیره خروجی‌های میانی نیاز دارد. کنترل برچسب‌های نامعتبر، هم‌ترازی ردیف‌ها و تعریف معیارهای ارزیابی نیز ضروری است. معماری پروژه هر مرحله را در خروجی مستقلاً ثبت می‌کند تا اثر مؤلفه‌ها و منشأ تصمیم نهایی قابل بررسی باشد.

این پژوهش از نظر روش‌شناختی نیز اهمیت دارد. تنظیم سیاست با داده آموزش و گزارش عملکرد روی همان داده، برداشتی خوش‌بینانه ایجاد می‌کند. از این رو، معیار اصلی مقایسه، عملکرد روی بخش آزمون است. سیاست انتخاب منبع نیز بدون استفاده از برچسب‌های طلایی آزمون اعمال می‌شود. این تفکیک اعتبار ارزیابی و امکان مقایسه منصفانه با خط پایه را حفظ می‌کند.

۳-۱ اهداف پژوهش

۱-۳-۱ هدف اصلی

هدف اصلی پژوهش طراحی، پیاده‌سازی و ارزیابی یک سامانه چندمنبعی برای تحلیل احساسات ضمنی است. این سامانه پیش‌بینی مستقیم را با استدلال چندمرحله‌ای، بازبینی ساختاریافته و انتخاب منبع

تنظیم‌شده با داده آموزش ترکیب می‌کند. سامانه بدون ریزتنظیم^۸ وزن‌های مدل، برای هر زوج جمله و هدف یکی از سه برچسب را تولید می‌کند. خروجی‌های میانی نیز برای تحلیل رفتار و خطا ذخیره می‌شوند.

۱-۳-۲ اهداف فرعی

برای دستیابی به هدف اصلی، اهداف فرعی زیر دنبال می‌شوند:

- استخراج و پاک‌سازی نمونه‌های احساس ضمنی از داده‌های SCAPT مربوط به دامنه‌های لپ‌تاپ و رستوران و حفظ تقسیم آموزش و آزمون؛
- ایجاد یک خط پایه پیش‌بینی مستقیم با خروجی سه‌کلاسه و یک‌نواخت‌شده؛
- پیاده‌سازی یک مسیر استدلال چندمرحله‌ای به سبک THOR برای تولید جنبه، نظر ضمنی، استدلال قطبیت و برچسب؛
- بررسی خودسازگاری^۹ سه‌گانه و رأی اکثریت برای کاهش نوسان مسیر استدلال؛
- طراحی بازبینی آگاه از نوع خطا با خروجی ساختاریافته شامل نوع خطا، برچسب پیشنهادی و سطح اطمینان؛
- طراحی کنترل‌گری صریح برای مدیریت توافق، اختلاف و اصلاح‌های تشخیصی به عنوان یک تصمیم میانی؛
- یادگیری یک سیاست انتخاب منبع از بخش آموزش و اعمال آن بر بخش آزمون، بدون استفاده از برچسب طلایی آزمون؛
- مقایسه مؤلفه‌ها با معیارهای دقت و امتیاز افیک ماکرو^{۱۰} و انجام مطالعات حذف مؤلفه و تحلیل خطا؛
- اعتبارسنجی هم‌ترازی خروجی‌ها، استخراج نمونه‌های کیفی و فراهم‌سازی اجرای بازتولیدپذیر؛

^۸Fine-tuning

^۹Self-consistency

^{۱۰}Macro-F1

- اجرای چارچوب آزمایشی با Gemini 2.5 Flash روی زیرمجموعه‌ای متوازن و مقایسه آن با اجرای متناظر Qwen3 8B.

۴-۱ پرسش‌های پژوهش

پژوهش حاضر بر پاسخ‌گویی به پرسش‌های زیر متمرکز است:

۱. پیش‌بینی مستقیم و استدلال چندمرحله‌ای در تحلیل احساسات ضمنی چه تفاوتی دارند؟ آیا استدلال چندمرحله‌ای به تنهایی همواره موجب بهبود می‌شود؟
۲. آیا بازبینی ساختاریافته نوع خطا و یک کنترل‌گر صریح می‌توانند اختلاف میان پیش‌بینی مستقیم و استدلالی را به تصمیمی قابل کنترل‌تر تبدیل کنند؟
۳. آیا انتخاب منبع بر اساس الگوهای آموخته‌شده از داده آموزش می‌تواند در بخش آزمون از اتکالی ثابت به یک منبع بهتر عمل کند؟
۴. کدام الگوهای خطا بیشترین نقش را در شکست سامانه دارند؟ آیا از دست رفتن احساس، تفسیر بیش‌ازحد و جابه‌جایی دامنه هدف از الگوهای اصلی هستند؟
۵. انتخاب مدل و پشتانه اجرا چه ارتباطی با عملکرد مسیر مستقیم، استدلال چندمرحله‌ای و انتخاب منبع دارد؟ مقایسه محدود دو مدل چه شواهدی فراهم می‌کند؟

۵-۱ نوآوری‌ها و دستاوردهای پروژه

- نوآوری این پروژه ارائه الگوریتمی بنیادین برای مدل‌های زبانی نیست. نوآوری پژوهش در طراحی و ارزیابی ترکیبی منسجم برای تحلیل احساسات ضمنی قرار دارد. دستاوردهای اصلی پروژه عبارت‌اند از:
 - ایجاد یک خط لوله انتهابه‌انتهای از تبدیل داده خام تا ارزیابی و تحلیل کیفی، با خروجی‌های میانی قابل ردیابی برای همه مراحل اصلی؛
 - استفاده از THOR به عنوان منبع استدلال و نشانه مکمل، نه فرض کردن آن به عنوان پاسخ نهایی و قطعی سامانه؛

- تبدیل بازبینی آزاد به تشخیص ساختاریافته خطا، شامل مجموعه‌ای مشخص از انواع خطا، برچسب اصلاحی و سطح اطمینان؛
 - تفکیک روشن میان خروجی کنترل‌گر و پیش‌بینی نهایی؛ کنترل‌گر یک تصمیم میانی تولید می‌کند، درحالی‌که پاسخ نهایی از میان منابع مستقیم، THOR و تشخیصی انتخاب می‌شود؛
 - طراحی سیاست محافظت‌شده انتخاب منبع بر پایه الگویی شامل برچسب‌های مستقیم و THOR، نوع خطا، اطمینان تشخیصی و دامنه؛ برای هر الگو، بهترین منبع در داده آموزش تعیین می‌شود و گروه‌های کم‌پشتیبانی، کم‌حاشیه یا دیده‌نشده به منبع مستقیم بازمی‌گردند؛
 - اعتبارسنجی خودکار زنجیره نهایی از نظر تعداد ردیف‌ها، یکتایی کلیدها، هم‌ترازی خروجی‌ها و اعتبار برچسب‌های نهایی؛
 - اجرای مقایسه تکمیلی Qwen3 8B و Gemini 2.5 Flash روی یک زیرمجموعه متوازن مشترک؛
 - ارائه شواهد عددی و کیفی از اثر ترکیب چندمنبعی: در بخش آزمون ۴۴۲ نمونه‌ای، دقت از ۶۷۸۷۳۳٪ در خط پایه مستقیم به ۷۲۳۹۸۲٪ و امتیاز افیک ماکرو از ۶۷۴۰۷۵٪ به ۷۱۹۱۱۹٪ رسیده است. همچنین، سامانه نهایی ۲۶ خطای خط پایه را اصلاح کرده و در ۶ مورد، پاسخ درست خط پایه را به پاسخ نادرست تبدیل کرده است.
- این نتایج به معنای برتری مستقل استدلال چندمرحله‌ای نیستند. در تنظیم آزمایشی حاضر، مسیر THOR به تنهایی از خط پایه مستقیم ضعیف‌تر بوده است. ارزش این مسیر در فراهم کردن استدلال، منبع مکمل و اطلاعات لازم برای بازبینی و انتخاب نهایی آشکار می‌شود. ازاین‌رو، دستاورد محوری پروژه را باید در مدیریت اختلاف و انتخاب آگاهانه منبع جست‌وجو کرد.

۶-۱ روش کلی پژوهش

روش پژوهش از پنج مرحله متوالی و قابل تفکیک تشکیل شده است. در مرحله نخست، فایل‌های برچسب‌خورده SCAPT خوانده می‌شوند. برای هر عبارت هدف، جمله، دامنه، تقسیم داده، بازه هدف، قطبیت و ضمنی بودن استخراج می‌شود. سپس نمونه‌های دارای قطبیت تعارضی حذف و داده سه‌کلاسه ضمنی ساخته می‌شود. تقسیم رسمی آموزش و آزمون نیز در تمام مراحل حفظ می‌شود.

در مرحله دوم، دو منبع اصلی پیش‌بینی تولید می‌شوند. در ارزیابی اصلی، هر دو منبع با Qwen3 8B و از طریق Ollama اجرا می‌شوند. منبع نخست فقط جمله و هدف را دریافت می‌کند و یکی از سه برچسب را برمی‌گرداند. منبع دوم پیاده‌سازی نزدیک به منطق THOR است. این منبع تصمیم را به استنتاج جنبه، نظر ضمنی، استدلال قطبیت و تولید برچسب تقسیم می‌کند. مسیر استدلال سه بار با دمای غیرصفر اجرا می‌شود و رأی اکثریت برچسب THOR را تعیین می‌کند. هنگام تساوی، نخستین برچسب معتبر میان گزینه‌های مساوی انتخاب می‌شود. یکی از اجراهای هم‌سو با رأی نهایی نیز به عنوان ردپای نماینده نگهداری می‌شود.

در مرحله سوم، فقط هنگامی که پیش‌بینی مستقیم و THOR اختلاف دارند، بازبینی آگاه از نوع خطا فعال می‌شود. بازبین با مشاهده جمله، هدف، برچسب مستقیم و ردپای استدلالی، نوع خطا، برچسب پیشنهادی و اطمینان را در قالبی ساختاریافته تولید می‌کند. انواع خطا شامل احساس ازدست‌رفته، تفسیر بیش‌ازحد خنثی، جابه‌جایی دامنه هدف و ناهماهنگی جنبه و نظر هستند. ناسازگاری استدلال و برچسب و نبود شواهد کافی نیز در این مجموعه قرار دارند. سپس یک کنترل‌گر قاعده‌محور توافق، قابلیت اصلاح و سطح اطمینان را بررسی می‌کند و تصمیمی میانی می‌سازد.

در مرحله چهارم، انتخاب منبع نهایی انجام می‌شود. نمونه‌های بخش آموزش بر اساس پنج ویژگی برچسب مستقیم، برچسب THOR، نوع خطا، اطمینان تشخیصی و دامنه گروه‌بندی می‌شوند. در هر گروه، تعداد پیش‌بینی‌های درست سه منبع مستقیم، THOR و تشخیصی محاسبه می‌شود. واگذاری به منبعی غیر از مستقیم فقط هنگامی انجام می‌شود که پشتیبانی، حاشیه برتری و بهبود نسبی تنظیم‌شده با اعتبارسنجی داخلی کافی باشند؛ در غیر این صورت، منبع مستقیم گزینه بازگشت است. در این مرحله هیچ برچسب طلایی از بخش آزمون در دسترس انتخاب‌گر نیست.

در مرحله پنجم، همه روش‌ها با دقت و امتیاز افیک ماکرو ارزیابی می‌شوند. امتیاز افیک ماکرو در کنار دقت گزارش می‌شود تا عملکرد هر سه کلاس در نتیجه نقش یکسان‌تری داشته باشد. نتیجه اصلی از اجرای Qwen3 8B روی مجموعه کامل آزمون به دست می‌آید. برای مقایسه تکمیلی انتخاب مدل و پشته اجرا، همان چارچوب با Gemini 2.5 Flash روی زیرمجموعه متوازن ۲۴۰ نمونه‌ای اجرا می‌شود. اجرای متناظر Qwen3 8B روی همین زیرمجموعه مبنای مقایسه منصفانه با Gemini است. نتایج این مقایسه به دلیل محدوده متفاوت، جایگزین نتیجه اصلی نیستند و اثر علی اندازه مدل را نشان نمی‌دهند. در تمام اجراهای گزارش‌شده، وزن مدل‌های زبانی ثابت می‌ماند و هیچ ریزتنظیمی انجام نمی‌شود. افزون بر معیارهای عددی، تحلیل خطا، نمونه‌های کیفی، مطالعات سیاست انتخاب و هم‌ترازی فایل‌ها نیز بررسی می‌شوند.

۷-۱ ساختار پایان نامه

این پایان نامه در شش فصل تنظیم شده است:

۱. فصل نخست با عنوان «مقدمه» مسئله، ضرورت، اهداف، پرسش‌های پژوهش، دستاوردها و روش کلی را معرفی می‌کند.

۲. فصل دوم با عنوان «تعاریف اولیه» مفاهیم پایه تحلیل احساسات، مدل‌های زبانی، استدلال زنجیره‌ای و معیارهای ارزیابی را تعریف می‌کند.

۳. فصل سوم با عنوان «ادبیات تحقیق» پژوهش‌های مرتبط با تحلیل احساسات ضمنی، روش THOR، خوداصلاحی و انتخاب منبع را مرور می‌کند.

۴. فصل چهارم با عنوان «کار پیشنهادی» معماری سامانه، آماده‌سازی داده، مسیرهای پیش‌بینی، بازبینی و سیاست انتخاب منبع را تشریح می‌کند.

۵. فصل پنجم با عنوان «نتایج آزمایش‌ها» تنظیمات آزمایش، نتایج کمی، مطالعات حذف مؤلفه، تحلیل کیفی و مقایسه مدل‌ها را ارائه می‌دهد.

۶. فصل ششم با عنوان «نتیجه‌گیری و کارهای آتی» یافته‌ها را جمع‌بندی می‌کند، به پرسش‌های پژوهش پاسخ می‌دهد و کارهای آینده را شرح می‌دهد.

فصل دوم

تعاریف اولیه

فصل نخست مسئله تحلیل احساسات ضمنی و نمای کلی سامانه پژوهش را معرفی کرد. برای تشریح دقیق ادبیات تحقیق و روش پیشنهادی، لازم است اصطلاحات اصلی با معنایی یکسان به کار روند. این فصل مفاهیم پایه تحلیل احساسات، مدل‌های زبانی، استدلال چندمرحله‌ای و ارزیابی طبقه‌بندی را تعریف می‌کند. تمرکز فصل بر تعریف‌ها و رابطه میان مفاهیم است؛ جزئیات پژوهش‌های پیشین در فصل سوم و نحوه پیاده‌سازی سامانه در فصل چهارم ارائه می‌شوند.

۱-۲ تحلیل احساسات

تحلیل احساسات یکی از مسائل پردازش زبان طبیعی است که نگرش یا ارزیابی بیان‌شده در متن را شناسایی می‌کند. خروجی این تحلیل می‌تواند قطبیت، شدت احساس یا رابطه نگرش با یک هدف مشخص باشد. در این پایان‌نامه، قطبیت نسبت به یک هدف معین اهمیت دارد؛ بنابراین، وجود یک واژه مثبت یا منفی در جمله برای تعیین پاسخ کافی نیست.

تحلیل احساسات با تشخیص هیجان یکسان نیست. هیجان به حالت‌هایی مانند شادی، خشم، ترس یا اندوه اشاره دارد. احساس در معنای مورد نظر این پژوهش، ارزیابی مطلوب، نامطلوب یا خنثی نسبت به یک موجودیت است. همچنین، ذهنی‌بودن یک جمله لزوماً قطبیت آن را تعیین نمی‌کند. ممکن است جمله‌ای ذهنی باشد، اما ارزیابی روشنی درباره هدف مورد نظر نداشته باشد.

۱-۱-۲ سطوح تحلیل احساسات

سطح تحلیل مشخص می‌کند که قطبیت برای کدام واحد زبانی یا معنایی پیش‌بینی می‌شود. سه سطح رایج عبارت‌اند از:

- **سطح سند:** یک برچسب برای کل متن تعیین می‌شود. این سطح معمولاً فرض می‌کند که سند درباره یک موضوع اصلی و دارای یک نگرش غالب است.
- **سطح جمله:** هر جمله جداگانه طبقه‌بندی می‌شود. وجود چند هدف یا چند نگرش متفاوت در یک جمله می‌تواند این سطح را با ابهام روبه‌رو کند.
- **سطح هدف یا جنبه:** قطبیت نسبت به هدف یا ویژگی مشخصی از آن تعیین می‌شود. در این سطح، یک جمله می‌تواند برای دو هدف، دو برچسب متفاوت داشته باشد.

سطح سوم برای این پژوهش مناسب‌تر است، زیرا ورودی شامل متن و هدف تعیین‌شده است. در یک صورت‌بندی عمومی، متن با x ، هدف با t و برچسب قطبیت با y نمایش داده می‌شود. تابع طبقه‌بندی نگاشت زیر را می‌آموزد یا اجرا می‌کند:

$$f(x, t) \rightarrow y, \quad y \in \mathcal{Y}. \quad (1-2)$$

مجموعه $\mathcal{Y}$ فضای برچسب‌ها است. هدف t نیز دامنه ارزیابی را محدود می‌کند. در نتیجه، قطبیت موجودیت‌های دیگر نباید به هدف نسبت داده شود.

۲-۱-۲ قطبیت احساس

قطبیت جهت کلی ارزیابی را نشان می‌دهد. فضای برچسب این پایان‌نامه از سه کلاس تشکیل شده است:

- مثبت: متن، هدف را مطلوب، مفید یا سازگار با انتظار نشان می‌دهد.
- منفی: متن، هدف را نامطلوب، زیان‌آور یا ناسازگار با انتظار نشان می‌دهد.
- خنثی: شواهد کافی برای ارزیابی مثبت یا منفی هدف وجود ندارد.

برچسب خنثی فقط به معنای نبود واژه احساسی نیست. یک متن بدون واژه احساسی می‌تواند نگرش ضمنی داشته باشد. از سوی دیگر، وجود واژه احساسی نیز لزوماً قطبیت هدف را تعیین نمی‌کند. ممکن است آن واژه به موجودیتی دیگر اشاره کند یا در ساختاری مانند نفی و مقایسه به کار رفته باشد. در این پژوهش، خنثی‌بودن با ابهام نیز تفاوت دارد. ابهام به نبود قطعیت در تفسیر اشاره می‌کند، اما خنثی یک برچسب معنایی است. سامانه طبقه‌بندی باید با وجود ابهام، یکی از برچسب‌های تعریف‌شده را انتخاب کند. نحوه مدیریت نمونه‌های مبهم به دستور مسئله و سیاست تصمیم‌گیری وابسته است.

۲-۲ تحلیل احساسات مبتنی بر جنبه

تحلیل احساسات مبتنی بر جنبه^۱ نگرش به موجودیت یا ویژگی مشخص را بررسی می‌کند و از تحلیل کل سند جزئی‌تر است. وظیفه چهارم SemEval 2014 معیار شناخته‌شده این مسئله است [۱].

^۱ Aspect-Based Sentiment Analysis (ABSA)

۱-۲-۲ هدف و جنبه

هدف^۲ موجودیتی است که قطبیت نسبت به آن سنجیده می‌شود. هدف می‌تواند نام محصول، خدمت، سازمان، ویژگی یا هر عبارت مشخص در متن باشد. **جنبه**^۳ ویژگی یا بُعدی از هدف است که ارزیابی به آن مربوط می‌شود. برای نمونه، «پشتیبانی» می‌تواند هدف باشد و «زمان پاسخ‌گویی» جنبه مورد ارزیابی آن باشد.

هدف و جنبه همیشه یکسان نیستند. هدف ممکن است به صورت صریح در متن ظاهر شود، اما جنبه از یک رویداد یا پیامد استنباط شود. همچنین، یک هدف می‌تواند چند جنبه داشته باشد. تعیین درست این رابطه مانع انتقال احساس از یک ویژگی به ویژگی دیگر می‌شود.

مفهوم **دسته جنبه**^۴ نیز با عبارت جنبه تفاوت دارد. دسته جنبه یک رده‌بندی کلی مانند «کیفیت خدمت» است، در حالی که عبارت جنبه ممکن است واژه‌ای مشخص در متن باشد. در تحلیل هدف‌محور این پایان‌نامه، هدف ورودی معلوم است، اما شناسایی جنبه مرتبط می‌تواند بخشی از فرایند استدلال باشد.

۲-۲-۲ نظر و قطبیت

نظر^۵ محتوایی است که ارزیابی نویسنده را نسبت به هدف یا جنبه منتقل می‌کند. در حالت صریح، این محتوا معمولاً با یک عبارت ارزیابانه بیان می‌شود. در حالت ضمنی، رویداد، پیامد، توصیه یا مقایسه می‌تواند نقش نظر را داشته باشد.

برای نمونه، در جمله «پشتیبانی با نخستین تماس مشکل را حل کرد»، عبارت «مشکل را حل کرد» یک رویداد توصیفی است. با توجه به هدف «پشتیبانی» و انتظار معمول از خدمت، این رویداد می‌تواند نظر مثبت را منتقل کند. بنابراین، قطبیت فقط ویژگی یک واژه نیست؛ حاصل رابطه متن، هدف، جنبه و نظر است.

این رابطه را می‌توان با چهارگانه مفهومی (t, a, o, y) نمایش داد. در این چهارگانه، t هدف، a جنبه، o نظر و y قطبیت است. همه مؤلفه‌ها لزوماً به صورت عبارت صریح در متن حضور ندارند. در تحلیل احساسات ضمنی، جنبه یا نظر ممکن است متغیری نهفته باشد که باید از بافت استنتاج شود.

^۲Target

^۳Aspect

^۴Aspect Category

^۵Opinion

۳-۲ تحلیل احساسات ضمنی

تحلیل احساسات ضمنی به تعیین نگرشی می‌پردازد که بدون نشانگر ارزیابانه مستقیم منتقل شده است. پژوهش‌های مرتبط، نیاز به دانش عمومی، درک بافت و استنتاج چندمرحله‌ای را از ویژگی‌های اصلی این مسئله می‌دانند [۲، ۳]. در این وضعیت، سامانه باید رابطه میان رویداد توصیف‌شده و مطلوبیت آن برای هدف را کشف کند.

۱-۳-۲ تفاوت احساس صریح و ضمنی

در احساس صریح، عبارت‌هایی مانند صفت ارزیابانه، قید شدت یا فعل نگرشی مسیر نسبتاً مستقیمی به قطبیت ایجاد می‌کنند. در احساس ضمنی، قطبیت از پیامد یا معنای کاربردی یک گزاره به دست می‌آید. این تمایز به حضور یک واژه منفرد محدود نمی‌شود و باید نسبت به هدف سنجیده شود. یک جمله می‌تواند هم‌زمان احساس صریح و ضمنی داشته باشد. ممکن است نگرش به یک هدف صریح باشد، اما نگرش به هدفی دیگر از رابطه‌ای غیرمستقیم استنباط شود. همچنین، نفی، کنایه یا نقل قول می‌توانند ظاهر واژگانی را با معنای نهایی ناسازگار کنند. از این رو، صریح یا ضمنی بودن یک ویژگی وابسته به متن، هدف و بافت است.

احساس ضمنی با معنای تلویحی به معنای عام نیز یکسان نیست. هر استنباط زبانی حامل احساس نیست. تنها زمانی مسئله تحلیل احساس مطرح می‌شود که استنتاج به یک ارزیابی نسبت به هدف منتهی شود. گزارش یک واقعیت می‌تواند صرفاً اطلاع‌رسان باشد، مگر آنکه بافت یا دانش عمومی مطلوبیت آن را مشخص کند.

۲-۳-۲ چالش‌های تحلیل احساسات ضمنی

نخستین چالش، بازیابی شواهدی است که به صورت واژه احساسی ظاهر نشده‌اند. این شواهد ممکن است در پیامد یک رویداد، برآورده شدن انتظار یا رابطه علت و معلولی قرار داشته باشند. سامانه باید تشخیص دهد که کدام بخش متن برای هدف اهمیت ارزیابانه دارد.

چالش دوم، استفاده از دانش عمومی و دانش وابسته به دامنه است. یک ویژگی در دو بافت می‌تواند ارزش متفاوتی داشته باشد. برای مثال، «سبک بودن» برای یک وسیله قابل حمل ممکن است مطلوب باشد. همین ویژگی برای محصولی که استحکام معیار اصلی آن است، معنای دیگری دارد. در نتیجه، نگاشت ثابت واژه به قطبیت کافی نیست.

چالش سوم، رعایت دامنه هدف است. حضور چند موجودیت یا چند جنبه می‌تواند باعث جابه‌جایی قطبیت شود. مدل باید شواهد مربوط به هدف تعیین‌شده را از ارزیابی سایر موجودیت‌ها جدا کند. این مسئله در جمله‌های مقایسه‌ای و جمله‌های دارای چند بند اهمیت بیشتری دارد.

چالش چهارم، تفکیک احساس ضمنی از توصیف خنثی است. استنتاج بیش‌ازحد می‌تواند گزاره بی‌طرف را به ارزیابی تبدیل کند. در مقابل، اتکای بیش‌ازحد به نبود واژه احساسی باعث ازدست‌رفتن نگرش واقعی می‌شود. تصمیم درست به میزان شواهد و رابطه آن با هدف وابسته است.

ابهام، کنایه، وابستگی به فرهنگ و تفاوت انتظار کاربران نیز تحلیل را دشوار می‌کنند. افزون بر این، یک توضیح زبانی روان لزوماً نشان نمی‌دهد که استنتاج درست است. این ویژگی، ارزیابی جداگانه مسیر استدلال و برچسب نهایی را ضروری می‌کند.

۲-۴ مدل‌های زبانی بزرگ و مهندسی پرامپت

مدل زبانی توزیع احتمال دنباله‌های زبانی را بر اساس بافت برآورد می‌کند. مدل‌های زبانی بزرگ^۶ با آموزش روی حجم گسترده‌ای از متن، الگوهای نحوی و معنایی را بازنمایی می‌کنند. بخشی از دانش عمومی نیز در پارامترهای این مدل‌ها بازنمایی می‌شود. مدل زبانی می‌تواند با دریافت یک دستور متنی، پاسخ یا برچسب تولید کند.

پرامپت^۷ متنی است که وظیفه، ورودی، محدودیت‌ها و شکل پاسخ مورد انتظار را برای مدل مشخص می‌کند. مهندسی پرامپت به طراحی این اجزا برای هدایت رفتار مدل گفته می‌شود. تغییر جزئی در ترتیب دستور، تعریف برچسب‌ها یا قالب خروجی می‌تواند پاسخ را تغییر دهد. از این‌رو، پرامپت بخشی از روش آزمایشی است و باید ثبت و ثابت نگه داشته شود.

۲-۴-۱ یادگیری درون‌متنی و پرامپت صفرنمونه

یادگیری درون‌متنی^۸ به سازگاری رفتار مدل با دستور و نمونه‌های موجود در همان ورودی اشاره دارد. در این روش، وزن‌های مدل تغییر نمی‌کنند. اطلاعات لازم برای انجام وظیفه از طریق بافت ورودی ارائه می‌شود.

^۶Large Language Models (LLMs)

^۷Prompt

^۸In-Context Learning

در پرامپت چندنمونه‌ای^۹ چند زوج ورودی و خروجی به مدل نشان داده می‌شود. مدل از الگوی این نمونه‌ها برای پاسخ به ورودی جدید استفاده می‌کند. در پرامپت صفرنمونه^{۱۰} هیچ نمونه حل‌شده‌ای ارائه نمی‌شود و مدل فقط تعریف وظیفه و محدودیت‌های پاسخ را دریافت می‌کند. صفرنمونه‌بودن به معنای نبود دانش پیشین در مدل نیست. این اصطلاح فقط نحوه ارائه وظیفه در زمان استنتاج را توصیف می‌کند. همچنین، یادگیری درون‌متنی با ریزتنظیم تفاوت دارد. در ریزتنظیم، پارامترهای مدل با داده‌های وظیفه جدید به‌روزرسانی می‌شوند، اما در یادگیری درون‌متنی پارامترها ثابت می‌مانند.

۲-۴-۲ خروجی آزاد و خروجی ساختاریافته

در خروجی آزاد، مدل می‌تواند پاسخ را با هر طول و قالبی تولید کند. این حالت برای توضیح مفصل مناسب است، اما پردازش خودکار آن دشوارتر است. ممکن است برچسب در میان توضیح قرار گیرد یا با صورت نوشتاری متفاوتی ظاهر شود.

در خروجی ساختاریافته، نام فیلدها، مقادیر مجاز و ترتیب پاسخ از پیش تعیین می‌شوند. برای مثال، می‌توان از مدل خواست یک برچسب، سطح اطمینان و توضیح کوتاه را در فیلدهای جداگانه برگرداند. ساختار ثابت، اعتبارسنجی و ذخیره خروجی را آسان‌تر می‌کند.

ساختاریافته‌بودن پاسخ، درستی محتوای آن را تضمین نمی‌کند. خروجی باید از دو جنبه بررسی شود: **اعتبار نحوی**، یعنی انطباق با قالب؛ و **اعتبار معنایی**، یعنی تعلق مقادیر به دامنه‌های مجاز. یکنواخت‌سازی برچسب‌ها نیز صورت‌های نوشتاری متفاوت را به مجموعه ثابت کلاس‌ها نگاشت می‌کند.

۲-۵ استدلال زنجیره‌ای چندمرحله‌ای

زنجیره تفکر^{۱۱} دنباله‌ای از گام‌های زبانی میانی است که ورودی را به پاسخ نهایی مرتبط می‌کند. ایده اصلی این است که مسئله پیچیده به چند تصمیم کوچک‌تر شکسته شود [۴]. در پیش‌بینی مستقیم، مدل بدون نمایش گام‌های میانی برچسب را تولید می‌کند. در پیش‌بینی زنجیره‌ای، مدل پیش از برچسب، مؤلفه‌های مؤثر بر تصمیم را بیان می‌کند.

^۹Few-shot Prompting

^{۱۰}Zero-shot Prompting

^{۱۱}Chain-of-Thought (CoT)

برای تحلیل احساسات ضمنی، تجزیه مسئله می‌تواند شامل تعیین جنبه مرتبط، استنتاج نظر نهفته و تعیین جهت قطبیت باشد. چارچوب THOR این منطق را به صورت یک استدلال سه گامی برای جنبه، نظر و قطبیت صورت‌بندی می‌کند [۲]. فصل سوم این روش را در بستر پژوهش‌های پیشین بررسی می‌کند و فصل چهارم نحوه استفاده از آن را در سامانه حاضر توضیح می‌دهد.

مزیت مفهومی استدلال چندمرحله‌ای، ایجاد یک ردپای قابل بررسی است. این ردپا می‌تواند نشان دهد مدل کدام جنبه یا پیامد را مبنای تصمیم قرار داده است. همچنین، خروجی میانی امکان مقایسه مسیرهای متفاوت و تشخیص محل احتمالی خطا را فراهم می‌کند.

با این حال، زنجیره طولانی‌تر همواره به پاسخ درست‌تر منتهی نمی‌شود. اگر جنبه اشتباه انتخاب شود، استنتاج‌های بعدی ممکن است بر همان خطا بنا شوند. یک زنجیره منسجم نیز می‌تواند بر فرضی نادرست تکیه کند. بنابراین، روانی توضیح، جانشین ارزیابی برچسب نهایی نیست.

ردپای تولیدشده را نیز نباید گزارش قطعی از سازوکار درونی مدل دانست. این ردپا یک خروجی زبانی قابل مشاهده است که برای تحلیل تصمیم به کار می‌رود. ارزش آن به ارتباط با شواهد متن، سازگاری گام‌ها و انطباق نتیجه با برچسب وابسته است.

۶-۲ بازبینی استدلال و تشخیص خطا

بازبینی استدلال فرایندی است که پاسخ اولیه را پیش از تصمیم نهایی دوباره بررسی می‌کند. ورودی بازبین می‌تواند متن، هدف، برچسب اولیه و ردپای استدلال باشد. بازبین باید ناسازگاری شواهد، محدوده هدف و نتیجه را تشخیص دهد و در صورت لزوم اصلاحی پیشنهاد کند.

بازبینی آزاد معمولاً یک نقد یا پاسخ بازنویسی شده تولید می‌کند. بازبینی ساختاریافته، مسئله را به فیلدهایی مانند وضعیت خطا، نوع کلی خطا، برچسب پیشنهادی و سطح اطمینان تقسیم می‌کند. صورت دوم برای تحلیل خودکار مناسب‌تر است، زیرا می‌توان هر فیلد را جداگانه اعتبارسنجی کرد.

تشخیص خطا با اصلاح خطا یکسان نیست. ممکن است بازبین وجود ناسازگاری را درست تشخیص دهد، اما برچسب جایگزین نادرستی پیشنهاد کند. همچنین، نبود خطای اعلام‌شده به معنای صحت پاسخ اولیه نیست. به همین دلیل، خروجی بازبین باید یک منبع اطلاعاتی در فرایند تصمیم‌گیری باشد، نه حقیقت قطعی.

سطح اطمینان نیز لزوماً احتمال کالیبره‌شده نیست. اگر مدل از برچسب‌هایی مانند کم، متوسط و زیاد استفاده کند، این مقادیر فقط ارزیابی خود مدل را نشان می‌دهند. رابطه آن‌ها با احتمال تجربی

صحت باید جداگانه سنجیده شود.

بازبینی می‌تواند خطای انتقال یافته از گام‌های استدلال را آشکار کند، اما خطر بیش‌اصلاحی نیز وجود دارد. در بیش‌اصلاحی، پاسخ درست اولیه فقط به دلیل تولید یک نقد ظاهراً قانع‌کننده تغییر می‌کند. بنابراین، پذیرش اصلاح باید تابع یک سیاست مشخص باشد. ایده افزودن مرحله تأمل به تحلیل احساسات ضمنی در پژوهش‌های مرتبط نیز بررسی شده است [۳].

۷-۲ خودسازگاری و رأی اکثریت

خروجی مدل زبانی در نمونه‌گیری غیرقطعی ممکن است میان اجراها تغییر کند. خودسازگاری روشی است که یک مسیر استدلال را چند بار اجرا و پاسخ نهایی را از میان خروجی‌ها جمع می‌کند [۵]. این روش، مرحله استدلال تازه‌ای نیست؛ همان روش پیشین را تکرار می‌کند و سپس از رأی خروجی‌ها بهره می‌گیرد.

فرض شود مسیر استدلال K بار اجرا شده و برچسب اجرای i ام برابر $y^{(i)}$ است. رأی اکثریت برچسبی را انتخاب می‌کند که بیشترین تعداد تکرار را دارد:

$$\hat{y}_{\text{vote}} = \arg \max_{c \in \mathcal{Y}} \sum_{i=1}^K \mathbb{I}(y^{(i)} = c). \quad (2-2)$$

در برابری ۲-۲، تابع $\mathbb{I}$ در صورت درست بودن شرط مقدار یک و در غیر این صورت مقدار صفر دارد. اگر چند کلاس تعداد رأی یکسان داشته باشند، سیاست رفع تساوی باید پیش از ارزیابی تعیین شود. جزئیات این سیاست به پیاده‌سازی وابسته است و در فصل چهارم بیان می‌شود. نسبت رأی غالب نیز می‌تواند به عنوان نشانه توافق استفاده شود:

$$r_{\text{vote}} = \frac{1}{K} \max_{c \in \mathcal{Y}} \sum_{i=1}^K \mathbb{I}(y^{(i)} = c). \quad (2-3)$$

مقدار بزرگ‌تر r_{vote} نشان‌دهنده توافق بیشتر اجراها است، اما صحت معنایی پاسخ را تضمین نمی‌کند. چند مسیر می‌توانند خطای نظام‌مند یکسانی داشته باشند. همچنین، اگر اجراها تنوع کافی نداشته باشند،

تکرار پاسخ اطلاعات تازه‌ای ایجاد نمی‌کند.

۸-۲ کنترل‌گر و انتخاب چندمنبعی

سامانه چندمنبعی بیش از یک پیش‌بینی برای هر ورودی تولید می‌کند. این منابع می‌توانند شامل پیش‌بینی مستقیم، پیش‌بینی استدلالی و پیشنهاد حاصل از تشخیص خطا باشند. مسئله اصلی آن است که هنگام توافق یا اختلاف منابع، پاسخ نهایی چگونه ساخته شود.

کنترل‌گر^{۱۲} مؤلفه‌ای است که سیگنال‌های میانی را بررسی و یک تصمیم هدایت‌کننده تولید می‌کند. این سیگنال‌ها می‌توانند شامل توافق منابع، اعتبار خروجی، نوع کلی خطا یا سطح اطمینان باشند. کنترل‌گر ممکن است بر اساس قواعد ثابت یا الگوهای آموخته‌شده عمل کند.

انتخاب‌گر منبع^{۱۳} مشخص می‌کند کدام منبع، برچسب نهایی را تأمین کند. فرض شود $s_j(x, t)$ پیش‌بینی منبع j و $\mathbf{z}$ بردار سیگنال‌های تصمیم باشد. انتخاب‌گر با سیاست π منبع نهایی را تعیین می‌کند:

$$j^* = \pi(\mathbf{z}), \quad \hat{y}_{\text{final}} = s_{j^*}(x, t). \quad (۴-۲)$$

تفکیک کنترل‌گر و انتخاب‌گر اهمیت دارد. خروجی کنترل‌گر می‌تواند یک تصمیم میانی یا پیشنهاد اصلاح باشد، اما پیش‌بینی نهایی لزوماً همان خروجی نیست. این جداسازی منشأ پاسخ نهایی را روشن و ارزیابی هر مؤلفه را ممکن می‌کند.

در انتخاب قاعده‌محور، برای وضعیت‌هایی مانند توافق یا اطمینان زیاد، قواعد از پیش تعریف می‌شوند. در انتخاب داده‌محور، عملکرد منابع روی داده آموزش یا اعتبارسنجی برای ساخت سیاست به کار می‌رود. در هر دو حالت، رفتار پیش‌فرض برای وضعیت‌های ناشناخته باید مشخص باشد.

برچسب طلایی آزمون نباید در ساخت یا تنظیم سیاست انتخاب استفاده شود. استفاده از این اطلاعات نشت داده^{۱۴} ایجاد می‌کند و برآورد عملکرد را خوش‌بینانه می‌سازد. سیاست باید پیش از مشاهده پاسخ‌های طلایی آزمون تثبیت شود. فصل چهارم ویژگی‌ها و قواعد واقعی انتخاب‌گر این پژوهش

^{۱۲}Controller

^{۱۳}Source Selector

^{۱۴}Data Leakage

را تشریح می‌کند.

۹-۲ معیارهای ارزیابی

ارزیابی طبقه‌بندی، برچسب پیش‌بینی‌شده را با برچسب طلایی مقایسه می‌کند. فرض شود مجموعه‌آزمون شامل N نمونه و C کلاس است. برای هر کلاس c ، سه مقدار زیر تعریف می‌شوند:

• TP_c : تعداد نمونه‌های کلاس c که به‌درستی در همان کلاس پیش‌بینی شده‌اند؛

• FP_c : تعداد نمونه‌های کلاس‌های دیگر که به‌اشتباه در کلاس c قرار گرفته‌اند؛

• FN_c : تعداد نمونه‌های کلاس c که به‌اشتباه در کلاس دیگری قرار گرفته‌اند.

ماتریس درهم‌ریختگی^{۱۵} تعداد نمونه‌های هر ترکیب برچسب طلایی و برچسب پیش‌بینی‌شده را نمایش می‌دهد. قطر اصلی این ماتریس پیش‌بینی‌های درست را نشان می‌دهد. خانه‌های خارج از قطر نیز نوع جابه‌جایی میان کلاس‌ها را آشکار می‌کنند.

در متون فارسی، برای دو اصطلاح Accuracy و Precision گاهی ترجمهٔ یکسان «دقت» به‌کار می‌رود. برای جلوگیری از ابهام، در این پایان‌نامه Accuracy «دقت کلی» و Precision «صحت پیش‌بینی» نامیده می‌شود.

۱-۹-۲ دقت کلی

دقت کلی^{۱۶} نسبت تعداد پیش‌بینی‌های درست به کل نمونه‌ها است:

$$\text{Accuracy} = \frac{1}{N} \sum_{i=1}^N \mathbb{I}(\hat{y}_i = y_i). \quad (5-2)$$

در برابری ۵-۲، y_i برچسب طلایی و $\hat{y}_i$ برچسب پیش‌بینی‌شدهٔ نمونهٔ i ام است. دقت کلی تفسیر ساده‌ای دارد، اما در داده‌های نامتوازن ممکن است عملکرد ضعیف روی کلاس کم‌تعداد را پنهان کند.

^{۱۵}Confusion Matrix

^{۱۶}Accuracy

۲-۹-۲ صحت پیش‌بینی، بازخوانی و امتیاز افیک

صحت پیش‌بینی^{۱۷} برای کلاس c نشان می‌دهد چه نسبتی از نمونه‌های پیش‌بینی شده در این کلاس واقعاً متعلق به آن هستند:

$$P_c = \frac{TP_c}{TP_c + FP_c}. \quad (۶-۲)$$

بازخوانی^{۱۸} نشان می‌دهد چه نسبتی از نمونه‌های واقعی کلاس c شناسایی شده‌اند:

$$R_c = \frac{TP_c}{TP_c + FN_c}. \quad (۷-۲)$$

امتیاز افیک^{۱۹} میانگین همساز صحت پیش‌بینی و بازخوانی است:

$$F_{1,c} = \frac{2P_cR_c}{P_c + R_c}. \quad (۸-۲)$$

میانگین همساز به مقدار کوچک‌تر حساس است. از این‌رو، امتیاز افیک زمانی بزرگ می‌شود که صحت پیش‌بینی و بازخوانی هر دو مناسب باشند. اگر مخرج یکی از معیارها صفر باشد، مقدار آن مطابق قرارداد ارزیابی صفر در نظر گرفته می‌شود.

۳-۹-۲ امتیاز افیک ماکرو

امتیاز افیک ماکرو ابتدا افیک هر کلاس را جداگانه محاسبه و سپس میانگین حسابی آن‌ها را گزارش می‌کند:

^{۱۷}Precision

^{۱۸}Recall

^{۱۹}F1-score

$$\text{Macro-}F_1 = \frac{1}{C} \sum_{c=1}^C F_{1,c}. \quad (9-2)$$

در این معیار، هر کلاس مستقل از تعداد نمونه‌هایش وزن یکسان دارد. بنابراین، عملکرد ضعیف روی کلاس کم‌تعداد اثر آشکارتری بر نتیجه می‌گذارد. گزارش هم‌زمان دقت کلی و افیک ماکرو، تصویری کامل‌تر از کیفیت طبقه‌بندی سه کلاسه فراهم می‌کند.

معیارهای کمی فقط صحت برچسب نهایی را می‌سنجند. آن‌ها به تنهایی نشان نمی‌دهند که استدلال از شواهد درست استفاده کرده یا انتخاب‌گر منبع مناسبی را برگزیده است. به همین دلیل، فصل پنجم معیارهای کمی را در کنار تحلیل خطا، بررسی منابع منتخب و نمونه‌های کیفی گزارش می‌کند.

۱۰-۲ جمع‌بندی

این فصل واژگان و نمادهای لازم برای ادامهٔ پایان‌نامه را تعریف کرد. تحلیل هدف‌محور، قطبیت را حاصل رابطهٔ متن، هدف، جنبه و نظر می‌داند. در احساس ضمنی، بخشی از این رابطه آشکار نیست و باید با استفاده از بافت و دانش عمومی استنتاج شود.

مدل زبانی می‌تواند پاسخ مستقیم یا ردپای استدلال چندمرحله‌ای تولید کند. بازبینی، خودسازگاری و کنترل‌گر نیز اطلاعات مکملی برای بررسی و تجمیع پاسخ‌ها فراهم می‌کنند. با این حال، هیچ‌یک به تنهایی تضمین‌کنندهٔ صحت نیستند و باید جداگانه ارزیابی شوند. معیارهای دقت کلی و افیک ماکرو نیز مبنای مقایسهٔ کمی روش‌ها را فراهم می‌کنند. فصل بعد پژوهش‌های مرتبط را بر اساس همین مفاهیم مرور می‌کند.

فصل سوم

ادبیات تحقیق

۱-۳ مقدمه

فصل دوم مفاهیم و معیارهای لازم برای تحلیل احساسات ضمنی را تعریف کرد. در این فصل، مسیر تحول پژوهش‌ها و نسبت آن‌ها با مسئله پایان‌نامه بررسی می‌شود. هدف، تکرار تعریف‌ها نیست؛ بلکه باید روشن شود هر جریان پژوهشی کدام بخش مسئله را حل کرده و چه محدودیتی باقی گذاشته است. مرور از روش‌های عمومی تحلیل احساسات آغاز می‌شود. سپس پژوهش‌های مبتنی بر جنبه و مجموعه داده‌های احساس ضمنی بررسی می‌شوند.

در ادامه، مهندسی پرامپت، زنجیره تفکر، خودسازی، روش THOR و چارچوب تحلیل احساسات مبتنی بر تفکر SAoT^۱ تحلیل می‌شوند. پایان فصل نیز به مقایسه روش‌ها و استخراج شکاف پژوهشی اختصاص دارد.

مقایسه عددی نتایج مقاله‌ها باید با احتیاط انجام شود. پژوهش‌ها از مدل‌های پایه، نسخه داده، شیوه نمونه‌گیری و تنظیمات متفاوت استفاده کرده‌اند. بنابراین، اعداد گزارش شده در یک مقاله لزوماً با اعداد مقاله دیگر قابل مقایسه مستقیم نیستند. تمرکز این فصل بر ایده روش، نوع اطلاعات مصرف شده و سازوکار تولید تصمیم است.

۲-۳ تحول رویکردهای تحلیل احساسات

۱-۲-۳ روش‌های مبتنی بر واژگان و یادگیری ماشین

پژوهش‌های نخستین تحلیل احساسات بیشتر بر واژه‌های دارای بار عاطفی تکیه داشتند. در این روش‌ها، متن با استفاده از فرهنگ واژگان، بسامد واژه‌ها یا ویژگی‌های سطحی نمایش داده می‌شد. سپس یک قاعده یا طبقه‌بند آماری قطبیت را تعیین می‌کرد [۶، ۷].

این رویکردها ساده، سریع و تا حدی تفسیرپذیر بودند. با این حال، معنای واژه به بافت و هدف وابسته است. منفی‌سازها، تضاد، کنایه و چندمعنایی نیز رابطه ثابت میان واژه و قطبیت را مختل می‌کنند. این مشکل در تحلیل مبتنی بر جنبه جدی‌تر است، زیرا یک جمله ممکن است درباره دو هدف، دو نگرش متفاوت بیان کند.

یادگیری ماشین نظارت شده بخشی از وابستگی به قواعد دستی را کاهش داد. ویژگی‌هایی مانند چندواژه، نقش دستوری و فاصله واژه تا هدف به طبقه‌بند داده می‌شدند. با این حال، کیفیت مدل همچنان

^۱Sentiment Analysis of Thinking (SAoT)

به مهندسی ویژگی و شباهت میان داده‌های آموزش و آزمون وابسته بود. چنین بازنمایی‌هایی معمولاً رابطه دوربرد میان هدف و قرینه احساسی را ناقص ثبت می‌کردند. این محدودیت در احساس ضمنی بنیادی‌تر است. ممکن است هیچ واژه مثبت یا منفی آشکاری در جمله وجود نداشته باشد. در این حالت، افزایش اندازه فرهنگ واژگان به تنهایی مسئله را حل نمی‌کند. مدل باید پیامد رویداد، انتظار متعارف یا رابطه آن با هدف را نیز استنتاج کند.

۲-۲-۳ روش‌های مبتنی بر شبکه‌های عصبی و مدل‌های زبانی

شبکه‌های عصبی امکان یادگیری بازنمایی متن را بدون تعریف دستی همه ویژگی‌ها فراهم کردند. مدل‌های بازگشتی، پیچشی و سازوکار توجه برای تمرکز بر بخش‌های مرتبط با هدف به کار رفتند. در تحلیل مبتنی بر جنبه، نمایش هدف معمولاً همراه با بازنمایی جمله ساخته می‌شد تا قطبیت نسبت به همان هدف تعیین شود.

مدل‌های گرافی گام دیگری در این مسیر بودند. برای نمونه، شبکه توجه گراف رابطه‌ای^۲ از رابطه نحوی میان واژه‌ها برای پیوند هدف و نشانه‌های نظر استفاده می‌کند [۸]. این روش‌ها وابستگی‌های ساختاری را بهتر از ویژگی‌های سطحی نمایش می‌دهند. باین‌حال، نمودار نحوی لزوماً دانشی را که در متن بیان نشده است فراهم نمی‌کند.

مدل‌های زبانی از پیش‌آموزش دیده، دانش زبانی گسترده‌تری را وارد مسئله کردند. سازگارسازی این مدل‌ها برای داده‌های برچسب‌خورده، عملکرد تحلیل مبتنی بر جنبه را بهبود داد. پژوهش‌های بعدی نیز اهداف پیش‌آموزش ویژه‌ای برای حساس کردن بازنمایی به هدف و قطبیت طراحی کردند [۹].

مدل‌های زبانی بزرگ، افزون بر بازنمایی، قابلیت تولید پاسخ و توضیح را در اختیار می‌گذارند. مسئله دیگر فقط نگاشت یک بردار به برچسب نیست. پژوهشگر می‌تواند صورت مسئله، فضای برچسب و مراحل تحلیل را با زبان طبیعی بیان کند. این تحول، مسیر استفاده از پرامپت و استدلال زنجیره‌ای را در تحلیل احساسات گشود.

^۲Relational Graph Attention Network

۳-۳ پژوهش‌های تحلیل احساسات مبتنی بر جنبه و ضمنی

۱-۳-۳ مجموعه داده‌ها و چارچوب‌های ارزیابی

رقابت SemEval 2014 یکی از مبنای مهم تحلیل احساسات مبتنی بر جنبه است [۸]. این رقابت داده‌هایی از دامنه‌های لپ‌تاپ و رستوران ارائه کرد. وظایف آن شامل شناسایی جنبه و تعیین قطبیت نسبت به هدف بود. ساختار هدف‌محور این داده‌ها امکان بررسی جمله‌هایی را فراهم کرد که چند موضوع یا چند نگرش دارند.

با این حال، داده‌های اصلی صرفاً برای مطالعه احساسات ضمنی طراحی نشده بودند. لی و همکاران نمونه‌های صریح و ضمنی را از یکدیگر تفکیک کردند. آن‌ها همچنین پیش‌آموزش تقابلی نظارت‌شده^۳ را برای یادگیری احساسات ضمنی در تحلیل مبتنی بر جنبه پیشنهاد کردند [۹]. روش پیشنهادی آن‌ها با نام SCAPT شناخته می‌شود. نسخه تفکیک‌شده داده نیز در پژوهش‌های بعدی بازاستفاده شده است. اهمیت این تفکیک در نوع شواهد موجود است. نمونه‌های صریح معمولاً نشانه‌ای نزدیک و آشکار برای نظر دارند. در مقابل، نمونه‌های ضمنی مدل را وادار می‌کند از توصیف رویداد یا ویژگی به نگرش برسد. به همین دلیل، عملکرد مناسب روی کل داده مبتنی بر جنبه الزاماً به معنای توانایی مناسب روی زیرمجموعه ضمنی نیست.

دو دامنه لپ‌تاپ و رستوران نیز الگوهای استنتاجی متفاوتی دارند. در رستوران، سرعت خدمت، زمان انتظار و کیفیت غذا با انتظارات روزمره پیوند دارند. در لپ‌تاپ، عمر باتری، وزن، قیمت و سازگاری نرم‌افزاری اهمیت بیشتری دارند. یک روش موفق باید هم ساختار مشترک مسئله و هم تفاوت دانش دامنه‌ای را در نظر بگیرد.

۲-۳-۳ روش‌های پیش از رویکردهای مولد

روش SCAPT با ساخت جفت‌های تقابلی، مدل را به تمایز نمونه‌های دارای قطبیت متفاوت هدایت می‌کند [۹]. این جهت‌گیری از پیش‌آموزش عمومی هدفمندتر است. مدل می‌آموزد بازنمایی‌هایی بسازد که برای تشخیص احساسات نسبت به جنبه مفید باشند. مزیت این روش آن است که دانش مسئله در پارامترها و فضای بازنمایی تثبیت می‌شود.

در کنار آن، روش‌های مبتنی بر ساختار نحوی تلاش کردند مسیر میان هدف و عبارت نظر را مدل

^۳Supervised Contrastive Pre-training

کنند [۸]. مداخله علی نیز برای کاهش اتکای مدل به هم‌بستگی‌های سطحی پیشنهاد شد [۱۰]. این پژوهش نشان می‌دهد بخشی از خطاهای احساس ضمنی از میان‌برهای آماری ناشی می‌شوند. مدل ممکن است به یک واژه یا الگوی پرتکرار تکیه کند، بدون آنکه رابطه واقعی شواهد و قطبیت را دریابد. این خانواده از روش‌ها معمولاً به داده برچسب‌خورده و آموزش ویژه نیاز دارد. خروجی آن‌ها نیز اغلب یک برچسب نهایی است. در نتیجه، تشخیص اینکه مدل کدام جنبه یا پیامد ضمنی را مبنای تصمیم قرار داده دشوار می‌شود. همچنین، انتقال به دامنه‌ای تازه می‌تواند به سازگارسازی مجدد نیاز داشته باشد. ورود مدل‌های مولد، پرسش پژوهش را تغییر داد. اکنون می‌توان از مدل خواست رابطه پنهان میان هدف، ویژگی ضمنی و نگرش را به زبان طبیعی آشکار کند. این قابلیت جای روش‌های بازنمایی‌محور را به طور کامل نمی‌گیرد، اما ابزار تازه‌ای برای صورت‌بندی و بررسی فرایند استنتاج فراهم می‌کند.

۳-۳-۳ چالش‌های مشترک گزارش شده

نخستین چالش، نبود قرینه احساسی صریح است. مدل باید بفهمد یک رویداد برای هدف مطلوب، نامطلوب یا بی‌اثر است. این دآوری به دانش عمومی و انتظارات دامنه‌ای وابسته است. یک رویداد واحد نیز ممکن است برای دو هدف پیامد متفاوتی داشته باشد.

چالش دوم، نسبت‌دادن احساس به هدف درست است. جمله ممکن است چند موجودیت یا چند ویژگی داشته باشد. اگر مدل شواهد مربوط به یک هدف را به هدف دیگر منتقل کند، قطبیت نهایی نادرست می‌شود. روش‌های نحوی این مسئله را کاهش می‌دهند، اما استنتاج ضمنی همیشه با رابطه نحوی مستقیم هم‌راستا نیست.

چالش سوم، تمایز خنثی از احساس ضعیف و ضمنی است. نبود واژه ارزیابانه می‌تواند مدل را به پیش‌بینی خنثی سوق دهد. از سوی دیگر، جست‌وجوی افراطی برای معنای پنهان ممکن است جمله واقعاً خنثی را احساسی جلوه دهد. بنابراین، روش باید هم از حذف شواهد ضمنی و هم از تفسیر بیش‌ازحد جلوگیری کند.

چالش چهارم، نبود تضمین برای وفاداری توضیح است. یک مدل مولد می‌تواند پس از انتخاب برچسب، توضیحی ظاهراً قانع‌کننده بسازد. پس وجود متن استدلال به تنهایی اثبات نمی‌کند که تصمیم از همان مسیر حاصل شده است. ارزیابی برچسب، سازگاری مراحل و منشأ تصمیم باید از یکدیگر تفکیک شوند.

۴-۳ مهندسی پرامپت

مرور روش‌های پرامپت نشان می‌دهد که صورت‌بندی وظیفه، نمونه‌های راهنما و قالب پاسخ بر رفتار مدل اثر می‌گذارند [۱۱]. در تحلیل احساسات، یک پرامپت حداقلی فقط جمله، هدف و برجسب‌های مجاز را مشخص می‌کند. پرامپت غنی‌تر می‌تواند تعریف قطبیت، قید هدف‌محوری یا مراحل تحلیل را نیز اضافه کند.

پرامپت مستقیم یک خط پایه ضروری است. این روش نشان می‌دهد مدل بدون الزام به تولید توضیح تا چه اندازه مسئله را حل می‌کند. اگر روش استدلالی با خط پایه مستقیم مقایسه نشود، نمی‌توان اثر واقعی مراحل افزوده را سنجید. همچنین، هر افزایش عملکرد را نمی‌توان صرفاً به طولانی‌تر شدن پرامپت نسبت داد.

قالب خروجی نیز اهمیت دارد. پاسخ آزاد ممکن است حاوی چند برجسب، توضیح مبهم یا عبارتی خارج از فضای برجسب باشد. قالب ساختاریافته، استخراج خودکار و تشخیص پاسخ نامعتبر را آسان‌تر می‌کند. با این حال، سخت‌گیری قالب نباید به اندازه‌ای باشد که ظرفیت تحلیل مدل را محدود کند.

پرامپت صفرنمونه هزینه آماده‌سازی مثال را کاهش می‌دهد، اما به تفسیر مدل از دستور وابسته است. پرامپت چندنمونه می‌تواند مرز میان برجسب‌ها را روشن کند. با این حال، گزینش مثال‌ها ممکن است سوگیری ایجاد کند. در هر دو حالت، متن دستور، ترتیب اطلاعات و نحوه نمایش هدف باید ثابت و مستند باشند.

در احساس ضمنی، پرامپت خوب باید مدل را به شواهد مرتبط با هدف هدایت کند. دستور کلی «احساس را تشخیص بده» ممکن است نگرش کلی جمله را جایگزین نگرش هدف‌محور کند. از این رو، پژوهش‌های جدیدتر وظیفه را به پرسش‌های کوچک‌تر تقسیم کرده‌اند.

۵-۳ زنجیره تفکر در پژوهش‌های پردازش زبان طبیعی

وی و همکاران نشان دادند که افزودن نمونه‌های دارای مراحل میانی می‌تواند توانایی استدلال مدل‌های زبانی بزرگ را آشکار کند [۴]. ایده اصلی آن‌ها تولید چند گام زبان طبیعی پیش از پاسخ نهایی بود. این روش ابتدا در مسئله‌های حسابی، نمادین و استدلال عقل سلیم بررسی شد.

اهمیت این پژوهش برای تحلیل احساسات ضمنی در شباهت ساختاری وظایف است. در هر دو حالت، پاسخ نهایی از مشاهده یک نشانه صریح به دست نمی‌آید. مدل باید اطلاعات متن را با دانش

زمینه‌ای ترکیب و رابطه چندمرحله‌ای را دنبال کند. با این حال، مراحل مناسب برای هر وظیفه باید بر اساس ساختار همان مسئله طراحی شوند.

زنجیره تفکر را نباید با صحت تضمین شده یکی دانست. مراحل تولیدی می‌توانند حاوی فرض نادرست، جابه‌جایی هدف یا تناقض باشند. طولانی‌تر شدن استدلال نیز الزاماً کیفیت را افزایش نمی‌دهد. هر مرحله اضافی یک فرصت تازه برای اصلاح، اما هم‌زمان یک نقطه تازه برای خطا ایجاد می‌کند. در ادبیات تحلیل احساسات ضمنی، این ایده از یک دستور عمومی به تجزیه وظیفه تبدیل شد. به جای درخواست مبهم برای «فکر کردن مرحله به مرحله»، پژوهش‌ها پرسش‌هایی درباره جنبه، نظر و رابطه آن‌ها با قطبیت مطرح کردند. روش THOR نمونه شاخص این صورت‌بندی ساختاریافته است.

۳-۶ روش THOR برای تحلیل احساسات ضمنی

فی و همکاران روش THOR را برای استدلال درباره احساس ضمنی ارائه کردند [۲]. این روش مسئله را به سه پرسش وابسته تقسیم می‌کند. هر پاسخ، زمینه لازم برای مرحله بعد را فراهم می‌سازد. هدف آن است که مدل پیش از انتخاب قطبیت، اجزای پنهان رابطه احساسی را آشکار کند.

۳-۶-۱ تجزیه استدلال به جنبه، نظر و قطبیت

مرحله نخست، جنبه یا ویژگی ضمنی مرتبط با هدف را استنتاج می‌کند. ممکن است جمله نام هدف را داشته باشد، اما ویژگی ارزیابی شده را آشکار بیان نکند. تشخیص این ویژگی فضای تفسیر را محدود می‌کند. برای مثال، توصیف مدت کارکرد دستگاه می‌تواند به جنبه‌ای مانند باتری مربوط باشد.

مرحله دوم، نظر ضمنی نسبت به جنبه را استخراج می‌کند. این نظر لزوماً یک صفت موجود در جمله نیست. مدل باید پیامد ویژگی یا رویداد را با انتظارات رایج مقایسه کند. پاسخ مرحله دوم به متن، هدف و جنبه‌ای که در مرحله نخست ساخته شده وابسته است.

مرحله سوم، قطبیت را از رابطه میان هدف، جنبه و نظر تعیین می‌کند. این ترتیب، جهش مستقیم از جمله به برچسب را به چند تصمیم قابل مشاهده تبدیل می‌کند. در نتیجه، پژوهشگر می‌تواند محل احتمالی انحراف را دقیق‌تر بررسی کند.

وابستگی مراحل هم‌مزیت و هم‌محدودیت است. اگر جنبه درست تشخیص داده شود، مرحله نظر راهنمای متمرکزتری دریافت می‌کند. اما خطای مرحله نخست می‌تواند به مراحل بعد منتقل شود. بنابراین، صحت هر گام و سازگاری میان گام‌ها اهمیت دارد.

۳-۶-۲ خودسازگاری و بازبینی در THOR

روش THOR برای کاهش ناپایداری تولید از نمونه‌گیری چندباره و رأی‌گیری استفاده می‌کند. ایده خودسازگاری آن است که مسیرهای استدلال متنوع تولید شوند و پاسخ پرتکرار انتخاب شود [۵]. این سازوکار وابستگی نتیجه به یک اجرای تصادفی را کاهش می‌دهد.

در صورت وجود داده نظارت‌شده، مقاله THOR سازوکاری برای بازبینی استدلال نیز مطرح می‌کند. نمونه خطا دار می‌تواند همراه با مسیر اصلاح‌شده به مدل ارائه شود. این بخش نشان می‌دهد که تولید استدلال و اصلاح استدلال دو مسئله جدا هستند. باین‌حال، دسترسی به نمونه اصلاح‌شده یا نظارت مناسب همیشه ممکن نیست.

خودسازگاری نیز تضمین‌کننده پاسخ درست نیست. اگر یک سوگیری در بیشتر مسیرها تکرار شود، رأی اکثریت همان خطا را تثبیت می‌کند. افزون بر این، چند اجرای یک روش ممکن است تنوع معنایی کافی نداشته باشند. بنابراین، توافق باید به عنوان نشانه ثابت تفسیر شود، نه اثبات صحت.

۳-۶-۳ نقاط قوت و محدودیت‌های THOR

نقطه قوت اصلی THOR، انطباق مراحل استدلال با ساختار تحلیل احساسات مبتنی بر جنبه است. روش به طور مشخص می‌پرسد چه چیزی درباره هدف ارزیابی شده و نظر پنهان چیست. این طراحی از یک دستور عمومی دقیق‌تر است و ردپایی برای تحلیل خطا فراهم می‌کند.

نقطه قوت دوم، امکان تفکیک خطاها است. خطا می‌تواند از تشخیص جنبه، استنتاج نظر یا نگاشت نظر به قطبیت ناشی شود. این تفکیک برای طراحی بازیین و تحلیل کیفی مفید است. همچنین، پاسخ استدلالی می‌تواند در کنار پیش‌بینی مستقیم به عنوان منبعی مکمل نگهداری شود.

محدودیت نخست، انتشار خطا در زنجیره است. هر مرحله بعدی به پاسخ‌های پیشین وابسته است. محدودیت دوم، هزینه بیشتر اجرای چندمرحله‌ای و چندباره است. محدودیت سوم، امکان تولید توضیحی روان اما ناسازگار با شواهد جمله است.

افزون بر این، مقاله اصلی عمدتاً کیفیت یک مسیر استدلالی را ارزیابی می‌کند. اختلاف میان پاسخ مستقیم و پاسخ استدلالی خود به مسئله‌ای مستقل تبدیل می‌شود. اگر یکی از دو منبع در گروهی از نمونه‌ها بهتر باشد، انتخاب ثابت یک منبع می‌تواند بخشی از اطلاعات مفید را از بین ببرد.

۷-۳ بازبینی و خوداصلاحی در تحلیل احساسات ضمنی

بازبینی از مدل می‌خواهد پاسخ اولیه را دوباره بررسی کند. این کار می‌تواند با پرسشی کلی یا مجموعه‌ای از معیارهای مشخص انجام شود. بازبینی کلی انعطاف‌پذیر است، اما خروجی آن ممکن است مبهم باشد. بازبینی ساختاریافته، نوع ناسازگاری و پیشنهاد اصلاح را جدا می‌کند.

دوان و وانگ روش SAoT را برای تحلیل احساسات ضمنی پیشنهاد کردند [۳]. این روش ابتدا جنبه‌ها و نظرهای ضمنی را تحلیل می‌کند. سپس مدل تحلیل خود را بازنگری می‌کند و در پایان قطبیت را نتیجه می‌گیرد. در این طراحی، بازاندیشی بخشی صریح از زنجیره تصمیم است.

تفاوت مهم SAoT و THOR در جایگاه بازبینی است. THOR بر تجزیه گام‌به‌گام و خودسازگاری تأکید دارد. SAoT یک مرحله بازاندیشی را پیش از نتیجه‌گیری نهایی وارد می‌کند. هر دو روش می‌کوشند استنتاج پنهان را آشکار کنند، اما کنترل خطا را به شکل متفاوتی صورت‌بندی می‌کنند.

بازبینی می‌تواند خطای اولیه را اصلاح کند، ولی ممکن است پاسخ درست را نیز تغییر دهد. مدل بازبین همان محدودیت‌های دانش و سوگیری مدل تولیدکننده را دارد. اگر دستور بازبینی صرفاً مدل را به تغییر پاسخ ترغیب کند، اصلاح ظاهری جای بررسی شواهد را می‌گیرد. بنابراین، فعال‌سازی بازبینی و پذیرش پیشنهاد آن باید از هم جدا باشند.

پژوهش‌های یادشده نشان می‌دهند که «دوباره فکر کردن» به تنهایی معیار تصمیم نیست. خروجی بازبینی باید قابل استخراج و قابل مقایسه با منابع دیگر باشد. همچنین، لازم است موارد توافق، اختلاف و نبود شواهد کافی از یکدیگر تفکیک شوند.

۸-۳ خودسازگاری در استدلال چندمرحله‌ای

وانگ و همکاران خودسازگاری را برای بهبود استدلال زنجیره‌ای معرفی کردند [۵]. به جای انتخاب نخستین مسیر، چند مسیر با نمونه‌گیری تصادفی تولید می‌شوند. سپس پاسخ نهایی با تجمیع پاسخ‌ها تعیین می‌شود. این روش از تنوع مسیرهای ممکن برای کاهش خطای یک اجرای منفرد استفاده می‌کند. خودسازگاری یک روش استدلال مستقل نیست. کیفیت آن به پرامپت، مدل پایه و تنوع نمونه‌گیری وابسته است. اگر همه اجزاها از یک برداشت نادرست آغاز شوند، رأی‌گیری کمکی نمی‌کند. اگر پاسخ‌ها بسیار پراکنده باشند، رأی اکثریت نیز ممکن است شکننده باشد.

در تحلیل احساسات ضمنی، دو سطح تجمیع قابل تصور است. در سطح نخست، برچسب نهایی هر

اجرای کامل رأی می‌دهد. در سطح دوم، پاسخ هر مرحله استدلال جداگانه تجمیع می‌شود. سطح دوم می‌تواند خطای میانی را زودتر مهار کند، اما به نرمال‌سازی پاسخ‌های زبانی نیاز دارد. رأی‌گیری همچنین اطلاعاتی فراتر از برچسب فراهم می‌کند. نسبت آرا می‌تواند نشانه ثبات باشد و مسیرهای مخالف می‌توانند برای تحلیل اختلاف نگهداری شوند. با این حال، این نشانه نباید بدون کالیبراسیون به احتمال صحت تعبیر شود.

۹-۳ کنترل‌گرها و انتخاب منبع پیش‌بینی

بیشتر روش‌های مرور شده یک مسیر اصلی را برای تولید پاسخ نهایی تعیین می‌کنند. روش بازنمایی محور از طبقه‌بند، روش مستقیم از پاسخ کوتاه و روش زنجیره‌ای از نتیجه استدلال استفاده می‌کند. با وجود این، هیچ مسیر واحدی در همه نمونه‌ها برتری تضمین شده ندارد.

پیش‌بینی مستقیم معمولاً کوتاه‌تر و کم‌هزینه‌تر است. این مسیر گاهی از دانش درونی مدل به شکل مؤثری استفاده می‌کند، بدون آنکه در مراحل میانی منحرف شود. مسیر استدلالی در نمونه‌هایی مفید است که رابطه رویداد و قطبیت به توضیح چندمرحله‌ای نیاز دارد. بازبینی نیز ممکن است ناسازگاری مشخصی را آشکار کند.

این تفاوت، مسئله انتخاب منبع را مطرح می‌کند. کنترل‌گر باید شواهدی مانند توافق، اعتبار قالب و نشانه‌های خطا را بررسی کند. سپس یک سیاست انتخاب تعیین می‌کند کدام منبع پاسخ نهایی را تأمین کند. این نگاه با انتخاب همیشگی پاسخ طولانی‌تر یا آخرین پاسخ متفاوت است.

ادبیات THOR و SAoT اهمیت مراحل میانی و بازبینی را نشان می‌دهد [۲، ۳]. با این حال، این پژوهش‌ها انتخاب داده‌محور میان پیش‌بینی مستقیم، استدلالی و تشخیصی را به عنوان مسئله محوری صورت‌بندی نمی‌کنند. از این رو، مدیریت اختلاف منابع همچنان جای بررسی دارد.

سیاست انتخاب باید بدون استفاده از برچسب طلایی آزمون ساخته شود. در غیر این صورت، انتخاب بهترین منبع پس از مشاهده پاسخ درست به برآوردی غیرواقعی منجر می‌شود. همچنین، رفتار سیاست در وضعیت‌های دیده‌نشده باید روشن باشد. جزئیات سیاست این پایان‌نامه در فصل چهارم ارائه می‌شود.

۱۰-۳ مقایسه پژوهش‌های مرتبط

جدول ۱-۳ پژوهش‌های محوری را از نظر هدف، سازوکار و محدودیت مرتبط مقایسه می‌کند. منظور از محدودیت، نفی دستاورد پژوهش نیست. این ستون نشان می‌دهد برای ساخت یک سامانه چندمنبعی چه مسئله‌ای همچنان باقی می‌ماند.

جدول ۱-۳: مقایسه پژوهش‌های محوری مرتبط با تحلیل احساسات ضمنی.

پژوهش	ایده و سازوکار	محدودیت مرتبط
لی و همکاران؛ SCAPT [۹]	پیش‌آموزش تقابلی نظارت‌شده برای یادگیری بازنمایی حساس به احساس ضمنی	نیازمند آموزش ویژه و فاقد ردپای زبانی برای استنتاج
وانگ و همکاران [۱۰]	مداخله علی برای کاهش اتکا به هم‌بستگی‌های سطحی	تمرکز بر بازنمایی یک مدل، نه انتخاب میان منابع
وی و همکاران؛ زنجیره تفکر [۴]	تولید مراحل زبانی میانی پیش از پاسخ نهایی	مراحل عمومی و غیرتخصصی برای احساس ضمنی
وانگ و همکاران؛ خودسازگاری [۵]	نمونه‌گیری چند مسیر و انتخاب پاسخ پرتکرار	امکان تثبیت خطای مشترک با رأی اکثریت
فی و همکاران؛ THOR [۲]	استنتاج مرحله‌ای جنبه، نظر و قطبیت همراه با خودسازگاری	انتشار خطا میان مراحل و نبود انتخاب تطبیقی منبع
دوان و وانگ؛ SAoT [۳]	تحلیل جنبه و نظر، بازاندیشی و سپس استنتاج قطبیت	امکان تغییر پاسخ درست و نبود سیاست مستقل برای پذیرش اصلاح

روند کلی جدول از یادگیری بازنمایی به آشکارسازی استدلال حرکت می‌کند. SCAPT و روش علی بر بهبود مدل آموزش‌دیده تمرکز دارند. زنجیره تفکر و THOR ساخت تصمیم را به زبان طبیعی قابل مشاهده می‌کنند. خودسازگاری و SAoT نیز به ترتیب ثبات و بازیابی را وارد فرایند می‌کنند. بااین‌حال، هیچ‌یک از این مؤلفه‌ها به تنهایی همه نیازها را پوشش نمی‌دهد. بازنمایی قوی ممکن است توضیحی نداشته باشد. توضیح چندمرحله‌ای ممکن است منحرف شود. رأی اکثریت ممکن است خطای مشترک را تقویت کند و بازیابی ممکن است پاسخ درست را تغییر دهد. این ناهمگونی، انگیزه ترکیب کنترل‌شده منابع را فراهم می‌کند.

۱۱-۳ شکاف تحقیقاتی و جایگاه پژوهش حاضر

مرور ادبیات چهار شکاف مرتبط را نشان می‌دهد. نخست، بسیاری از روش‌ها یک مسیر را پاسخ نهایی و قطعی فرض می‌کنند. درحالی‌که پیش‌بینی مستقیم و استدلالی می‌توانند در نمونه‌های متفاوت برتری داشته باشند. اختلاف آن‌ها صرفاً مزاحمت نیست و می‌تواند اطلاعات تشخیصی فراهم کند.

دوم، بازبینی اغلب به شکل یک مرحله تولیدی دیگر تعریف می‌شود. تولید پیشنهاد اصلاح با پذیرش آن یکسان نیست. سامانه باید تشخیص دهد بازبینی چه نوع خطایی را گزارش کرده و تا چه اندازه قابل اتکاست. بدون این جداسازی، خوداصلاحی می‌تواند به خودتخریبی تبدیل شود.

سوم، خودسازگاری عمدتاً مسیرهای یک روش را تجمیع می‌کند. این سازوکار برای کاهش نوسان مفید است، اما تفاوت میان منابع ناهمگون را مدل نمی‌کند. پاسخ مستقیم، استدلال زنجیره‌ای و بازبینی تشخیصی ماهیت یکسانی ندارند. رأی برابر میان آن‌ها نیز لزوماً بهترین سیاست نیست.

چهارم، انتخاب پس از مشاهده برچسب آزمون فاقد تجربی است. لازم است سیاست انتخاب فقط با داده‌های مجاز ساخته شود و برای وضعیت ناشناخته رفتار مشخصی داشته باشد. همچنین، منشأ هر پاسخ نهایی باید قابل ردیابی بماند تا سهم واقعی هر منبع ارزیابی شود.

پژوهش حاضر در همین نقطه قرار می‌گیرد. هدف، ابداع یک مدل زبانی یا روش بنیادی تازه برای زنجیره تفکر نیست. این پایان‌نامه پیش‌بینی مستقیم، استدلال چندمرحله‌ای و بازبینی تشخیصی را منابع مکمل در نظر می‌گیرد. سپس مسئله اصلی را به انتخاب کنترل‌شده منبع نهایی تبدیل می‌کند.

این جایگاه با THOR و SAoT پیوند دارد، اما با آن‌ها یکسان نیست. از THOR ساختار استدلال جنبه، نظر و قطبیت الهام گرفته می‌شود. ایده بازبینی نیز برای تشخیص ناسازگاری به کار می‌رود. تفاوت اصلی در جداسازی تصمیم‌میی از منبع نهایی و ارزیابی سیاست انتخاب است.

جزئیات این سیاست در این فصل ارائه نمی‌شود. فصل چهارم معماری، مسیرهای پیش‌بینی، بازبین و سازوکار انتخاب را به طور دقیق شرح می‌دهد. فصل پنجم نیز نشان می‌دهد هر مؤلفه و هر منبع در داده‌های آزمایشی چه رفتاری داشته است.

۱۲-۳ جمع‌بندی

این فصل سیر پژوهش را از ویژگی‌های سطحی به بازنمایی‌های آموخته‌شده و سپس استدلال مولد مرور کرد. روش‌های واژه‌محور و آماری برای نشانه‌های آشکار مناسب‌تر بودند. مدل‌های عصبی، گرافی و پیش‌آموزش تقابلی رابطه هدف و متن را بهتر مدل کردند، اما همچنان به آموزش ویژه وابسته بودند.

زنجیره تفکر امکان آشکارسازی مراحل استنتاج را فراهم کرد. THOR این ایده را با تجزیه جنبه، نظر و قطبیت برای احساس ضمنی تخصصی کرد. خودسازگاری نوسان اجرا را کاهش داد و SAoT بازاندیشی را وارد زنجیره کرد. در عین حال، انتشار خطا، توضیح غیرهمسو و اصلاح نادرست همچنان باقی ماندند.

نتیجه اصلی مرور آن است که هیچ منبعی همواره برتر نیست. مسئله پژوهش حاضر فقط تولید یک

استدلال دیگر نیست؛ بلکه باید اختلاف منابع را مدیریت و منشأ پاسخ نهایی را روشن کند. فصل بعد بر پایه این شکاف، کار پیشنهادی و اجزای اجرایی سامانه را تشریح می‌کند.

فصل چهارم

کار پیشنهادی

۴-۱ مقدمه

مرور فصل پیش نشان داد که استدلال چندمرحله‌ای می‌تواند شواهد پنهان احساس را آشکار کند، اما همیشه از پیش‌بینی مستقیم دقیق‌تر نیست. مسیر استدلال ممکن است یک گزارهٔ خنثی را بیش از اندازه تفسیر کند یا خطای یک مرحلهٔ میانی را به برچسب نهایی انتقال دهد. از سوی دیگر، پیش‌بینی مستقیم نیز در نمونه‌هایی که به دانش عمومی و استنتاج پیامد نیاز دارند، بخشی از اطلاعات لازم را بازیابی نمی‌کند. بنابراین، تکیهٔ ثابت بر یکی از این دو مسیر برای تمام نمونه‌ها مناسب نیست.

کار پیشنهادی این پایان‌نامه، مسئله را به‌صورت تولید چند منبع پیش‌بینی و انتخاب کنترل‌شدهٔ منبع نهایی صورت‌بندی می‌کند. سه منبع اصلی عبارت‌اند از پیش‌بینی مستقیم، پیش‌بینی استدلالی مبتنی بر THOR و برچسب پیشنهادی بازبینی تشخیصی. ابتدا دو مسیر مستقیم و استدلالی به‌طور مستقل اجرا می‌شوند. در صورت اختلاف، یک بازبین ساختاریافته نوع خطا، برچسب پیشنهادی و سطح اطمینان را تولید می‌کند. سپس یک کنترل‌گر قاعده‌محور تصمیمی میانی می‌سازد و در مرحلهٔ نهایی، انتخاب‌گری محافظت‌شده که فقط با بخش آموزش تنظیم شده است، یکی از سه منبع را برمی‌گزیند. این فصل نحوهٔ پیاده‌سازی این ایده را شرح می‌دهد. ابتدا مسئله و نمادگذاری آن مشخص می‌شود. سپس معماری کلی، آماده‌سازی داده، تولید منابع پیش‌بینی، بازبینی خطا و دو سطح تصمیم‌گیری توضیح داده می‌شوند. در پایان نیز جزئیات نرم‌افزاری و سازوکارهای بازتولیدپذیری ارائه می‌شوند. نتایج کمی و مقایسهٔ روش‌ها به فصل پنجم واگذار شده‌اند.

۴-۲ صورت‌بندی مسئله

۴-۲-۱ ورودی، خروجی و نمادگذاری

هر نمونهٔ ورودی با زوج (s_i, t_i) نمایش داده می‌شود که در آن، s_i جملهٔ ورودی و t_i هدف مشخص‌شده در جمله است. دامنه با d_i و بخش داده با z_i نشان داده می‌شود. دامنه یکی از دو مقدار لپ‌تاپ یا رستوران و بخش داده یکی از دو مقدار آموزش یا آزمون است. برچسب طلایی نمونهٔ i نیز با y_i نمایش داده می‌شود.

فضای برچسب‌ها شامل سه قطبیت مثبت، منفی و خنثی است:

$$\mathcal{Y} = \{\text{positive, negative, neutral}\}. \quad (۱-۴)$$

هدف سامانه، تولید برچسب نهایی $\hat{y}_i^* \in \mathcal{Y}$ برای هر زوج جمله و هدف است. محدود کردن خروجی به این فضای سه‌عضوی، ارزیابی یکسان همه مسیرها را ممکن می‌کند. اگر پاسخ خام مدل با هیچ‌یک از برچسب‌های مجاز تطبیق نداشته باشد، در مرحله پردازش با مقدار داخلی unknown علامت‌گذاری می‌شود. این مقدار یک کلاس مسئله نیست و فقط برای آشکار کردن خروجی نامعتبر به کار می‌رود. تمرکز این پایان‌نامه بر احساس هدف‌محور ضمنی است. از این‌رو، سامانه نباید صرفاً قطبیت کلی جمله را تعیین کند. شواهد باید نسبت به هدف t_i تفسیر شوند و نبود واژه احساسی آشکار نیز نباید به‌طور خودکار به برچسب خنثی بینجامد. برای نمونه، توصیف انتظار طولانی ممکن است بدون صفت احساسی، نگرشی منفی نسبت به خدمت مورد نظر منتقل کند.


۲-۲-۴ اصول طراحی

معماری پیشنهادی بر چهار اصل استوار است. اصل نخست، حفظ یک خط پایه ساده و قابل تفسیر است. پیش‌بینی مستقیم مشخص می‌کند مدل بدون زنجیره میانی چه برچسبی تولید می‌کند. این مسیر هم مبنای مقایسه است و هم در موقعیت‌های نامطمئن، گزینه بازگشت محافظه‌کارانه را فراهم می‌کند. اصل دوم، جداسازی استدلال از تصمیم نهایی است. مسیر THOR شواهد را در چند گام آشکار می‌کند، اما خروجی آن به‌طور خودکار پاسخ نهایی سامانه محسوب نمی‌شود. اصل سوم، فعال‌سازی بازبینی بر پایه اختلاف است. هنگامی که پیش‌بینی مستقیم و استدلالی یکسان‌اند، تولید نقد تازه معمولاً اطلاعات ضروری ایجاد نمی‌کند. بازبینی برای نمونه‌هایی اجرا می‌شود که دو مسیر درباره آن‌ها اختلاف دارند.

اصل چهارم، جلوگیری از استفاده از برچسب طلایی آزمون در انتخاب منبع است. سیاست انتخاب فقط با نمونه‌های بخش آموزش و برچسب‌های همان بخش ساخته می‌شود. پس از تثبیت سیاست، همان قاعده بدون تغییر بر بخش آزمون اعمال می‌شود. این جداسازی مانع نشت داده و برآورد خوش‌بینانه عملکرد می‌شود.

۳-۴ نمای کلی سامانه پیشنهادی

شکل ۱-۴ جریان اطلاعات را در سامانه نشان می‌دهد. ورودی مشترک به دو شاخه مستقیم و استدلالی فرستاده می‌شود. پس از مقایسه دو برچسب، در حالت توافق برچسب مشترک حفظ می‌شود و در حالت اختلاف، بازبینی آگاه از نوع خطا فعال می‌گردد. سیگنال‌های حاصل در اختیار کنترل‌گر میانی و انتخاب‌گر نهایی قرار می‌گیرند. داده آموزش نیز از مسیری جداگانه برای تنظیم پروفایل‌های عملکردی و آستانه‌های محافظ وارد انتخاب‌گر می‌شود.



شکل ۱-۴: معماری کلی سامانه پیشنهادی.

دو سطح تصمیم‌گیری شکل، نقش یکسانی ندارند. کنترل‌گر قاعده‌محور سازگاری خروجی‌ها و قابل اعتماد بودن اصلاح را بررسی می‌کند و یک تصمیم میانی قابل ردیابی می‌سازد. انتخاب‌گر نهایی، خروجی کنترل‌گر را به عنوان منبع چهارم در نظر نمی‌گیرد؛ بلکه با استفاده از الگوی آموخته‌شده در بخش آموزش،

مستقیماً یکی از منابع مستقیم، THOR یا تشخیصی را انتخاب می‌کند. این تفکیک مانع آن می‌شود که یک تصمیم میانی با برچسب نهایی سامانه اشتباه گرفته شود.

۴-۴ آماده‌سازی داده

۱-۴-۴ منبع داده و واحد تحلیل

داده‌های مورد استفاده از نسخه برچسب‌خورده‌ای می‌آیند که در پژوهش SCAPT از داده‌های SemEval 2014 ساخته شده است [۹، ۱]. این داده دو دامنه لپ‌تاپ و رستوران را پوشش می‌دهد. واحد تحلیل، یک هدف در یک جمله است؛ بنابراین، اگر جمله چند هدف داشته باشد، هر هدف می‌تواند یک نمونه مستقل ایجاد کند. این تعریف با ماهیت هدف‌محور مسئله سازگار است.

برای هر نمونه، شناسه، دامنه، بخش داده، متن جمله، عبارت هدف، جایگاه هدف، قطبیت و نشانگر صریح یا ضمنی استخراج می‌شوند. در صورت وجود، اطلاعات واژه نظر نیز نگه‌داری می‌شود. این فیلدها امکان هم‌ترازی خروجی مسیرهای مختلف و تحلیل خطا در مراحل بعد را فراهم می‌کنند.

۲-۴-۴ استخراج و پاک‌سازی نمونه‌ها

فایل‌های مبدأ در قالب XML خوانده می‌شوند. هر مدخل هدف به یک سطر جدولی تبدیل می‌شود و فاصله ابتدا و انتهای هدف برای کنترل هم‌ترازی حفظ می‌شود. پیش از آزمایش، نبود مقدار مفقود در ستون‌های ضروری شامل شناسه، شناسه جمله مبدأ، دامنه، بخش داده، متن جمله، هدف، بازه هدف، قطبیت و نشانگر ضمنی بودن بررسی شد و در نسخه مورداستفاده هیچ ردیف ناقصی مشاهده نشد. سپس فقط قطبیت‌های مثبت، منفی و خنثی و نمونه‌های دارای نشانگر معتبر صریح یا ضمنی نگه داشته شدند. پس از تبدیل، نمونه‌هایی انتخاب می‌شوند که در برچسب‌گذاری SCAPT ضمنی شناخته شده‌اند. این فیلتر برای هر دو دامنه و هر دو بخش داده یکسان اعمال می‌شود. تقسیم اصلی آموزش و آزمون نیز بدون جابه‌جایی حفظ می‌شود. در نتیجه این فرایند، مجموعه اصلی شامل ۲۱۸۸ نمونه است که ۱۷۴۶ نمونه در بخش آموزش و ۴۴۲ نمونه در بخش آزمون قرار دارند.

پاک‌سازی داده فقط به آماده‌سازی متن محدود نیست. ستون ID به‌تنهایی شناسه‌ای یکتا برای هر ردیف نیست. برای اتصال پایدار خروجی‌ها از کلید مرکب شامل id، source_sentence_id، متن جمله، هدف، ابتدا و انتهای بازه هدف و قطبیت استفاده می‌شود. یکتایی این کلید مرکب، شمار سطرها، بخش

داده و برچسب طلایی پیش از ادغام فایل‌های پیش‌بینی کنترل می‌شوند. این کنترل از جابه‌جایی خاموش سطرها میان مسیرهای مستقیم، استدلالی و تشخیصی جلوگیری می‌کند و بدون تغییر یا بازشماره‌گذاری شناسه‌های اصلی انجام می‌شود.

۴-۵ خط پایه کلاسیک

۴-۵-۱ بازنمایی TF-IDF و رگرسیون لجستیک

در نخستین گام آزمایش‌های این پژوهش، پیش از به‌کارگیری مدل‌های زبانی، یک خط پایه کلاسیک و کم‌هزینه ساخته شد تا سطح مرجعی برای دشواری مسئله فراهم شود. این خط پایه جزئی از معماری سامانه پیشنهادی نیست و فقط یک روش مقایسه‌ای مستقل است. برای هر نمونه، عبارت هدف و متن جمله پس از یکسان‌سازی فاصله‌ها با جداکننده [SEP] به‌صورت target [SEP] sentence به هم متصل شدند.

از متن حاصل، دو دسته ویژگی استخراج شد: ویژگی‌های واژه‌ای TF-IDF شامل تک‌واژه‌ها و دوواژه‌ها، و ویژگی‌های نویسه‌ای درون‌واژه‌ای شامل دنباله‌های سه تا پنج نویسه‌ای. الحاق این دو بازنمایی به رگرسیون لجستیک با وزن‌دهی متوازن کلاس‌ها، سقف ۲۰۰۰ تکرار و بذر ثابت ۴۲ داده شد. به‌دلیل نامتوازن بودن توزیع سه کلاس، انتخاب مدل بر اساس افیک ماکرو انجام شد تا هر کلاس سهم یکسانی در معیار انتخاب داشته باشد.

ضریب منظم‌سازی از میان مقادیر $C \in \{0.1, 1, 10\}$ با اعتبارسنجی متقاطع طبقه‌بندی‌شده پنج‌لایه روی ۱۷۴۶ نمونه آموزش انتخاب شد. در هر لایه، واژگان و وزن‌های TF-IDF فقط روی چهار لایه آموزشی برآزش شدند. معیار اصلی، میانگین افیک ماکروی اعتبارسنجی بود؛ در صورت تساوی، دقت بیشتر و سپس مقدار کوچک‌تر C اولویت داشت. این فرایند مقدار $C = 1$ را انتخاب کرد. سپس خط لوله تازه‌ای با همین مقدار روی کل بخش آموزش برآزش و فقط یک‌بار روی ۴۴۲ نمونه آزمون ارزیابی شد. بنابراین، هیچ متن یا برچسبی از آزمون در ساخت ویژگی یا انتخاب ابرپارامتر دخالت نداشت.

۴-۶ تولید منابع اولیه پیش‌بینی

۴-۶-۱ پیش‌بینی مستقیم

پیش‌بینی مستقیم ساده‌ترین منبع سامانه است. پرامپت این مسیر، جمله، هدف و سه برچسب مجاز را به مدل ارائه می‌کند. از مدل خواسته می‌شود فقط یک برچسب تولید کند و هیچ توضیح اضافی ننویسد. این اجرا صفرنمونه است و وزن‌های مدل در آن تغییر نمی‌کنند. اگر P_D پرامپت مستقیم، f_θ مدل زبانی و $\mathcal{N}$ تابع نرمال‌سازی خروجی باشد، برچسب مستقیم به شکل زیر تعریف می‌شود:

$$\hat{y}_i^{(D)} = \mathcal{N}(f_\theta(P_D(s_i, t_i))) . \quad (۲-۴)$$

در اجرای اصلی، دمای تولید این مسیر صفر و سقف پاسخ کوتاه در نظر گرفته شده است. پارسر پاسخ را به حروف کوچک تبدیل و فاصله‌های اضافی را یکسان می‌کند؛ سپس سه برچسب معتبر را با رعایت مرز واژه جست‌وجو می‌کند. خروجی فقط هنگامی پذیرفته می‌شود که دقیقاً یک برچسب یکتای مثبت، منفی یا خنثی در پاسخ وجود داشته باشد. اگر هیچ برچسبی یافت نشود یا پاسخ بیش از یک برچسب متفاوت داشته باشد، مقدار داخلی unknown ثبت می‌شود تا خروجی غایب یا مبهم با یک قطبیت واقعی اشتباه نشود.

این مسیر دو کارکرد دارد. نخست، خط پایه حداقلی برای سنجش ارزش مراحل پیچیده‌تر است. دوم، در کنترل‌گر و انتخاب‌گر نقش یک منبع پایدار را دارد. کوتاهی پرامپت و تولید قطعی باعث می‌شود تفاوت آن با مسیر استدلالی به شکل روشنی قابل بررسی باشد.

۴-۶-۲ استدلال چندمرحله‌ای مبتنی بر THOR

منبع دوم از ساختار THOR الهام گرفته است [۲]. در این مسیر، مدل پیش از برچسب نهایی سه مسئله وابسته را حل می‌کند: تعیین جنبه مرتبط، استنتاج نظر و توضیح جهت قطبیت. هر مرحله، جمله، هدف و خروجی لازم از مراحل پیشین را دریافت می‌کند. به این ترتیب، برچسب فقط نتیجه یک دستور کلی نیست و مسیر رسیدن به آن نیز ثبت می‌شود.

در گام جنبه، مدل باید مشخص کند کدام ویژگی یا بُعد از هدف در جمله مطرح شده است. پاسخ

این مرحله کوتاه نگه داشته می‌شود تا از تولید توضیح‌های پراکنده جلوگیری شود. اگر جنبه مشخصی قابل استخراج نباشد، مقدار عمومی ثبت می‌شود. خروجی این مرحله با a_i نشان داده می‌شود:

$$a_i = f_{\theta}(P_A(s_i, t_i)). \quad (3-4)$$

در گام نظر، مدل رابطه رویداد توصیف‌شده با هدف و جنبه را تفسیر می‌کند. پرامپت از دانش عمومی استفاده می‌کند، اما هم‌زمان مدل را از تفسیر افراطی جمله‌های صرفاً خبری، فهرست‌گونه یا نامرتبط بازمی‌دارد. اگر شاهد کافی برای نگرش وجود نداشته باشد، باید نبود شاهد احساسی را بیان کند. این قید برای کاهش تبدیل خودکار هر رویداد به احساس طراحی شده است:

$$o_i = f_{\theta}(P_O(s_i, t_i, a_i)). \quad (4-4)$$

در گام قطبیت، مدل بررسی می‌کند که نظر استنتاج‌شده چه پیامدی برای هدف دارد و چرا این پیامد مثبت، منفی یا خنثی است. این پاسخ یک توضیح زبانی است و هنوز برچسب نهایی محسوب نمی‌شود:

$$r_i = f_{\theta}(P_R(s_i, t_i, o_i)). \quad (5-4)$$

در پرامپت این گام، جنبه به‌صورت ورودی صریح تکرار نمی‌شود؛ اثر آن به‌طور غیرمستقیم از طریق نظر o_i که در گام پیشین با توجه به جنبه استخراج شده است، وارد تصمیم می‌شود. در پایان، یک پرامپت جداگانه توضیح قطبیت را به برچسبی از فضای لا تبدیل می‌کند. جداسازی توضیح و برچسب، احتمال مخلوط‌شدن متن استدلال با خروجی قابل ارزیابی را کاهش می‌دهد:

$$\hat{y}_i^{(T)} = \mathcal{N}(f_{\theta}(P_L(s_i, t_i, r_i))). \quad (6-4)$$

۳-۶-۴ خودسازی سه‌اجرایی

تولید زنجیره استدلال با نمونه‌گیری غیرقطعی ممکن است میان اجراها تغییر کند. برای کاهش وابستگی نتیجه به یک مسیر منفرد، کل زنجیره THOR در یک سازگارسازی ویژه این پژوهش سه بار اجرا می‌شود و رأی اکثریت برچسب‌های نهایی، خروجی خودسازی سه‌اجرایی SC3^۱ را می‌سازد. مراحل استخراج جنبه، نظر و تولید استدلال قطبیت با دمای ۰/۷ اجرا می‌شوند، اما پرامپت جداگانه تبدیل استدلال به برچسب نهایی برای کاهش تغییرپذیری دمای صفر دارد. این طراحی از ایده خودسازی الهام می‌گیرد [۵] و بازتولید دقیق سازوکار مرحله‌به‌مرحله پژوهش اصلی THOR نیست. هر اجرا جنبه، نظر، استدلال قطبیت و برچسب مستقل خود را تولید می‌کند.

اگر برچسب اجرای k ام با $\hat{y}_{i,k}^{(T)}$ نمایش داده شود، برچسب تجمیع‌شده از بیشترین تعداد رأی معتبر به دست می‌آید:

$$\hat{y}_i^{(T)} = \arg \max_{c \in \mathcal{Y}} \sum_{k=1}^3 \mathbb{I}(\hat{y}_{i,k}^{(T)} = c). \quad (۷-۴)$$

پیش از رأی‌گیری، خروجی‌های نامعتبر کنار گذاشته می‌شوند. اگر هیچ اجرای معتبری وجود نداشته باشد، خروجی تجمیع‌شده unknown است. در حالت تساوی، برچسبی انتخاب می‌شود که زودتر در ترتیب اجراهای مساوی ظاهر شده باشد. مسیر نماینده ذخیره‌شده نیز نخستین اجرای دارای برچسب منتخب است. ثبت هر سه پاسخ خام و شمار رأی‌ها، امکان بازبینی رفتار این سازوکار را حفظ می‌کند.

۷-۴ بازبینی آگاه از نوع خطا

۱-۷-۴ شرط فعال‌سازی بازبینی

بازبینی زمانی فعال می‌شود که برچسب مستقیم و برچسب THOR با یکدیگر متفاوت باشند. در حالت برابری، بازبینی اجرا نمی‌شود و برای نمونه وضعیت بدون خطا ثبت می‌گردد. اگر برچسب مشترک معتبر باشد، کنترل‌گر همان برچسب را حفظ می‌کند. این شرط، هزینه و خطر بیش‌اصلاحی را محدود می‌کند؛ زیرا بازبین فقط در نقطه‌ای وارد می‌شود که شواهدی از ناسازگاری تصمیم وجود دارد.

^۱Self-Consistency with three reasoning runs; SC3

بازبین جمله، هدف، پیش‌بینی مستقیم، مسیر استدلال THOR و برچسب آن را دریافت می‌کند. وظیفه آن تولید یک توضیح آزاد نیست. خروجی باید سه جزء ساختاریافته داشته باشد: نوع خطا، برچسب پیشنهادی و سطح اطمینان. این تفکیک باعث می‌شود نقد مدل به سیگنال‌های قابل استفاده در قواعد تصمیم تبدیل شود.

۴-۷-۲ رده‌بندی خطاها

رده‌های خطا بر اساس الگوهای محتمل در تحلیل احساس ضمنی طراحی شده‌اند. جدول ۴-۱ این رده‌ها و اثر تصمیمی آن‌ها را نشان می‌دهد. شش رده قابل اصلاح‌اند و دو رده به‌تنهایی مجوز تغییر پاسخ را نمی‌دهند.

جدول ۴-۱: انواع خروجی بازبینی تشخیصی و نقش آن‌ها در تصمیم‌گیری.

شناسه	توصیف	نقش
missed_implicit_negative	نادیده گرفتن پیامد یا نگرش منفی بیان نشده به صورت صریح	قابل اصلاح
missed_implicit_positive	نادیده گرفتن پیامد یا نگرش مثبت بیان نشده به صورت صریح	قابل اصلاح
neutral_overinterpretation	نسبت دادن قطبیت به گزاره خنثی یا فاقد شاهد کافی	قابل اصلاح
target_scope_shift	انتقال نگرش از هدف واقعی جمله به موجودیت یا هدفی دیگر	قابل اصلاح
aspect_opinion_mismatch	ناسازگاری میان جنبه انتخاب شده و نظر استنتاج شده	قابل اصلاح
reasoning_label_inconsistency	ناسازگاری برچسب نهایی با استدلال قطبیت تولید شده	قابل اصلاح
no_error	تشخیص ندادن خطای قابل اتکا در مسیر بررسی شده	غیر اصلاحی
insufficient_evidence	ناکافی بودن شواهد برای داوری مطمئن میان منابع	غیر اصلاحی

رده‌های «از دست رفتن احساس مثبت یا منفی» به ناتوانی در بازیابی نگرش ضمنی مربوط‌اند. «بیش‌تفسیر خنثی» حالت معکوس را پوشش می‌دهد؛ یعنی مدل از یک واقعیت، نگرشی تولید کرده است که شواهد کافی ندارد. «تغییر دامنه هدف» و «تاهمخوانی جنبه و نظر» خطاهای هدف‌محوری را مشخص می‌کنند. «ناسازگاری استدلال و برچسب» نیز حالتی است که متن استدلال یک جهت و برچسب نهایی جهت دیگری را نشان می‌دهد.

۴-۷-۳ قالب خروجی و ترمیم پاسخ

خروجی بازبین در قالب JSON درخواست می‌شود. فیلد error_type یکی از شناسه‌های جدول، فیلد label یکی از سه قطبیت و فیلد confidence یکی از سطوح low, medium یا high است. این محدودیت،

تبدیل پاسخ زبانی به داده‌ای قابل پردازش را ساده می‌کند. پارسر ابتدا قالب کامل JSON را بررسی می‌کند و سپس الگوهای متنی نزدیک به قالب را نیز می‌پذیرد. نوع خطای ناشناخته به «شاهد ناکافی» و سطح اطمینان نامعتبر به سطح پایین نگاشت می‌شود. اگر برچسب پیشنهادی نامعتبر باشد، یک پرامپت ترمیمی فقط برای بازتولید برچسب اجرا می‌شود. اگر تلاش ترمیم نیز برچسب معتبری نسازد، مقدار unknown باقی می‌ماند و اصلاح در کنترل‌گر پذیرفته نمی‌شود.

۴-۸ کنترل‌گر تصمیم‌گیری میانی

کنترل‌گر قاعده‌محور از پیش‌بینی مستقیم، پیش‌بینی THOR و خروجی بازبین استفاده می‌کند. هدف آن ساخت تصمیمی ردیابی‌پذیر است که دلیل هر انتخاب را نیز ثبت کند. این مؤلفه به داده‌های طلایی آزمون دسترسی ندارد و قواعد آن برای تمام نمونه‌ها یکسان‌اند.

نخست، اگر دو پیش‌بینی معتبر مستقیم و استدلالی برابر باشند، همان برچسب مشترک نگه داشته می‌شود. دوم، اگر نوع خطا در مجموعه خطاهای قابل اصلاح باشد، برچسب تشخیصی معتبر باشد و اطمینان دست‌کم متوسط گزارش شود، کنترل‌گر برچسب پیشنهادی را می‌پذیرد. صرف تولید یک نقد برای تغییر پاسخ کافی نیست؛ نوع خطا و اطمینان نیز باید شرط پذیرش را برآورده کنند.

در سایر حالت‌ها، قاعده بازگشت محافظه‌کارانه اجرا می‌شود. پیکربندی اصلی در اختلاف‌ها به پیش‌بینی مستقیم بازمی‌گردد و گزینه no_error را مجوز ترجیح THOR نمی‌داند. اگر برچسب مستقیم نامعتبر باشد، کنترل‌گر به ترتیب از برچسب معتبر THOR و سپس برچسب تشخیصی استفاده می‌کند. اگر هیچ منبع معتبری وجود نداشته باشد، خروجی داخلی unknown ثبت می‌شود.

برای هر تصمیم، یک دلیل ماشینی مانند توافق منابع، پذیرش نوع خطای مشخص یا بازگشت به منبع مستقیم ذخیره می‌شود. این فیلد امکان تحلیل فراوانی قواعد و بررسی نمونه‌های تغییرکرده را فراهم می‌کند. با این حال، خروجی کنترل‌گر پیش‌بینی نهایی سامانه نیست. نقش آن جمع‌بندی قاعده‌محور سیگنال‌ها و فراهم کردن یک نقطه مقایسه برای ارزیابی فصل پنجم است.

۹-۴ انتخاب منبع محافظت شده و تنظیم شده با داده آموزش

۱-۹-۴ تعریف پروفایل انتخاب

هیچ یک از منابع برای تمام نمونه‌ها برتر نیست. برای تبدیل این مشاهده به یک سیاست عملی، نمونه‌ها بر اساس پنج سیگنال در پروفایل‌های عملکردی گسسته گروه‌بندی می‌شوند. پروفایل نمونه i به شکل زیر است:

$$p_i = \left(\hat{y}_i^{(D)}, \hat{y}_i^{(T)}, e_i, c_i, d_i \right), \quad (۸-۴)$$

که در آن، e_i نوع خطای تشخیصی، c_i سطح اطمینان بازبین و d_i دامنه است. کنار هم قرار گرفتن برچسب‌های مستقیم و THOR نوع توافق یا اختلاف دو منبع را آشکار می‌کند؛ نوع خطا و اطمینان ماهیت اختلاف را توصیف می‌کنند؛ و دامنه تفاوت الگوهای لپ‌تاپ و رستوران را در نظر می‌گیرد.

۲-۹-۴ یادگیری سیاست از بخش آموزش

مجموعه منابع نامزد با $\mathcal{S} = \{D, T, E\}$ نمایش داده می‌شود. این نمادها به ترتیب نماینده پیش‌بینی مستقیم، پیش‌بینی THOR و برچسب تشخیصی‌اند. برای هر پروفایل مشاهده شده در بخش آموزش، تعداد پاسخ‌های درست هر منبع محاسبه می‌شود. منبع دارای بیشترین شمار پاسخ درست، منبع منتخب آن پروفایل است:

$$\pi(p) = \arg \max_{s \in \mathcal{S}} \sum_{i \in \mathcal{D}_{\text{train}}} \mathbb{I}(p_i = s) \mathbb{I}(\hat{y}_i^{(s)} = y_i). \quad (۹-۴)$$

در این محاسبه، برچسب طلایی فقط برای سطرهای آموزش خوانده می‌شود. در صورت برابری امتیاز منابع، ترتیب ثابت مستقیم، THOR و تشخیصی اعمال می‌شود؛ بنابراین، منبع مستقیم نخستین اولویت تساوی است. با این حال، انتخاب صرفاً بر پایه بیشترین شمار پاسخ درست برای پروفایل‌های کم‌نمونه ناپایدار است. از این رو، سیاست اصلی پیش از واگذاری نمونه به منبعی غیر از مستقیم، چهار شرط محافظ را بررسی می‌کند.

۴-۹-۳ تنظیم آستانه‌های محافظ با اعتبارسنجی داخلی

شرط نخست حداقل پشتیبانی پروفایل، یعنی شمار نمونه‌های آموزشی همان پروفایل، است. شرط دوم حداقل حاشیه برتری منبع منتخب نسبت به منبع مستقیم، شرط سوم حاشیه آن نسبت به دومین منبع و شرط چهارم حداقل بهبود نسبی نسبت به منبع مستقیم است. اگر هر شرط برقرار نباشد یا پروفایل در آموزش دیده نشده باشد، سامانه به پیش‌بینی مستقیم بازمی‌گردد.

مقادیر این آستانه‌ها از روی آزمون انتخاب نمی‌شوند. بخش آموزش با حفظ گروه‌های دامنه و قطبیت، برای بذره‌های صفر تا ۹ به دو زیرمجموعه ساخت سیاست و اعتبارسنجی داخلی تقسیم می‌شود. برای هر پیکربندی، افیک ماکرو و سپس دقت اعتبارسنجی محاسبه می‌شوند و میانگین ده تقسیم مبنای انتخاب است. پیکربندی منتخب از پروفایل پنج‌جزئی بالا و آستانه‌های حداقل پشتیبانی 10° ، حداقل حاشیه دو پاسخ درست نسبت به منبع مستقیم، حاشیه صفر نسبت به منبع دوم و حداقل بهبود نسبی 0.05 استفاده می‌کند. پس از تثبیت این مقادیر، سیاست از کل بخش آموزش آموخته و بدون تغییر روی آزمون اعمال می‌شود.

۴-۹-۴ تولید پیش‌بینی نهایی

پس از تعیین سیاست محافظت‌شده π_g ، برچسب نهایی هر نمونه از منبع منتخب پروفایل آن خوانده می‌شود:

$$\hat{y}_i^* = \hat{y}_i^{(\pi_g(p_i))}. \quad (10-4)$$

علاوه بر برچسب نهایی، نام منبع منتخب نیز ذخیره می‌شود. این جداسازی برای تحلیل رفتار انتخاب‌گر ضروری است؛ زیرا می‌توان مشخص کرد هر پروفایل به کدام منبع واگذار شده و انتخاب منبع نسبت به پیش‌بینی مستقیم چه سود یا زیانی داشته است. خروجی کنترل‌گر در این فرمول وارد نمی‌شود و فقط به‌عنوان تصمیم میانی جداگانه باقی می‌ماند.

مزیت این سیاست نسبت به یک قاعده ثابت آن است که اعتبار نسبی منابع را در وضعیت‌های تکرارشونده از داده آموزش برآورد می‌کند و با شروط محافظ از تصمیم‌های مبتنی بر شواهد اندک می‌پرهیزد. برچسب طلایی آزمون نه در ساخت پروفایل، نه در انتخاب آستانه‌ها و نه در انتخاب منبع هر

نمونه نقش ندارد و فقط پس از تثبیت پیکربندی برای محاسبه سنج‌های نهایی خوانده می‌شود. مقایسه کمی سیاست محافظت‌شده و نسخه بدون محافظ در فصل پنجم ارائه خواهد شد.

۴-۱۰ انتخاب‌گرهای یادگرفتنی جایگزین

۴-۱۰-۱ انتخاب‌گر فراسطح مبتنی بر درخت

برای بررسی اینکه آیا یک مدل یادگرفتنی می‌تواند روابط پیچیده‌تری را بیاموزد، برای هر نمونه آموزش یک برچسب منبع ساخته می‌شود. منابع به ترتیب مستقیم، THOR و تشخیصی بررسی می‌شوند و نخستین منبعی که پاسخ درست دارد، هدف آموزشی است؛ اگر هیچ منبعی درست نباشد، منبع مستقیم به‌عنوان بازگشت ثبت می‌شود. این ترتیب در نمونه‌هایی که چند منبع هم‌زمان درست‌اند، هدف را به سمت منبع زودتر متمایل می‌کند و یکی از محدودیت‌های این صورت‌بندی است.

ویژگی‌ها شامل برچسب‌های منابع مستقیم، THOR، تشخیصی و کنترل‌گر، نوع خطا، اطمینان تشخیصی، دامنه، فعال‌شدن بازبینی، توافق زوجی منابع و ویژگی‌های رأی‌گیری SC3 مانند بیشترین رأی، حاشیه رأی، سهم رأی برتر و شمار برچسب‌های یکتا هستند. بخش آموزش با بذر ۴۲ و به‌صورت طبقه‌بندی‌شده به ۷۵ درصد برآزش و ۲۵ درصد اعتبارسنجی داخلی تقسیم می‌شود. نامزدها شامل رگرسیون لجستیک متوازن، درخت‌های تصمیم با عمق‌های سه و پنج و حداقل اندازه برگ ۱۰ یا ۲۰، و گرادیان‌بوستینگ با ۱۰۰ درخت عمق دو و نرخ یادگیری 0.05 هستند. مدل با بیشترین افیک ماکروی اعتبارسنجی انتخاب و سپس روی کل بخش آموزش بازبرآزش می‌شود؛ هیچ برچسب آزمونی در این فرایند به کار نمی‌رود.

۴-۱۰-۲ رتبه‌بند لجستیک منبع

در صورت‌بندی دوم، هر نمونه آموزش به سه ردیف نامزد، یکی برای هر منبع، گسترش می‌یابد؛ بنابراین، ۱۷۴۶ نمونه آموزش ۵۲۳۸ ردیف نامزد می‌سازند. ویژگی‌های مشترک نمونه همراه با نام منبع، برچسب پیشنهادی آن و توافق آن با سایر خروجی‌ها به رگرسیون لجستیک داده می‌شوند. هدف دودویی مشخص می‌کند آیا برچسب همان منبع با پاسخ طلایی برابر است. مدل با $C=1$ ، وزن‌دهی متوازن کلاس‌ها، سقف ۳۰۰۰ تکرار و بذر ۴۲ برآزش می‌شود و در زمان پیش‌بینی، منبع دارای بیشترین امتیاز انتخاب می‌گردد. اگر امتیاز قابل استفاده‌ای وجود نداشته باشد، مسیر مستقیم گزینه بازگشت است.

۴-۱۱ جزئیات پیاده‌سازی و بازتولیدپذیری

۴-۱۱-۱ معماری نرم‌افزار

پیاده‌سازی به مؤلفه‌های مستقل تقسیم شده است تا هر خروجی پیش از ورود به مرحله بعد قابل بررسی باشد. جدول ۴-۲ نقش فایل‌های اصلی را خلاصه می‌کند. این جداسازی امکان اجرای مجدد یک مرحله را بدون بازتولید تمام پاسخ‌های پرهزینه فراهم می‌سازد.

جدول ۴-۲: مؤلفه‌های اصلی پیاده‌سازی سامانه پیشنهادی.

فایل یا مؤلفه	وظیفه
src/data_loader.py	خواندن داده، استخراج هدف‌ها و ساخت جدول یکپارچه
experiments/ run_tfidf_logreg_ baseline.py	ساخت خط پایه کلاسیک، تنظیم C فقط روی آموزش و ذخیره پیش‌بینی‌های آزمون
src/prompt_runner.py	ارسال پرامپت، دریافت پاسخ و یکسان‌سازی رابط مدل‌ها
src/thor_pipeline.py	اجرای مراحل جنبه، نظر، قطبیت و تولید برچسب THOR
src/reflection_pipeline.py	تولید و پردازش بازبینی ساختاریافته نوع خطا
src/controller.py	اعمال قواعد کنترل‌گر و ثبت دلیل تصمیم میانی
experiments/apply_etc_policy.py	یادگیری پروفایل‌ها از بخش آموزش و انتخاب منبع نهایی
src/evaluator.py	اعتبارسنجی برچسب‌ها و محاسبه خروجی‌های ارزیابی
src/final_results.py	

پرامپت‌ها در فایل‌های متنی مستقل نگهداری می‌شوند و کد اجرا فقط مقادیر جمله، هدف و خروجی مراحل پیشین را در آن‌ها جای‌گذاری می‌کند. این روش، نسخه دستورها را از منطق برنامه جدا می‌سازد. پارامترهایی مانند دما، سقف توکن، شمار اجراها، مسیر خروجی و حالت ادامه اجرا نیز به‌صورت تنظیمات ثبت می‌شوند.

۴-۱۱-۲ مدل‌ها و رابط اجرا

اجرای اصلی با مدل Qwen3 8B و از طریق Ollama انجام شده است. مسیر تکمیلی نیز همان مراحل سامانه را با Gemini 2.5 Flash از طریق رابط سازگار با OpenAI اجرا می‌کند. یک لایه مشترک، ساخت پیام، فراخوانی مدل و استخراج متن پاسخ را برای این دو پشته یکسان می‌کند. در هیچ‌یک از این اجراها وزن مدل تغییر داده نمی‌شود و تفاوت رفتار از پرامپت، نمونه‌گیری و سیاست انتخاب ناشی است. تفاوت تنظیمات مسیر مستقیم و استدلالی آگاهانه است. پیش‌بینی مستقیم با تولید قطعی و پاسخ کوتاه اجرا می‌شود تا یک خط پایه پایدار بسازد. مسیر خودسازگاری از نمونه‌گیری با دمای غیرصفر

استفاده می‌کند تا مسیرهای متفاوتی ایجاد شوند. تمام تنظیمات همراه خروجی ذخیره می‌شوند تا مقایسه به پیکربندی مشخصی ارجاع داشته باشد.

۳-۱۱-۴ ذخیره، ادامه اجرا و اعتبارسنجی

خروجی هر مرحله در فایل CSV جداگانه ذخیره می‌شود. پاسخ خام مدل، برچسب نرمال شده، اجزای استدلال، شمار رأی‌ها، نوع خطا، اطمینان، تصمیم کنترل‌گر و منبع منتخب در ستون‌های مستقل قرار می‌گیرند. نگهداری پاسخ خام مانع از آن می‌شود که خطای پارس یا نرمال‌سازی بدون امکان بازبینی باقی بماند.

اجراهای طولانی از سرگیری می‌شوند. پیش از پردازش هر سطر، وجود خروجی معتبر آن مرحله بررسی می‌شود و فقط نمونه‌های ناقص دوباره اجرا می‌شوند. ذخیره دوره‌ای نیز اثر قطع ارتباط یا توقف فرایند را محدود می‌کند. این سازوکار به‌ویژه برای سه اجرای THOR و بازبینی اختلاف‌ها اهمیت دارد. پیش از تولید نتایج نهایی، هم‌ترازی سطرها میان فایل‌ها اعتبارسنجی می‌شود. شمار کل نمونه‌ها، شناسه‌ها، جمله، هدف، دامنه، بخش داده و برچسب طلایی باید یکسان باشند. سطر تکراری، جابه‌جایی کلید یا برچسب نهایی خارج از فضای مجاز به‌عنوان خطا گزارش می‌شود. پس از عبور از این کنترل‌ها، فایل یکپارچه نهایی مبنای محاسبه معیارها و ترسیم نمودارهای فصل پنجم قرار می‌گیرد.

۱۲-۴ جمع‌بندی

در این فصل، سامانه پیشنهادی برای تحلیل احساسات ضمنی تشریح شد. سامانه ابتدا دو دیدگاه متفاوت تولید می‌کند: پیش‌بینی مستقیم و استدلال چندمرحله‌ای THOR با خودسازگاری سه‌اجرایی. اختلاف این دو مسیر، بازبینی ساختاریافته‌ای را فعال می‌کند که نوع خطا، برچسب پیشنهادی و سطح اطمینان را گزارش می‌دهد. کنترل‌گر قاعده‌محور از این سیگنال‌ها یک تصمیم میانی قابل ردیابی می‌سازد. پیش‌بینی نهایی با سیاستی جداگانه انتخاب می‌شود. این سیاست، نمونه‌های آموزش را بر اساس برچسب‌های مستقیم و THOR، نوع خطا، اطمینان و دامنه گروه‌بندی می‌کند و برای هر پروفایل، مناسب‌ترین منبع را از میان مستقیم، THOR و تشخیصی می‌سجد. واگذاری به منبع غیرمستقیم فقط با پشتیبانی و حاشیه کافی انجام می‌شود و در سایر حالت‌ها قاعده بازگشت مستقیم فعال است. برچسب طلایی آزمون در ساخت پروفایل، تنظیم آستانه یا انتخاب منبع به کار نمی‌رود.

تفکیک مسیرهای تولید، بازبینی، کنترل میانی و انتخاب نهایی، امکان بررسی سهم هر مؤلفه را فراهم

می‌کند. فصل پنجم این مؤلفه‌ها را روی داده‌های آزمون مقایسه می‌کند، ماتریس‌های درهم‌ریختگی را تحلیل می‌کند و رفتار انتخاب‌گر را در دو اجرای Qwen3 8B و Gemini 2.5 Flash بررسی خواهد کرد.

فصل پنجم

نتایج آزمایش‌ها

۵-۱ مقدمه

فصل چهارم سامانه پیشنهادی را به صورت تولید چند منبع پیش‌بینی و انتخاب کنترل‌شده منبع نهایی صورت‌بندی کرد. در آن معماری، پیش‌بینی مستقیم، استدلال چندمرحله‌ای THOR و بازبینی تشخیصی نقش‌های متفاوتی دارند و خروجی کنترل‌گر قاعده‌محور نیز تصمیمی میانی است، نه پاسخ نهایی سامانه. پرسش اصلی این فصل آن است که این جداسازی در عمل چه اثری بر تشخیص احساسات ضمنی دارد و آیا انتخاب منبع بر پایه بخش آموزش می‌تواند از اتکای ثابت به یک مسیر بهتر عمل کند.

برای پاسخ به این پرسش، ارزیابی در دو سطح انجام می‌شود. در سطح نخست، آزمایش‌ها با یک خط پایه کلاسیک آغاز می‌شوند و سپس پیکربندی‌های مبتنی بر Qwen3 8B روی مجموعه کامل آزمون مقایسه می‌شوند. این سطح برای سنجش فاصله با یک مرجع کم‌هزینه، مقایسه روش‌ها، تحلیل کلاس‌ها، بررسی رفتار انتخاب‌گر و مطالعه خطا به کار می‌رود. سطح دوم، مقایسه‌ای تکمیلی میان Qwen3 8B و Gemini 2.5 Flash روی زیرمجموعه‌ای مشترک و متوازن است. از آنجا که این زیرمجموعه کوچک‌تر از آزمون اصلی است، نتایج آن فقط برای مقایسه دو پشته مدل در شرایط یکسان تفسیر می‌شوند و جایگزین نتیجه اصلی نیستند.

ادامه فصل ابتدا تنظیمات آزمایش و روش‌های مورد مقایسه را مشخص می‌کند. سپس نتایج کمی Qwen3 8B، ماتریس‌های درهم‌ریختگی، عملکرد دامنه‌ای و رفتار انتخاب‌گر تحلیل می‌شوند. پس از بررسی نمونه‌های کیفی و خطاهای باقی‌مانده، مقایسه تکمیلی با Gemini 2.5 Flash ارائه می‌شود. در پایان نیز محدودیت‌های ارزیابی و یافته‌های اصلی فصل جمع‌بندی می‌شوند.

۵-۲ تنظیمات آزمایش

۵-۲-۱ مجموعه داده و تقسیم ارزیابی

همان‌گونه که در فصل چهارم توضیح داده شد، داده‌های اصلی از نمونه برچسب‌خورده و ضمنی SCAPT مبتنی بر SemEval 2014 به دست آمده‌اند. هر سطر شامل یک جمله و یک هدف مشخص است و برچسب آن یکی از سه قطبیت مثبت، منفی یا خنثی است. جدول ۵-۱ توزیع نمونه‌ها را در دو دامنه لپ‌تاپ و رستوران نشان می‌دهد. تقسیم اصلی آموزش و آزمون بدون جابه‌جایی حفظ شده است.

در بخش آزمون، ۸۲ نمونه منفی، ۲۴۸ نمونه خنثی و ۱۱۲ نمونه مثبت وجود دارد. بنابراین، کلاس خنثی بیش از نیمی از آزمون را تشکیل می‌دهد. این توزیع سبب می‌شود که دقت کلی به‌تنهایی برای

جدول ۵-۱: توزیع نمونه‌های ضمنی در دو دامنه و دو بخش داده.

دامنه	آموزش	آزمون	مجموع
لپ‌تاپ	۷۱۶	۱۷۵	۸۹۱
رستوران	۱۰۳۰	۲۶۷	۱۲۹۷
مجموع	۱۷۴۶	۴۴۲	۲۱۸۸

تفسیر عملکرد کافی نباشد و رفتار هر سه کلاس نیز جداگانه بررسی شود.

۵-۲-۲ مدل‌ها و زیرساخت اجرا

اجرای اصلی با Qwen3 8B و از طریق Ollama انجام شده است. پیش‌بینی مستقیم با تولید قطعی و پاسخ کوتاه اجرا می‌شود. مسیر سازگار شده THOR کل زنجیره استدلال را سه بار اجرا می‌کند و برچسب نهایی این مسیر از رأی اکثریت به دست می‌آید. دمای مراحل استدلال ۰/۷ و دمای تبدیل استدلال به برچسب صفر است. بازبینی تشخیصی فقط در صورت اختلاف پیش‌بینی مستقیم و استدلالی فعال می‌شود.

مقایسه تکمیلی از Gemini 2.5 Flash استفاده می‌کند. برای جلوگیری از مخلوط شدن تفاوت مدل با تفاوت داده، هر دو مدل روی زیرمجموعه مشترک یکسان اجرا شده‌اند. وزن هیچ‌یک از مدل‌ها تغییر نکرده و همه روش‌ها مبتنی بر پرامپت هستند. پاسخ خام، برچسب نرمال شده، اجزای استدلال، اطلاعات تشخیصی و منبع منتخب در فایل‌های جداگانه ذخیره شده‌اند.

۵-۲-۳ پروتکل ارزیابی و جلوگیری از نشت داده

انتخاب‌گر نهایی فقط از برچسب‌های طلایی بخش آموزش برای سنجش اعتبار منابع در پروفایل‌های مشاهده شده استفاده می‌کند. پس از ساخت سیاست، همان نگاشت بدون تغییر روی بخش آزمون اعمال می‌شود. برچسب طلایی آزمون فقط پس از تولید پیش‌بینی نهایی و برای محاسبه معیارها خوانده می‌شود. انتخاب‌گرهای تنظیم شده با اعتبارسنجی نیز تقسیم‌های داخلی خود را فقط از بخش آموزش می‌سازند.

برای خط پایه کلاسیک نیز همین اصل جداسازی رعایت شده است. انتخاب مقدار C و برازش بازنمایی‌های TF-IDF فقط در اعتبارسنجی پنج‌لایه بخش آموزش انجام شد. پس از انتخاب $C = 1$ ، مدل روی کل آموزش برازش شد و بخش آزمون فقط برای گزارش نهایی معیارها به کار رفت. پیش از ارزیابی، هم‌ترازی سطرها میان خروجی‌های مستقیم، استدلالی، تشخیصی و نهایی کنترل

شده است. هر فایل ۲۱۸۸ سطر دارد، کلید مرکب نمونه در هر فایل یکتا است و تمام ۲۱۸۸ برچسب نهایی در فضای سه کلاسه معتبرند. ستون ID به‌تنهایی یکتا نیست و در این کنترل همراه شناسه جمله مبدأ، متن، هدف، بازه هدف و قطبیت به کار می‌رود. این کنترل مانع آن می‌شود که اختلاف ترتیب سطرها یا یک خروجی نامعتبر به‌صورت تغییر عملکرد تفسیر شود.

۳-۵ روش‌های مورد مقایسه و معیارهای ارزیابی

۱-۳-۵ روش‌های مورد مقایسه

برای نشان‌دادن مسیر پژوهش از یک مرجع کلاسیک تا سامانه نهایی، هشت پیکربندی در آزمایش اصلی مقایسه می‌شوند:

۱. خط پایه کلاسیک: پیش از آزمایش مدل‌های زبانی، ویژگی‌های واژه‌ای و نویسه‌ای TF-IDF به رگرسیون لجستیک متوازن داده می‌شوند و ضریب منظم‌سازی فقط با بخش آموزش انتخاب می‌شود.

۲. پیش‌بینی مستقیم Qwen3 8B: مدل فقط یکی از سه برچسب مجاز را بدون تولید زنجیره استدلال برمی‌گرداند.

۳. THOR ساده‌شده: مسیر چندمرحله‌ای نخستین پیاده‌سازی است که یک زنجیره استدلال برای هر نمونه تولید می‌کند.

۴. THOR SC3 سازگار شده سه‌اجرایی: سازگارسازی ویژه این پژوهش است که کل مسیر را سه بار اجرا و برچسب‌های نهایی را با رأی اکثریت جمع می‌کند.

۵. بازبینی ساده: خروجی مسیر استدلالی بدون رده‌بندی ساختاریافته نوع خطا بازبینی می‌شود.

۶. کنترل‌گر استاندارد: بازبینی آگاه از نوع خطا^۱ روی THOR ساده‌شده اعمال و تصمیم‌میان قاعده‌محور تولید می‌شود. اختصار ETC در شکل‌ها به همین کنترل‌گر آگاه از نوع خطا اشاره دارد.

۷. کنترل‌گر روی THOR SC3: همان قواعد با خروجی استدلالی سه‌اجرایی به کار می‌روند.

^۱Error-Type-Aware Reflection; ETC

۸. سامانه نهایی انتخاب منبع: سیاست محافظت‌شده و تنظیم‌شده با اعتبارسنجی‌های داخلی آموزش، یکی از منابع مستقیم، استدلالی یا تشخیصی را برای هر پروفایل انتخاب می‌کند و در وضعیت‌های کم‌پشتیبانی یا کم‌حاشیه به مسیر مستقیم بازمی‌گردد.

دو پیکربندی ششم و هفتم خروجی کنترل‌گر میانی را ارزیابی می‌کنند. بنابراین، نباید آن‌ها را با پیکربندی هشتم که پیش‌بینی نهایی سامانه است یکسان دانست. این تفکیک نشان می‌دهد آیا اجرای قواعد ثابت به‌تنهایی کافی است یا انتخاب منبع متناسب با وضعیت نمونه ارزش افزوده ایجاد می‌کند.

۲-۳-۵ معیارهای ارزیابی

تعریف دقت کلی، صحت پیش‌بینی، بازخوانی، امتیاز افیک هر کلاس و امتیاز افیک ماکرو در روابط ۲-۵ تا ۲-۹ فصل دوم ارائه شد. در این فصل، دقت کلی برای سنجش نسبت کل پاسخ‌های درست و امتیاز افیک ماکرو برای وزن‌دادن یکسان به سه کلاس گزارش می‌شود. نزدیک‌بودن تغییر این دو معیار نشان می‌دهد که بهبود فقط حاصل غلبه کلاس خنثی نیست؛ باین‌حال، برای روشن‌شدن محل تغییرها، ماتریس درهم‌ریختگی و افیک هر کلاس نیز بررسی می‌شوند.

۴-۵ نتایج روش‌های اصلی روی آزمون کامل

۱-۴-۵ مقایسه کلی روش‌ها

جدول ۲-۵ نتایج هشت روش را روی ۴۴۲ نمونه آزمون گزارش می‌کند. ترتیب روش‌ها مسیر آزمایش را از خط پایه کلاسیک، پیش‌بینی مستقیم مدل زبانی، روش‌های استدلالی و بازبینی تا انتخاب منبع نهایی دنبال می‌کند. نسخه THOR سه‌اجرایی نیز بلافاصله پس از نسخه ساده‌شده قرار گرفته است. جدول ۲-۵: نتایج روش‌های اصلی، از خط پایه کلاسیک تا سامانه نهایی، روی مجموعه کامل آزمون.

افیک ماکرو	دقت کلی	روش
۰/۵۱۴۰۸۲	۰/۵۴۷۵۱۱	خط پایه کلاسیک TF-IDF + Logistic Regression
۰/۶۷۴۰۷۵	۰/۶۷۸۷۳۳	پیش‌بینی مستقیم Qwen3 8B
۰/۵۷۸۴۳۷	۰/۵۹۹۵۴۸	THOR ساده‌شده
۰/۶۰۰۶۹۰	۰/۵۹۰۴۹۸	THOR SC3 سازگار شده سه‌اجرایی
۰/۶۰۶۷۳۲	۰/۶۱۵۳۸۵	بازبینی ساده
۰/۶۵۹۴۳۰	۰/۶۶۰۶۳۳	کنترل‌گر استاندارد
۰/۶۶۲۱۰۸	۰/۶۶۰۶۳۳	کنترل‌گر روی THOR SC3
۰/۷۱۹۱۱۹	۰/۷۲۳۹۸۲	سامانه نهایی انتخاب منبع


خط پایه کلاسیک در نخستین آزمایش به دقت 0.547511 و افیک ماکرو 0.514082 رسید. افیک کلاس منفی در این روش 0.374332 بود و نشان داد که تشخیص احساس ضمنی منفی دشوارترین بخش این بازنمایی کلاسیک است. پیش‌بینی مستقیم Qwen3 8B دقت را حدود $13/12$ واحد درصد و افیک ماکرو را حدود 0.16 واحد درصد نسبت به این مرجع افزایش داد. این مقایسه نشان می‌دهد که حتی پیش از افزودن مراحل استدلال و انتخاب منبع، مدل زبانی اطلاعات معنایی بیشتری از بازنمایی واژگانی و نویسه‌ای استخراج می‌کند.

سامانه نهایی نسبت به خط پایه کلاسیک حدود $17/65$ واحد درصد در دقت و $20/50$ واحد درصد در افیک ماکرو برتری دارد. با این حال، این فاصله نباید فقط به معماری استدلالی پیشنهادی نسبت داده شود؛ زیرا خط پایه کلاسیک و روش‌های مبتنی بر مدل زبانی از خانواده‌ها و ظرفیت‌های متفاوتی استفاده می‌کنند. نقش این آزمایش فراهم کردن یک مرجع کلاسیک بازتولیدپذیر است و این روش جایگزین مقایسه با رمزگذارهای از پیش آموزش دیده و تنظیم دقیق شده نیست.

نتایج نشان می‌دهند که افزودن استدلال چندمرحله‌ای به تنهایی بهبود ایجاد نکرده است. دقت هر دو نسخه THOR از پیش‌بینی مستقیم کمتر است. خودسازگاری سه‌جایی نیز اگرچه افیک ماکرو را نسبت به THOR ساده شده از 0.578437 به 0.60690 رسانده، دقت کلی را اندکی کاهش داده است. این تفاوت نشان می‌دهد که رأی‌گیری، توزیع خطا میان کلاس‌ها را تغییر داده است، اما ضعف مسیر استدلالی را به‌طور کامل برطرف نمی‌کند.

بازبینی ساده نسبت به هر دو مسیر استدلالی بهتر عمل کرده، ولی همچنان از خط پایه مستقیم پایین‌تر است. کنترل‌گرهای قاعده‌محور بخش مهمی از این فاصله را جبران می‌کنند، اما هیچ‌یک از خط پایه مستقیم عبور نمی‌کنند. در مقابل، سامانه نهایی محافظت شده به دقت 0.723982 و افیک ماکرو 0.719119 رسیده است. نسبت به پیش‌بینی مستقیم، افزایش دقت حدود $4/52$ واحد درصد و افزایش افیک ماکرو حدود $4/50$ واحد درصد است.

شکل ۵-۱ همین مقایسه هشت‌روش را از خط پایه کلاسیک تا سامانه نهایی نمایش می‌دهد. با این حال، نزدیک بودن دقت و افیک ماکرو به تنهایی برای داوری درباره همه کلاس‌ها کافی نیست؛ جدول ۵-۳ نشان می‌دهد که امتیاز افیک هر سه کلاس منفی، خنثی و مثبت نسبت به پیش‌بینی مستقیم افزایش یافته است.



شکل ۵-۱: مقایسه دقت کلی و امتیاز افیک ماکرو هشت روش اصلی روی ۴۴۲ نمونه آزمون.

۲-۴-۵ تحلیل ماتریس‌های درهم‌ریختگی

برای مشخص شدن منشأ بهبود، شکل ۲-۵ ماتریس‌های درهم‌ریختگی پیش‌بینی مستقیم و سامانه نهایی را مقایسه می‌کند. سطرها برچسب طلایی و ستون‌ها برچسب پیش‌بینی شده‌اند و درصدهای هر خانه نسبت به مجموع همان سطر محاسبه شده‌اند.

در کلاس منفی، شمار پاسخ‌های درست از ۶۶ به ۷۰ رسیده و بازخوانی از ۸۰/۵ درصد به ۸۵/۴ درصد افزایش یافته است. هم‌زمان، خطای منفی به خنثی از ۱۳ به ۹ نمونه کاهش یافته است. در کلاس خنثی، شمار پاسخ‌های درست از ۱۴۶ به ۱۶۰ رسیده و بازخوانی از ۵۸/۹ درصد به ۶۴/۵ درصد رسیده است. کاهش خنثی‌های اشتباه پیش‌بینی شده به‌عنوان منفی، از ۵۹ به ۵۱ نمونه، مهم‌ترین تغییر این کلاس است.

در کلاس مثبت نیز شمار پاسخ‌های درست از ۸۸ به ۹۰ افزایش یافته است. خطای مثبت به منفی از ۶ به ۳ نمونه کاهش یافته، هرچند خطای مثبت به خنثی از ۱۸ به ۱۹ رسیده است. بنابراین، بهبود نهایی حاصل حذف یکنواخت همه خطاها نیست؛ انتخاب‌گر بخشی از خطاها را اصلاح کرده و هم‌زمان تعداد محدودی خطای تازه ایجاد کرده است.

جدول ۳-۵ نشان می‌دهد که افیک هر سه کلاس نسبت به پیش‌بینی مستقیم افزایش یافته است.

Qwen3 8B مستقیم پیش‌بینی				نهایی سامانه					
واقعی برچسب	منفی	خنثی	مثبت	واقعی برچسب	منفی	خنثی	مثبت		
	منفی	۶۶ ۵٪.۸۰	۱۳ ۹٪.۱۵		۳ ۷٪.۳	منفی	۷۰ ۴٪.۸۵	۹ ۰٪.۱۱	۳ ۷٪.۳
	خنثی	۵۹ ۸٪.۲۳	۱۴۶ ۹٪.۵۸		۴۳ ۳٪.۱۷	خنثی	۵۱ ۶٪.۲۰	۱۶۰ ۵٪.۶۴	۳۷ ۹٪.۱۴
	مثبت	۶ ۴٪.۵	۱۸ ۱٪.۱۶		۸۸ ۶٪.۷۸	مثبت	۳ ۷٪.۲	۱۹ ۰٪.۱۷	۹۰ ۴٪.۸۰

پیش‌بینی شده برچسب

پیش‌بینی شده برچسب

می‌دهد نشان را سطر درصد و شمار خانه هر سطر؛ نرمال‌سازی

شکل ۵-۲: ماتریس‌های درهم‌ریختگی پیش‌بینی مستقیم و سامانه نهایی Qwen3 8B روی آزمون کامل. بیشترین افزایش مربوط به کلاس منفی است و کلاس خنثی نیز با وجود فراوانی بیشتر، بهبود قابل توجهی دارد.

جدول ۵-۳: امتیاز افیک کلاس‌ها برای پیش‌بینی مستقیم و سامانه نهایی Qwen3 8B.

کلاس	پیش‌بینی مستقیم	سامانه نهایی
منفی	۰/۶۱۹۷۱۸	۰/۶۷۹۶۱۲
خنثی	۰/۶۸۷۰۵۹	۰/۷۳۳۹۴۵
مثبت	۰/۷۱۵۴۴۷	۰/۷۴۳۸۰۲

۳-۴-۵ تحلیل عملکرد بر اساس دامنه

جدول ۵-۴ نتایج دو دامنه را جدا می‌کند. سامانه نهایی در هر دو دامنه از پیش‌بینی مستقیم بهتر است؛ بنابراین، افزایش سنجۀ کل فقط از یک دامنه ناشی نشده است.

جدول ۵-۴: عملکرد پیش‌بینی مستقیم و سامانه نهایی به تفکیک دامنه در بخش آزمون.

دامنه	تعداد	مستقیم		نهایی	
		دقت	افیک ماکرو	دقت	افیک ماکرو
لپ‌تاپ	۱۷۵	۰/۶۸۵۷۱۴	۰/۶۷۳۶۴۷	۰/۷۲۰۰۰۰	۰/۷۰۳۵۹۶
رستوران	۲۶۷	۰/۶۷۴۱۵۷	۰/۶۷۱۶۵۰	۰/۷۲۶۵۹۲	۰/۷۲۵۸۰۶

در دامنه لپ‌تاپ، افزایش افیک ماکرو حدود ۳٪ واحد درصد است. این افزایش در دامنه رستوران به حدود ۵/۴۲ واحد درصد می‌رسد. متن‌های رستوران در بسیاری از موارد پیامدهایی مانند انتظار،

قیمت، کیفیت خدمت و رفتار کارکنان را توصیف می‌کنند؛ از این‌رو، مسیر استدلالی در بخشی از این نمونه‌ها اطلاعات مکمل بیشتری نسبت به پیش‌بینی مستقیم فراهم کرده است. با این حال، این مشاهده یک رابطه علی را اثبات نمی‌کند و فقط با الگوی خطاهای همین آزمون سازگار است.

۵-۵ تحلیل انتخاب‌گر و مؤلفه‌های سامانه

۱-۵-۵ توزیع منابع و سود یا زیان نسبت به مسیر مستقیم

انتخاب منبع به معنای تغییر قطعی وضعیت صحت نیست؛ ممکن است دو منبع برچسب‌های متفاوت اما هر دو نادرست تولید کرده باشند. جدول ۵-۵ نشان می‌دهد که سیاست محافظت‌شده در ۴۰۹ نمونه آزمون منبع مستقیم و فقط در ۳۳ نمونه منبع THOR را انتخاب کرده است. برچسب تشخیصی در هیچ نمونه آزمون منبع نهایی نبوده است. بنابراین، بهبود آزمون از واگذاری محدود به پروفایل‌هایی حاصل شده که پشتیبانی و حاشیه آموزشی کافی داشته‌اند، نه از اتکای گسترده به مسیر استدلالی یا برچسب بازبین.

جدول ۵-۵: توزیع منبع منتخب در ۴۴۲ نمونه آزمون.

منبع منتخب	تعداد نمونه
پیش‌بینی مستقیم	۴۰۹
THOR	۳۳
برچسب تشخیصی	صفر

مقایسه مستقیم برچسب نهایی با خط پایه نشان می‌دهد که دو روش در ۴۱۰ نمونه نتیجه صحت یکسان داشته‌اند: هر دو در ۲۹۴ نمونه درست و در ۱۱۶ نمونه نادرست بوده‌اند. سامانه نهایی ۲۶ خطای پیش‌بینی مستقیم را اصلاح کرده و در ۶ نمونه، پاسخ درست مستقیم را به پاسخ نادرست تبدیل کرده است. حاصل خالص این جابه‌جایی، ۲۰ پاسخ درست بیشتر و افزایش شمار پاسخ‌های صحیح از ۳۰۰ به ۳۲۰ است.

هر ۳۳ نمونه واگذارشده به THOR برچسبی متفاوت از مسیر مستقیم داشته‌اند و در ۳۲ نمونه وضعیت صحت نیز تغییر کرده است؛ یک نمونه میان دو پاسخ نادرست جابه‌جا شده است. این تمرکز نشان می‌دهد شروط محافظ بیشتر انتخاب‌های بی‌اثر نسخه بدون محافظ را حذف کرده‌اند، درحالی‌که همان ۲۶ اصلاح و ۶ تضعیف اصلی حفظ شده‌اند.

۵-۲ مقایسهٔ تصمیم‌میان، انتخاب‌گرهای فراسطح و کران‌اوراکل

جدول ۵-۶ سامانهٔ نهایی را با چند نقطهٔ مقایسه نشان می‌دهد. کنترل‌گر قاعده‌محور همان خروجی میانی فصل چهارم است. انتخاب‌گر فراسطح با یک درخت تصمیم تنظیم‌شده روی اعتبارسنجی و رتبه‌بند لجستیک نیز تلاش می‌کند منبع مناسب را با ویژگی‌های بیشتری پیش‌بینی کنند. اوراکل از برچسب طلایی برای انتخاب بهترین منبع هر نمونه استفاده می‌کند و فقط کران بالای تحلیلی است؛ این روش در کاربرد واقعی قابل استفاده نیست.

جدول ۵-۶: مقایسهٔ سیاست‌های انتخاب منبع روی ۴۴۲ نمونهٔ آزمون Qwen3 8B.

روش	دقت کلی	افیک ماکرو
پیش‌بینی مستقیم	۰/۶۷۸۷۳۳	۰/۶۷۴۰۷۵
کنترل‌گر قاعده‌محور	۰/۶۶۰۶۳۳	۰/۶۶۲۱۰۸
رتبه‌بند لجستیک منبع	۰/۷۱۲۶۷۰	۰/۶۹۷۹۱۳
انتخاب‌گر فراسطح مبتنی بر درخت	۰/۷۱۹۴۵۷	۰/۷۱۳۴۵۲
انتخاب پروفایلی بدون محافظ (حذف مؤلفه)	۰/۷۲۳۹۸۲	۰/۷۱۹۲۰۴
سامانهٔ نهایی محافظت‌شده	۰/۷۲۳۹۸۲	۰/۷۱۹۱۱۹
اوراکل انتخاب منبع	۰/۷۸۵۰۶۸	۰/۷۷۹۵۱۱

کنترل‌گر قاعده‌محور از خط پایهٔ مستقیم پایین‌تر است؛ پس قواعد ثابت پذیرش اصلاح برای ساخت پاسخ نهایی کافی نیستند. انتخاب‌گرهای یادگرفتنی از خط پایه عبور کرده‌اند. نسخهٔ پروفایلی بدون محافظ افیک ماکرویی فقط ۰/۰۰۰۰۸۵ بیشتر از روش اصلی دارد، اما ۱۴۲ نمونه را به THOR واگذار می‌کند؛ در مقابل، آستانه‌های روش محافظت‌شده فقط با اعتبارسنجی آموزش انتخاب شده‌اند و شمار واگذاری را به ۳۳ کاهش می‌دهند. بنابراین، روش محافظت‌شده با عملکرد عملاً برابر و تصمیم‌های محافظه‌کارانه‌تر به‌عنوان سامانهٔ اصلی در نظر گرفته می‌شود و نسخهٔ بدون محافظ نقش مطالعهٔ حذف مؤلفه را دارد. فاصلهٔ افیک ماکرو سامانهٔ نهایی با اوراکل حدود ۶/۰۴ واحد درصد است.

۵-۳ اعتبارسنجی زنجیرهٔ نهایی

اعتبارسنجی فقط به شمار سطرها محدود نشده است. کلیدهای نمونه در چهار خروجی مستقیم، THOR، کنترل‌گر و انتخاب‌گر بررسی شده‌اند. هیچ کلید تکراری وجود ندارد، ۲۱۸۸ سطر مستقیم و کنترل‌گر با یکدیگر هم‌ترازند، ۲۱۸۸ سطر THOR با کنترل‌گر تطبیق دارند و تمام سطرهای کنترل‌گر و انتخاب‌گر نیز هم‌ترازند. ستون‌های تشخیصی در فایل نهایی حاضرند و هیچ برچسبی خارج از مثبت، منفی و خنثی مشاهده نشده است. در نتیجه، سنج‌های گزارش‌شده بر یک زنجیرهٔ کامل و قابل ردیابی محاسبه شده‌اند.

۵-۶ تحلیل کیفی و خطا

۵-۶-۱ نمونه‌های اصلاح‌شده

در بخش آزمون، ۲۶ نمونه وجود دارد که پیش‌بینی مستقیم در آن‌ها نادرست و سامانه نهایی درست است. نمونه زیر به دامنه رستوران و هدف price مربوط است:

For the price you pay for the food here, you'd expect it to be at least on par with other Japanese restaurants.

برچسب طلایی این نمونه منفی است. مسیر مستقیم آن را خنثی پیش‌بینی کرده، اما THOR رابطه میان قیمت پرداخت‌شده و برآورده‌نشدن انتظار را منفی استنتاج کرده است. انتخاب‌گر منبع THOR را برگزیده و خطای «از دست‌رفتن احساس منفی ضمنی» اصلاح شده است. این نمونه با تعریف فصل دوم سازگار است: واژه احساسی صریح برای هدف وجود ندارد و قطبیت از مقایسه هزینه و انتظار به دست می‌آید.

نمونه اصلاح‌شده دیگر به هدف OS X Mountain Lion مربوط است:

Got this Mac Mini with OS X Mountain Lion for my wife.

پیش‌بینی مستقیم برچسب مثبت تولید کرده است، در حالی که جمله فقط مالکیت و دریافت دستگاه را بیان می‌کند و نگرش مشخصی نسبت به سیستم‌عامل ندارد. مسیر استدلالی نبود شاهد احساسی را تشخیص داده و برچسب خنثی تولید کرده است. انتخاب همین منبع از بیش‌تفسیر یک گزاره خبری جلوگیری کرده است.

۵-۶-۲ نمونه‌های تضعیف‌شده

در مقابل، شش نمونه وجود دارد که پیش‌بینی مستقیم درست بوده و سامانه نهایی آن‌ها را نادرست کرده است. نمونه زیر برای هدف food برچسب منفی دارد:

I have never in my life sent back food before, but I simply had to, and the waiter argued with me over this.

مسیر مستقیم منفی را به‌درستی تشخیص داده است، اما مسیر THOR عبارت بازگرداندن غذا را به‌عنوان شاهد ناکافی تفسیر کرده و خنثی داده است. انتخاب‌گر نیز به دلیل شباهت پروفایل این نمونه با مواردی که THOR در آموزش بهتر بوده، منبع استدلالی را انتخاب کرده است. در اینجا خطای مرحله استدلال به انتخاب نهایی منتقل شده است.

نمونه بعدی اهمیت محدوده هدف را نشان می‌دهد:

Unfortunately, we chose this spot for lunch as we had done a lot of walking and ended up at the South St Seaport.

هدف نمونه lunch و برچسب طلایی آن خنثی است. مسیر مستقیم خنثی را حفظ کرده، اما مسیر استدلالی نشانه منفی ابتدای جمله و وضعیت کلی انتخاب مکان را به هدف ناهار منتقل کرده است. این خطا نمونه‌ای از جابه‌جایی دامنه هدف است: وجود احساس منفی در جمله برای منفی‌بودن هر هدف کافی نیست.

۵-۶-۳ الگوهای خطای باقی‌مانده

نمونه‌های کیفی سه الگوی اصلی را آشکار می‌کنند. الگوی نخست، از دست‌رفتن پیامد ضمنی است؛ یعنی مدل رابطه میان انتظار، رویداد و ارزیابی را بازیابی نمی‌کند. الگوی دوم، بیش‌تفسیر گزاره خنثی است؛ در این حالت مدل از رویدادی که فقط اطلاعات توصیفی دارد، قطبیت می‌سازد. الگوی سوم، انتقال نگرش میان هدف‌های مختلف یک جمله است. مسیر چندمرحله‌ای می‌تواند الگوی نخست را اصلاح کند، اما اگر جنبه یا هدف را نادرست تثبیت کند، دو الگوی بعدی را تشدید می‌کند.

وجود ۱۱۶ نمونه‌ای که هم پیش‌بینی مستقیم و هم سامانه نهایی در آن‌ها نادرست‌اند نشان می‌دهد که مسئله فقط انتخاب میان منابع فعلی نیست. بخشی از خطاها میان منابع مشترک‌اند و برای اصلاح آن‌ها به استدلال هدف‌محور دقیق‌تر، دانش زمینه‌ای مناسب‌تر یا منابع پیش‌بینی متنوع‌تر نیاز است. در عین حال، فاصله او را کل با سامانه نهایی نشان می‌دهد که بهبود خود انتخاب‌گر نیز هنوز ظرفیت قابل توجهی دارد.

۷-۵ مقایسه تکمیلی با Gemini 2.5 Flash

۱-۷-۵ ساخت زیرمجموعه مشترک

برای مقایسه دو مدل، زیرمجموعه‌ای متوازن با ۲۴۰ نمونه ساخته شده است. این زیرمجموعه ۱۵۰ نمونه آموزش و ۹۰ نمونه آزمون دارد و بخش آزمون شامل ۳۰ نمونه از هر کلاس است. تمام مسیرهای مستقیم، THOR سه‌جراحی و انتخاب منبع برای هر دو مدل روی همین شناسه‌ها اجرا شده‌اند. بنابراین، اختلاف نتایج این بخش از تفاوت جمعیت آزمون ناشی نمی‌شود.

با این حال، اندازه ۹۰ نمونه برای نتیجه‌گیری کلی درباره برتری یک مدل کافی نیست. هدف این آزمایش بررسی رفتار دو پشته در یک چارچوب و مجموعه یکسان است. نتیجه اصلی پایان‌نامه همچنان همان ارزیابی Qwen3 8B روی ۴۴۲ نمونه آزمون کامل است.


۲-۷-۵ مقایسه سنجه‌های دو مدل

شکل ۳-۵ امتیاز افیک ماکرو دو مدل را در سه پیکربندی مشترک نشان می‌دهد. پیکربندی انتخاب منبع این بخش با تقسیم‌های اعتبارسنجی ساخته‌شده از بخش آموزش تنظیم شده است و هیچ برچسب طلایی آزمون در انتخاب سیاست دخالت ندارد.

در مسیر مستقیم، افیک ماکرو Qwen3 8B برابر ۰/۷۲۱۹۰۳ و مقدار Gemini 2.5 Flash برابر ۰/۸۰۴۸۸۶ است. در مسیر THOR SC3، مقادیر به ترتیب ۰/۶۰۶۴۵ و ۰/۷۱۶۱۰۹ هستند. بنابراین، مسیر استدلالی برای هر دو مدل از پیش‌بینی مستقیم ضعیف‌تر است، هرچند افت مشاهده‌شده در پشته Gemini کمتر است.

پس از تنظیم سیاست انتخاب، افیک ماکرو Qwen3 8B برابر ۰/۷۲۱۹۰۳ و باقی مانده و برای Gemini 2.5 Flash به ۰/۸۰۸۳۴ رسیده است. در این زیرمجموعه، انتخاب منبع برای Qwen نسبت به مسیر مستقیم سود خالصی ایجاد نکرده و بهبود Gemini نیز محدود است. از این رو، نتیجه شکل بیش از آنکه اثر علی ظرفیت مدل را نشان دهد، بیانگر وابستگی سود مراحل بعدی به انتخاب مدل، پشته اجرا و الگوی خطای مشاهده‌شده در همین تنظیم آزمایشی است.

$n = 90$ آزمون مشترک متوازن زیرمجموعه



شکل ۳-۵: مقایسه امتیاز افیک ماکرو Qwen3 8B و Gemini 2.5 Flash روی زیرمجموعه مشترک ۹۰ نمونه‌ای آزمون.

۳-۷-۵ ماتریس‌های درهم‌ریختگی Gemini

شکل ۴-۵ تغییر رفتار کلاسی Gemini را پس از انتخاب منبع نشان می‌دهد. دقت کلی هر دو پیکربندی برابر ۸۱٪ است و هر کدام ۷۳ پاسخ درست دارند، اما توزیع خطاها یکسان نیست.

		Gemini 2.5 Flash مستقیم پیش‌بینی					Gemini منتخب سیاست		
		منفی	خنثی	مثبت			منفی	خنثی	مثبت
واقعی برچسب	منفی	۲۷ ۰٪۹۰	۲ ۷٪۶	۱ ۳٪۳	واقعی برچسب	منفی	۲۷ ۰٪۹۰	۲ ۷٪۶	۱ ۳٪۳
	خنثی	۳ ۰٪۱۰	۱۸ ۰٪۶۰	۹ ۰٪۳۰		خنثی	۳ ۰٪۱۰	۲۰ ۷٪۶۶	۷ ۳٪۲۳
	مثبت	۱ ۳٪۳	۱ ۳٪۳	۲۸ ۳٪۹۳		مثبت	۱ ۳٪۳	۳ ۰٪۱۰	۲۶ ۷٪۸۶
پیش‌بینی‌شده برچسب					پیش‌بینی‌شده برچسب				

سطری نرمال‌شده درصد‌های و شمار: $n = 90$ آزمون مشترک متوازن زیرمجموعه

شکل ۴-۵: ماتریس‌های درهم‌ریختگی پیش‌بینی مستقیم و سیاست انتخاب تنظیم‌شده برای Gemini 2.5 Flash روی آزمون مشترک.

در کلاس منفی، هر دو روش ۲۷ نمونه درست دارند. در کلاس خنثی، شمار پاسخ‌های درست از ۱۸ به ۲۰ افزایش یافته و خطای خنثی به مثبت از ۹ به ۷ کاهش یافته است. در مقابل، پاسخ‌های درست کلاس مثبت از ۲۸ به ۲۶ کاهش یافته و خطای مثبت به خنثی از یک به سه رسیده است. این جابه‌جایی توضیح می‌دهد که چرا دقت ثابت مانده، ولی افیک ماکرو اندکی تغییر کرده است. انتخاب منبع تعادل میان کلاس‌های خنثی و مثبت را عوض کرده، نه اینکه تعداد کل پاسخ‌های درست را افزایش دهد.

۵-۸ ملاحظات اجرایی و محدودیت‌ها

مسیر مستقیم برای هر نمونه یک پاسخ کوتاه تولید می‌کند و کم‌هزینه‌ترین پیکربندی است. مسیر THOR SC3 کل زنجیره استدلال را سه بار اجرا می‌کند و بازبینی تشخیصی نیز برای موارد اختلاف فراخوانی اضافی دارد. بنابراین، افزایش عملکرد سامانه نهایی با هزینه محاسباتی بیشتر همراه است. از آنجا که زمان اجرا در محیط‌های مختلف به سخت‌افزار، بار سرویس و پشته مدل وابسته است و آزمایش زمان‌سنجی کنترل‌شده‌ای انجام نشده، در این فصل ادعای عددی درباره سرعت یا هزینه ارائه نمی‌شود. نخستین محدودیت تجربی، تمرکز مجموعه اصلی بر داده‌های انگلیسی SCAPT و دو دامنه لپ‌تاپ و رستوران است. تعمیم نتیجه به زبان‌ها، دامنه‌ها یا شیوه برچسب‌گذاری دیگر به ارزیابی مستقل نیاز دارد. دوم، مقایسه Gemini فقط روی ۹۰ نمونه آزمون مشترک انجام شده است و نباید با نتیجه کامل Qwen در یک جمعیت واحد تلقی شود. سوم، مسیر استدلالی غیرقطعی است و خودسازگاری فقط بخشی از تغییرپذیری پاسخ را مهار می‌کند.

محدودیت دیگر به منبع تشخیصی مربوط است. اگرچه بازبین نوع خطا و اطمینان را برای ساخت پروفایل فراهم می‌کند، برچسب تشخیصی در هیچ نمونه آزمون منبع نهایی نبوده است. پس شواهد این آزمایش از نقش اطلاعات تشخیصی در انتخاب میان مستقیم و THOR پشتیبانی می‌کنند، اما برتری مستقل برچسب تشخیصی را نشان نمی‌دهند. همچنین، فاصله باقی‌مانده با اوراکل نباید به‌عنوان عملکرد دست‌یافتنی قطعی تفسیر شود؛ اوراکل از اطلاعاتی استفاده می‌کند که هنگام پیش‌بینی در دسترس نیست.

۹-۵ جمع‌بندی

این فصل نشان داد که استدلال چندمرحله‌ای به‌تنهایی از پیش‌بینی مستقیم دقیق‌تر نیست. هر دو نسخه THOR و نیز بازبینی ساده روی آزمون کامل Qwen3 8B پایین‌تر از خط پایه مستقیم قرار گرفتند. کنترل‌گر قاعده‌محور بخشی از خطاها را مهار کرد، اما خروجی آن نیز از خط پایه عبور نکرد. این نتایج ضرورت جداسازی تولید استدلال از انتخاب پاسخ نهایی را تأیید می‌کنند.

سامانه نهایی محافظت‌شده انتخاب منبع، دقت آزمون را از ۰/۶۷۸۷۳۳ به ۰/۷۲۳۹۸۲ و افیک ماکرو را از ۰/۶۷۴۰۷۵ به ۰/۷۱۹۱۱۹ رساند. بهبود در هر دو دامنه و هر سه کلاس مشاهده شد. انتخاب‌گر ۲۶ خطای مستقیم را اصلاح و شش پاسخ درست را تضعیف کرد و در نهایت ۲۰ پاسخ درست بیشتر ساخت. با این حال، ۱۱۶ نمونه مشترک نادرست و فاصله حدود شش واحد درصدی افیک ماکرو با اوراکل نشان می‌دهند که هم منابع پیش‌بینی و هم سازوکار انتخاب هنوز قابل بهبودند.

مقایسه تکمیلی نشان داد که Gemini 2.5 Flash روی زیرمجموعه مشترک از Qwen3 8B سنجه‌های بالاتری دارد، اما انتخاب منبع در این جمعیت کوچک فقط بهبود محدودی برای Gemini ایجاد کرده و برای Qwen تغییری در افیک ماکرو نداده است. بنابراین، اثر مراحل استدلال و انتخاب به الگوی خطای مدل پایه و جمعیت ارزیابی وابسته است. فصل ششم بر پایه این یافته‌ها نتیجه‌گیری کلی پژوهش، محدودیت‌های اصلی و مسیرهای کار آتی را بیان می‌کند.

فصل ششم

نتیجه‌گیری و کارهای آتی

۱-۶ جمع‌بندی پژوهش

تحلیل احساسات ضمنی با تحلیل متن‌هایی سروکار دارد که نگرش نویسنده را بدون اتکای مستقیم به واژه‌های احساسی آشکار منتقل می‌کنند. در چنین متن‌هایی، قطبیت ممکن است از پیامد یک رویداد، برآورده‌شدن یا نشدن انتظار، مقایسه، توصیه یا رابطه میان هدف و بافت استنباط شود. دشواری مسئله زمانی بیشتر می‌شود که یک جمله چند موجودیت داشته باشد یا گزارشی خنثی در کنار نشانه‌ای احساسی قرار گیرد. از این‌رو، سامانه تحلیل باید هم احساس بیان‌نشده را بازیابی کند و هم از نسبت‌دادن نگرش به هدفی نادرست یا تفسیر افراطی یک واقعیت خنثی بپرهیزد.

هدف این پژوهش طراحی و ارزیابی سامانه‌ای چندمنبعی برای تحلیل احساسات ضمنی هدف‌محور بود. سامانه پیشنهادی یک پیش‌بینی مستقیم را در کنار مسیر استدلال چندمرحله‌ای الهام‌گرفته از THOR قرار داد. هنگام اختلاف این دو مسیر، بازبینی ساختاریافته نوع خطا، برچسب پیشنهادی و سطح اطمینان را تولید کرد و کنترل‌گر قاعده‌محور تصمیمی میانی ساخت. در مرحله نهایی، سیاستی محافظت‌شده که آستانه‌های آن فقط با اعتبارسنجی‌های داخلی بخش آموزش تنظیم شده بود، از میان منابع مستقیم، استدلالی و تشخیصی منبع مناسب را انتخاب کرد. این تفکیک اهمیت دارد؛ زیرا خروجی کنترل‌گر پاسخ نهایی سامانه نیست و انتخاب نهایی نیز به برچسب‌های طلایی آزمون دسترسی ندارد.

ارزیابی اصلی با Qwen3 8B و از طریق Ollama روی آزمون کامل SCAPT انجام شد. نتایج نشان دادند که افزودن مراحل استدلالی به‌تنهایی دقت را تضمین نمی‌کند. هر دو پیکربندی استدلالی بررسی‌شده از پیش‌بینی مستقیم ضعیف‌تر بودند و کنترل‌گر قاعده‌محور نیز به‌تنهایی از خط پایه عبور نکرد. با این حال، منابع مختلف دقیقاً در نمونه‌های یکسان خطا نمی‌کردند. سیاست انتخاب منبع توانست از این مکمل‌بودن استفاده کند و عملکرد نهایی را در هر دو دامنه و هر سه کلاس بهبود دهد.

بنابراین، یافته محوری پژوهش برتری مستقل یک زنجیره استدلال یا یک پرامپت خاص نیست. نتیجه اصلی این است که در تحلیل احساسات ضمنی، تولید استدلال و انتخاب پاسخ نهایی باید دو مسئله جدا در نظر گرفته شوند. استدلال چندمرحله‌ای می‌تواند شواهد و پاسخ‌های مکمل فراهم کند، اما استفاده از آن باید تحت کنترل سازوکاری باشد که از داده آموزش می‌آموزد هر منبع در چه شرایطی قابل اعتمادتر است.

۲-۶ پاسخ به پرسش‌های پژوهش

بر پایه نتایج فصل پنجم، پاسخ پرسش‌های مطرح‌شده در فصل نخست به شرح زیر است:

۱. **تفاوت پیش‌بینی مستقیم و استدلال چندمرحله‌ای.** پیش‌بینی مستقیم مسیر کوتاه‌تر و کم‌هزینه‌تری فراهم کرد و در ارزیابی اصلی از هر دو نسخه استدلالی دقیق‌تر بود. در مقابل، مسیر THOR تصمیم را به تشخیص جنبه، استنتاج نظر و تعیین قطبیت تقسیم کرد و ردپایی قابل بررسی ساخت. این ردپا برای تحلیل و تولید منبع مکمل مفید بود، اما افزایش تعداد مراحل باعث انتقال خطای جنبه یا نظر به برجسب نهایی نیز شد. پس پاسخ بخش دوم پرسش منفی است: استدلال چندمرحله‌ای به‌تنهایی همواره موجب بهبود نمی‌شود و در تنظیم آزمایشی این پژوهش از پیش‌بینی مستقیم ضعیف‌تر بود.

۲. **نقش بازبینی ساختاریافته و کنترل‌گر.** بازبینی ساختاریافته اختلاف میان دو مسیر را به اطلاعاتی قابل استفاده شامل نوع خطا، پیشنهاد اصلاح و اطمینان تبدیل کرد. این اطلاعات امکان داد تصمیم‌ها بر اساس رده‌های مشخصی مانند احساس ازدست‌رفته، بیش‌تفسیر خنثی و جابه‌جایی دامنه هدف بررسی شوند. با این حال، خروجی کنترل‌گر قاعده‌محور هنوز از خط پایه مستقیم پایین‌تر بود و برجسب تشخیصی نیز در هیچ نمونه آزمون به‌عنوان منبع نهایی انتخاب نشد. بنابراین، بازبینی و کنترل‌گر اختلاف را ردیابی‌پذیرتر و قابل کنترل‌تر کردند، اما شواهد موجود برتری مستقل پاسخ تشخیصی یا قواعد ثابت کنترل‌گر را نشان نمی‌دهند. فایده عملی اطلاعات تشخیصی در این پژوهش، کمک به ساخت پروفایل انتخاب میان منابع مستقیم و استدلالی بود.

۳. **اثر انتخاب منبع تنظیم‌شده با داده آموزش.** پاسخ این پرسش در مجموعه اصلی مثبت است. سامانه نهایی بدون استفاده از برجسب طلایی آزمون، دقت را از ۰/۶۷۸۷۳۳ به ۰/۷۲۳۹۸۲ و امتیاز افیک ماکرو را از ۰/۶۷۴۰۷۵ به ۰/۷۱۹۱۱۹ رساند. این سیاست ۲۶ خطای پیش‌بینی مستقیم را اصلاح کرد و در مقابل، ۶ پاسخ درست مستقیم را تضعیف کرد. حاصل خالص، ۲۰ پاسخ درست بیشتر بود. در نتیجه، انتخاب وابسته به الگوهای آموخته‌شده از بخش آموزش از اتکای ثابت به مسیر مستقیم یا استدلالی مناسب‌تر بود. این نتیجه به سیاست، داده و مدل بررسی‌شده مقید است و به معنای برتری هر انتخاب‌گر در هر مجموعه دیگری نیست.

۴. **الگوهای اصلی خطا.** تحلیل کیفی سه الگوی برجسته را نشان داد. در حالت نخست، مدل پیامد یا انتظار ضمنی را بازبینی نمی‌کند و احساس مثبت یا منفی را از دست می‌دهد. در حالت دوم،

یک گزاره خبری یا خنثی بیش از حد تفسیر می‌شود و قطبیتی بدون شاهد کافی شکل می‌گیرد. در حالت سوم، نگرش مربوط به یک موجودیت یا وضعیت کلی به هدف تعیین شده منتقل می‌شود. مسیر استدلالی می‌تواند الگوی نخست را اصلاح کند، اما در صورت تثبیت نادرست هدف یا جنبه، دو الگوی دیگر را تشدید می‌کند. همچنین، پیش‌بینی مستقیم و سامانه نهایی در ۱۱۶ نمونه آزمون هر دو نادرست بودند؛ از این رو، بخشی از خطاها با انتخاب بهتر میان منابع موجود رفع نمی‌شود.

۵. اثر انتخاب مدل و پشته‌آه اجرا. این مقایسه روی ۹۰ نمونه مشترک آزمون انجام شد. در آن، Gemini در هر دو مسیر مستقیم و استدلالی امتیاز بالاتری از اجرای متناظر Qwen داشت. با این حال، مسیر THOR برای هر دو مدل از پیش‌بینی مستقیم همان مدل ضعیف‌تر بود. انتخاب منبع برای Gemini بهبودی محدود ایجاد کرد و برای Qwen در این زیرمجموعه تغییری در افیک ماکرو نداد. چون خانواده مدل، زیرساخت اجرا و سایر مشخصات نیز هم‌زمان متفاوت‌اند، این مشاهده فقط رابطه انتخاب مدل و الگوی خطای آن با میزان سود مراحل بعدی را در تنظیم حاضر نشان می‌دهد و اثر علی ظرفیت مدل را اثبات نمی‌کند. با توجه به اندازه محدود آزمون مشترک، این نتیجه شاهی تکمیلی است و نباید به عنوان رتبه‌بندی عمومی دو مدل یا تضمین رفتار آن‌ها در داده‌های دیگر تفسیر شود.

۳-۶ دستاوردهای اصلی

۱-۳-۶ دستاوردهای علمی

نخستین دستاورد علمی پژوهش، صورت‌بندی استدلال چندمرحله‌ای به عنوان منبعی مکمل به جای پاسخ قطعی سامانه است. کیفیت ظاهری ردپای استدلال صحت برچسب را تضمین نمی‌کند؛ از این رو، تولید تفسیر و انتخاب پاسخ دو وظیفه جدا هستند. دستاورد دوم، تفکیک بازبینی، کنترل میانی و انتخاب نهایی است. بازبین خطای احتمالی را ساختارمند می‌کند، کنترل‌گر تصمیمی قابل ردیابی می‌سازد و انتخاب‌گر با تکیه بر الگوهای آموزش منبع پاسخ را تعیین می‌کند.

دستاورد دیگر، ارزیابی انتخاب منبع بدون نشت اطلاعات آزمون است. پروفایل‌ها و آستانه‌های محافظ فقط با بخش آموزش ساخته و تنظیم و سپس پس از تثبیت روی آزمون اعمال شدند. بهبود حاصل نشان داد که می‌توان مکمل بودن خطاهای منابع را بدون دسترسی به پاسخ آزمون به سود عملی تبدیل کرد.

در عین حال، فاصله سامانه نهایی با اوراکل نشان می‌دهد که تشخیص منبع مناسب هنوز مسئله‌ای باز است.

۲-۳-۶ دستاوردهای فنی و مهندسی

از نظر فنی، پروژه خط لوله‌ای انتهابه‌انتها از خواندن داده تا گزارش نهایی فراهم کرد. تقسیم رسمی آموزش و آزمون حفظ شد و خروجی‌های مستقیم، استدلالی، تشخیصی، کنترل‌گر و نهایی جداگانه ذخیره شدند. پیش از ارزیابی نیز شمار و یکتایی ردیف‌ها، هم‌ترازی شناسه، جمله، هدف و دامنه و اعتبار برچسب‌ها به‌صورت خودکار کنترل شد.

اجرای اصلی با Qwen3 8B و Ollama در یک چارچوب واحد انجام شد. برای مقایسه تکمیلی نیز خروجی دو مدل روی شناسه‌های مشترک سنجیده شد تا تفاوت جمعیت آزمون وارد مقایسه نشود. این اجزا امکان ردیابی خروجی هر مرحله و تکرار ارزیابی در محدوده تنظیمات گزارش شده را فراهم می‌کند.

۴-۶ محدودیت‌های پژوهش

مجموعه اصلی شامل متن‌های انگلیسی و فقط دو دامنه لپ‌تاپ و رستوران است؛ بنابراین، تعمیم نتیجه به زبان فارسی، شبکه‌های اجتماعی یا حوزه‌های تخصصی به آزمایش مستقل نیاز دارد. نتیجه اصلی نیز به اجرای کامل Qwen3 8B تعلق دارد. مقایسه Gemini 2.5 Flash فقط روی ۹۰ نمونه آزمون مشترک انجام شد و شاهی تکمیلی است.

مسیر استدلال چندمرحله‌ای غیرقطعی است. خودسازگاری بخشی از نوسان برچسب را مهار می‌کند، اما خطاهای مشترک اجراها را از بین نمی‌برد. ردپای استدلال نیز ارزیابی انسانی مستقلی از نظر صحت و وفاداری نداشته است. از سوی دیگر، مراحل چندگانه فراخوانی و متن بیشتری تولید می‌کنند و چون زمان سنجی کنترل شده انجام نشده، نسبت دقیق بهبود به زمان یا هزینه مشخص نیست.

اطلاعات تشخیصی در ساخت پروفایل‌ها نقش داشتند، اما برچسب پیشنهادی بازبین در هیچ نمونه آزمون منبع نهایی نبود؛ پس کارایی مستقل آن اثبات نشده است. برخی پروفایل‌ها کم‌نمونه‌اند، ولی سیاست اصلی برای پشتیبانی کمتر از ۱۰ یا حاشیه ناکافی به مسیر مستقیم بازمی‌گردد؛ بنابراین، خطر تصمیم‌های مبتنی بر گروه‌های کوچک محدود شده، نه اینکه کم‌نمونه‌بودن آن گروه‌ها حذف شده باشد. فاصله سامانه نهایی با اوراکل فقط کرانی تحلیلی است و نباید عملکرد تضمین شده انتخاب‌گر آینده تلقی شود.

در نهایت، مسیر THOR برای مدل، داده و زیرساخت پروژه سازگار شده و بازتولید کامل تنظیم رسمی پژوهش اصلی نیست. وزن مدل‌ها ثابت مانده و اثر ریزتنظیم نیز بررسی نشده است. یافته‌های این پایان‌نامه در نتیجه به چارچوب پرامپت‌محور و انتخاب منبع محدود می‌شوند.

۵-۶ کارهای آتی

۱-۵-۶ توسعه و بهبود انتخاب‌گر منبع

می‌توان شمار تقسیم‌های اعتبارسنجی را افزایش داد و پایداری انتخاب پروفایل‌ها و آستانه‌های محافظ را با باز نمونه‌گیری سنجید. هموارسازی الگوهای کم‌نمونه و ادغام پروفایل‌های مشابه نیز قابل بررسی‌اند. فرادسته‌بندهای کنترل‌شده می‌توانند با ویژگی‌های تنظیم‌شده از بخش آموزش و قید پرهیز از اصلاح کم‌اطمینان توسعه یابند. ارزیابی آن‌ها باید علاوه بر میانگین عملکرد، شمار پاسخ‌های درستی را که تضعیف می‌شوند گزارش کند و جدایی آموزش و آزمون را حفظ کند.

۲-۵-۶ بهبود بازبینی و استدلال هدف‌محور

برای کاهش جابه‌جایی دامنه هدف، می‌توان بازه هدف و شواهد مرتبط را در تمام مراحل برجسته کرد و پیش از تعیین قطبیت، ارتباط شاهد با هدف را سنجید. آزمون سازگاری میان جنبه، نظر و برچسب نیز می‌تواند استدلال‌های ناهم‌جهت را آشکار کند. بازبین آینده بهتر است شواهد موافق و مخالف را تفکیک و نبود شاهد کافی را معتبر تلقی کند. اطمینان تشخیصی نیز باید با داده اعتبارسنجی کالیبره و اثر تغییرها با کاهش خطاهای هدف‌محور سنجیده شود.

۳-۵-۶ تحلیل خطاهای مشترک و گسترش منابع

تحلیل دقیق‌تر ۱۱۶ نمونه مشترک نادرست می‌تواند سهم دانش عمومی، ابهام برچسب، ساختار نحوی و چندهدف‌بودن جمله را روشن کند. برای این موارد باید منابعی با شیوه استنتاج یا دانش متفاوت، مانند پرامپت هدف‌محور مستقل یا بازیابی دانش زمینه‌ای، بررسی شوند. افزودن هر منبع باید با مطالعه حذف مؤلفه همراه باشد تا اثر تنوع واقعی از افزایش صرف تعداد فراخوانی‌ها جدا شود.

۴-۵-۶ گسترش ارزیابی به داده‌ها و مدل‌های دیگر

ارزیابی روی مجموعه داده‌ها، دامنه‌ها و زبان‌های دیگر، به‌ویژه متن فارسی، می‌تواند پایداری سیاست انتخاب را روشن کند. مقایسه مدل‌ها نیز باید روی چند زیرمجموعه مستقل یا آزمون کامل انجام شود. در این بررسی، علاوه بر امتیاز نهایی، تغییر الگوهای خطا، مکمل بودن منابع و نیاز انتخاب‌گر به تنظیم دوباره با داده آموزش اهمیت دارد.

۵-۵-۶ کاهش هزینه اجرا

مراحل پرهزینه می‌توانند فقط هنگام نامطمئن بودن پیش‌بینی مستقیم یا وجود نشانه ابهام هدف فعال شوند. چنین دروازه‌ای باید کاهش فراخوانی را همراه با تغییر عملکرد گزارش کند. اندازه‌گیری کنترل‌شده زمان، شمار توکن، حافظه و هزینه سرویس نیز امکان مقایسه پیکربندی‌ها برای کاربردهای برخط، دسته‌ای و کم‌منبع را فراهم می‌کند.

۶-۵-۶ ارزیابی انسانی و ریزتنظیم

ردپای استدلال باید از نظر صحت شواهد، ارتباط با هدف، سازگاری با قطبیت و وفاداری ارزیابی انسانی شود. در صورت فراهم‌شدن داده بزرگ‌تر و برجسب‌های معتبر برای جنبه، نظر، شواهد و نوع خطا، ریزتنظیم پارامترکم نیز قابل بررسی است. این مسیر باید با خط پایه پرامپت‌محور و تحت تقسیم یکسان مقایسه شود؛ زیرا آموزش با برجسب‌های خودتولیدشده ممکن است خطای مدل مولد را بازتولید کند.

۶-۶ نتیجه‌گیری نهایی

این پایان‌نامه نشان داد که افزودن مراحل بیشتر به یک پرامپت، به‌تنهایی تحلیل احساسات ضمنی را بهبود نمی‌دهد. پیش‌بینی مستقیم مرجعی قوی بود و استدلال چندمرحله‌ای، با وجود ایجاد ردپای قابل تحلیل، خطاهای تازه‌ای نیز وارد کرد. ارزش آن زمانی آشکار شد که به‌عنوان منبعی مکمل به کار رفت و انتخاب پاسخ از تولید استدلال جدا شد.

دست‌آورد اصلی پژوهش چارچوبی برای مدیریت اختلاف منابع است: خطای احتمالی ساختارمند می‌شود و پاسخ نهایی با سیاستی جداگانه و آموخته‌شده از آموزش انتخاب می‌گردد. بهبود مشاهده‌شده به داده و تنظیم حاضر مقید است، اما نشان می‌دهد توجه هم‌زمان به شواهد، محدوده هدف و اعتمادپذیری

نسبی منابع مسیر مناسبی برای ادامه پژوهش است.

منابع و مراجع

- [1] Pontiki, Maria, Galanis, Dimitris, Pavlopoulos, John, Papageorgiou, Harris, Androutsopoulos, Ion, and Manandhar, Suresh. Semeval-2014 task 4: Aspect based sentiment analysis. in Proceedings of the 8th International Workshop on Semantic Evaluation (SemEval 2014), pp. 27–35. Association for Computational Linguistics, 2014.
- [2] Fei, Hao, Li, Bobo, Liu, Qian, Bing, Lidong, Li, Fei, and Chua, Tat-Seng. Reasoning implicit sentiment with chain-of-thought prompting. in Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (Volume 2: Short Papers), pp. 1171–1183. Association for Computational Linguistics, 2023.
- [3] Duan, Zhihua and Wang, Jialin. Implicit sentiment analysis based on chain-of-thought prompting. arXiv preprint arXiv:2408.12157, 2024.
- [4] Wei, Jason, Wang, Xuezhi, Schuurmans, Dale, Bosma, Maarten, Ichter, Brian, Xia, Fei, Chi, Ed H., Le, Quoc V., and Zhou, Denny. Chain-of-thought prompting elicits reasoning in large language models. in Advances in Neural Information Processing Systems, vol. 35, pp. 24824–24837, 2022.
- [5] Wang, Xuezhi, Wei, Jason, Schuurmans, Dale, Le, Quoc V., Chi, Ed H., Narang, Sharan, Chowdhery, Aakanksha, and Zhou, Denny. Self-consistency improves chain of thought reasoning in language models. in International Conference on Learning Representations, 2023.

- [6] Pang, Bo and Lee, Lillian. Opinion mining and sentiment analysis. *Foundations and Trends in Information Retrieval*, 2(1–2):1–135, 2008.
- [7] Wankhade, Mayur, Rao, Annavarapu Chandra Sekhara, and Kulkarni, Chaitali. A survey on sentiment analysis methods, applications, and challenges. *Artificial Intelligence Review*, 55(7):5731–5780, 2022.
- [8] Wang, Kai, Shen, Weizhou, Yang, Yunyi, Quan, Xiaojun, and Wang, Rui. Relational graph attention network for aspect-based sentiment analysis. in *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, pp. 3229–3238. Association for Computational Linguistics, 2020.
- [9] Li, Zhengyan, Zou, Yicheng, Zhang, Chong, Zhang, Qi, and Wei, Zhongyu. Learning implicit sentiment in aspect-based sentiment analysis with supervised contrastive pre-training. in *Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing*, pp. 246–256. Association for Computational Linguistics, 2021.
- [10] Wang, Siyin, Zhou, Jie, Sun, Changzhi, Ye, Junjie, Gui, Tao, Zhang, Qi, and Huang, Xuanjing. Causal intervention improves implicit sentiment analysis. in *Proceedings of the 29th International Conference on Computational Linguistics*, pp. 6966–6977. International Committee on Computational Linguistics, 2022.
- [11] Liu, Pengfei, Yuan, Weizhe, Fu, Jinlan, Jiang, Zhengbao, Hayashi, Hiroaki, and Neubig, Graham. Pre-train, prompt, and predict: A systematic survey of prompting methods in natural language processing. *ACM Computing Surveys*, 55(9), 2023.

پیوست: جزئیات بازتولید آزمایش‌ها

این پیوست اطلاعات لازم برای بازسازی ارزیابی‌های گزارش‌شده را خلاصه می‌کند. خروجی‌های خام و میانی هر مرحله به‌صورت فایل‌های جداگانه ذخیره شده‌اند؛ بنابراین، بازتولید جدول‌ها و شکل‌های نهایی به اجرای دوباره مدل زبانی نیاز ندارد.

داده و تقسیم‌بندی

داده اصلی از نمونه برچسب‌خورده و ضمنی SCAPT مبتنی بر SemEval 2014 به دست آمده است. پس از پاک‌سازی، ۲۱۸۸ نمونه شامل ۱۷۴۶ نمونه آموزش و ۴۴۲ نمونه آزمون باقی مانده است. تقسیم رسمی آموزش و آزمون در تمام مراحل حفظ می‌شود. برای تطبیق پایدار ردیف‌ها، کلید مرکب شامل id، شناسه جمله منبع، متن جمله، هدف، بازه هدف و قطبیت به کار می‌رود.

مدل‌ها و تنظیمات تولید

اجرای اصلی از مدل qwen3:8b از طریق Ollama استفاده می‌کند. پیش‌بینی مستقیم با دمای صفر تولید می‌شود. در مسیر THOR، مراحل استخراج جنبه، استخراج نظر ضمنی و تولید استدلال قطبیت با دمای ۷/۰ اجرا می‌شوند؛ مرحله تبدیل استدلال به برچسب نهایی دمای صفر دارد. برای خودسازگاری سه‌جایی، سه مسیر استدلالی برای هر نمونه تولید و برچسب‌ها با رأی اکثریت تجمیع می‌شوند. مقایسه تکمیلی Gemini 2.5 Flash فقط روی زیرمجموعه متوازن ۲۴۰ نمونه‌ای انجام شده است.

انتخاب منبع

سیاست اصلی، انتخاب‌گر پروفایلی محافظت‌شده و تنظیم‌شده با اعتبارسنجی داخلی بخش آموزش است. ویژگی‌های پروفایل شامل پیش‌بینی مستقیم، پیش‌بینی THOR، نوع خطای تشخیصی، سطح اطمینان و دامنه است. واگذاری به منبع غیرمستقیم فقط در صورت پشتیبانی و حاشیه کافی انجام می‌شود؛ در غیر این صورت، پیش‌بینی مستقیم قاعده بازگشت است. هیچ برجسب طلایی آزمون در ساخت پروفایل‌ها، تنظیم آستانه‌ها یا انتخاب منبع نهایی استفاده نمی‌شود.

فایل‌های اصلی خروجی

- results/direct_isa_predictions.csv
- results/thor_originalish_sc3_isa_predictions.csv
- results/final_results_table.csv
- results/tfidf_logreg_predictions.csv

وجود واژه originalish در نام داخلی بعضی فایل‌های خروجی صرفاً برای سازگاری با اجراهای ذخیره‌شده است و نام علمی روش محسوب نمی‌شود.

فرمان‌های بازتولید گزارش

فرمان‌های زیر در ریشه مخزن و در محیط ویندوز اجرا می‌شوند:

```
.\.venv\Scripts\python.exe -B `
    experiments\run_final_pipeline.py
.\.venv\Scripts\python.exe -B `
    experiments\generate_thesis_result_figures.py
.\.venv\Scripts\python.exe -m unittest discover `
    -s tests -p "test_*.py" -v
powershell.exe -NoProfile -ExecutionPolicy Bypass `
```


-File .\scripts\build_thesis.ps1

فرمان `run_final_pipeline.py` پیش‌بینی‌های ذخیره‌شده را اعتبارسنجی و جدول نهایی را بازسازی می‌کند و مدل زبانی را دوباره اجرا نمی‌کند. فرمان `generate_thesis_result_figures.py` نیز شکل‌ها را از همان خروجی‌های ذخیره‌شده می‌سازد. اجرای دوباره استنتاج مستلزم راه‌اندازی پشته مدل و اجرای جداگانه اسکرپت‌های مراحل مستقیم، استدلالی و تشخیصی است و برای بازسازی اعداد این پایان‌نامه ضروری نیست.

واژه‌نامه فارسی به انگلیسی

Precision	صحت پیش‌بینی	Evaluation	ارزیابی
Large Language Model . .	مدل زبانی بزرگ	Multi-Stage	استدلال چندمرحله‌ای
Confusion Matrix . .	ماتریس درهم‌ریختگی	Reasoning	
Macro-F1	افیک ماکرو	Source Selection	انتخاب منبع
		Diagnostic Review	بازبینی تشخیصی
		Recall	بازخوانی
		Prompt	پرامپت
		Direct Prediction	پیش‌بینی مستقیم
		Implicit Sentiment	تحلیل احساسات ضمنی
		Analysis	
		Aspect-	تحلیل احساسات مبتنی بر جنبه
		Based Sentiment Analysis	
		Self-Consistency	خودسازگاری
		Accuracy	دقت
		Chain of Thought	زنجیره تفکر

واژه‌نامه انگلیسی به فارسی

Accuracy دقت	Large Language Model . . مدل زبانی بزرگ
Aspect- . . . تحلیل احساسات مبتنی بر جنبه . . . Based Sentiment Analysis	Macro-F1 افیک ماکرو
Chain of Thought زنجیره تفکر	Multi-Stage استدلال چندمرحله‌ای Reasoning
Confusion Matrix . . ماتریس درهم‌ریختگی	Precision صحت پیش‌بینی
Diagnostic Review بازبینی تشخیصی	Prompt پرامپت
Direct Prediction پیش‌بینی مستقیم	Recall بازخوانی
Evaluation ارزیابی	Self-Consistency خودسازگاری
Implicit Sentiment Analysis تحلیل احساسات ضمنی	Source Selection انتخاب منبع

Abstract

Detecting sentiment in texts without explicit evaluative words requires contextual understanding, commonsense knowledge, and inference about the relationship between a described event and its target. This thesis presents a prompt-based, multi-source system for implicit sentiment analysis. The system combines a language model’s direct prediction with multi-stage reasoning inspired by THOR, structured error diagnosis, and a source-selection policy. The final selection policy is tuned using the training data and, without access to gold test labels, selects one of the direct, reasoning, or diagnostic sources. The main evaluation uses the SCAPT-labelled data derived from SemEval 2014 in the laptop and restaurant domains. The main dataset contains 2,188 examples, with 1,746 training examples and 442 test examples. The primary experiments use Qwen3 8B through Ollama. On the test set, the final system increases accuracy from 0.678733 to 0.723982 and Macro-F1 from 0.674075 to 0.719119. A supplementary comparison with Gemini 2.5 Flash is also conducted on a balanced subset of 240 examples. For the model, data, and experimental setting examined in this thesis, the results indicate that controlled source selection is more effective than relying on one fixed prediction path. **Key Words:**

Implicit Sentiment Analysis, Large Language Models, Chain-of-Thought, Multi-Stage Reasoning, Source Selection